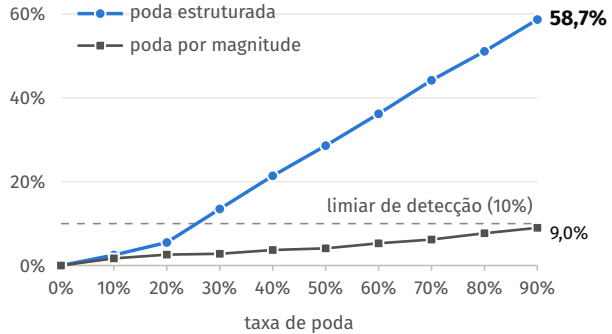
Resultados · Pergunta A: custo e energia

Só a poda estruturada reduziu o consumo de energia



Com 90% de taxa de poda

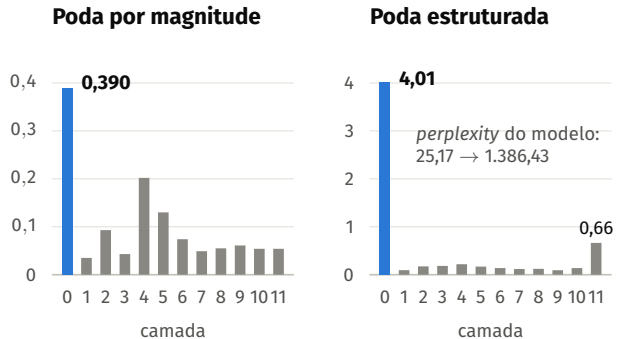
	Magnitude	**Estruturada**
Parâmetros	−61%	**−61%**
Memória	0%	**−61%**
FLOPs	0%	**−62%**
Energia	n.d.	**−59%**
Tempo	n.d.	**−56%**

n.d.: não detectável, abaixo do limiar de 10%. Na poda por magnitude, contam-se os parâmetros não nulos.

Redução de energia (ΔE) em relação ao modelo base medido na mesma sessão.

A poda por magnitude zera pesos, mas mantém as dimensões dos tensores; a estruturada remove cabeças de atenção e neurônios do MLP.

A camada 0 concentra a sensibilidade do modelo



77%

da degradação de podar as 12 camadas é atingida ao podar só a camada 0 (poda estruturada a 50%).

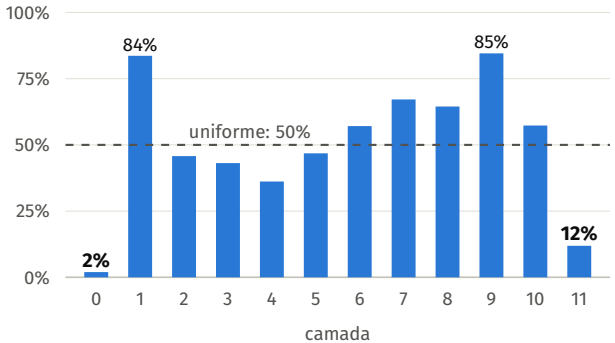
42,9×

é a razão entre a degradação da camada mais sensível e a da mais tolerante (poda estruturada); 11,3× na poda por magnitude.

Δ_ℓ: aumento do logaritmo da *perplexity* ao podar só a camada ℓ a 50%, sem *fine-tuning*. Escalas verticais diferentes.

A ordenação das camadas se manteve ao repetir o perfil com taxa-sonda de 30%: correlação de postos de 0,944 (magnitude) e 0,713 (estruturada).

O perfil define quanto podar em cada camada

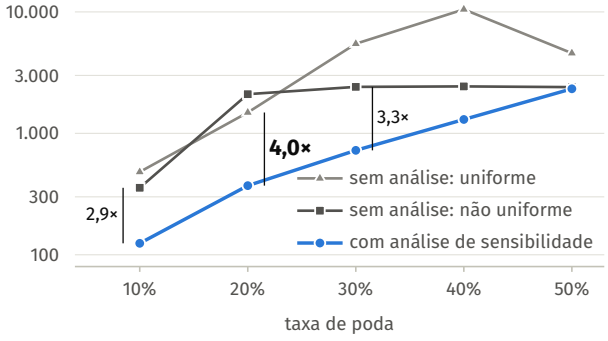


- Cada camada recebe uma taxa proporcional à sua **tolerância**: o inverso da degradação medida no perfil.
- As camadas mais sensíveis são preservadas: **2%** na camada 0 e **12%** na camada 11.
- A taxa de poda do modelo não muda: a média das 12 camadas continua **50%**.

Taxa de poda por camada na poda estruturada, para uma taxa de poda de 50%, com parâmetro de intensidade $\beta = 1{,}0$.

O esquema de poda uniforme aplicaria 50% também à camada 0, a mais sensível do modelo.

Análise de sensibilidade: *perplexity* até 4 vezes menor



4,0×

menor *perplexity* a 20% de taxa de poda: de 1.484,89 para 371,07.

2,5×

na média geométrica de 10% a 50%: de 1.602,62 para 632,46.

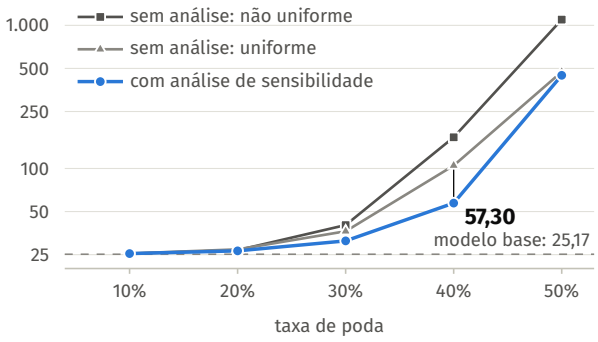
Mesma energia

ΔE médio de 18,0%, contra 14,3% e 18,7% sem a análise.

Escala logarítmica, sem *fine-tuning* (modelo base: 25,17). Fatores em relação ao melhor esquema sem a análise em cada taxa.

Controle: com $\beta = 0$, o esquema reproduz a poda uniforme até a última casa decimal. O ganho vem do perfil de sensibilidade.

O ganho se repetiu na poda por magnitude



7 de 9

taxas de poda com a menor *perplexity*: todas de 20% a 80%.

57,30

contra 104,82 do melhor esquema sem a análise, a 40%: quase a metade.

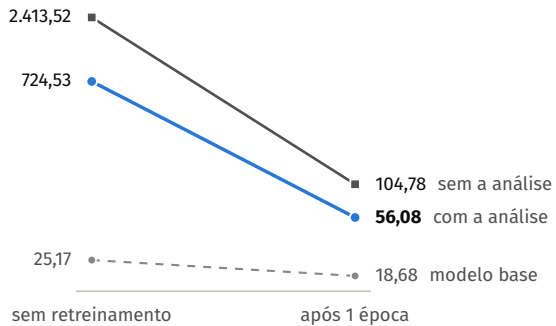
−15%

na média geométrica de 10% a 50%: de 66,00 para 55,80.

Escala logarítmica, sem *fine-tuning*. Curva com a análise: $\beta = 0{,}5$; a contagem de 7 em 9 considera também $\beta = 1{,}0$.

A análise de sensibilidade reduziu a perda de qualidade nas duas estratégias de poda.

Após uma época de *fine-tuning*, a vantagem se manteve a 30%



1,87×

menor *perplexity* com a análise de sensibilidade, na mesma taxa de poda: 56,08 contra 104,78.

≈ 19%

menos energia e tempo de inferência que o modelo base retreinado, nas duas configurações (ΔE de 17,7% e 19,1%).

Perplexity em escala logarítmica. Poda estruturada a 30%, com e sem análise de sensibilidade ($\beta = 1{,}0$); uma época no conjunto de treino do WikiText-2.

O dano medido sem retreinamento é parcialmente reversível, e o esquema de poda com análise de sensibilidade continuou à frente ao mesmo custo.

Conclusões

A poda estruturada reduz a energia, e a análise de sensibilidade reduz a perda de qualidade

Pergunta A

A redução de parâmetros se converte em redução real de tempo e energia?

Só quando a poda remove estruturas.

- Poda estruturada a 90%: 61% menos parâmetros, **59% menos energia** e 56% menos tempo.
- Poda por magnitude: 61% menos parâmetros não nulos, sem redução detectável de energia.

Pergunta B

A análise de sensibilidade por camada melhora o compromisso entre compressão e qualidade?

Sim, nas taxas de poda de 10% a 50%.

- Poda estruturada: *perplexity* **2,5 vezes menor** na média, até 4 vezes a 20%, com a mesma energia.
- Poda por magnitude: menor *perplexity* em 7 de 9 taxas.
- Após uma época de *fine-tuning*, a 30%: *perplexity* 1,87 vez menor.