1 Introdução

[TODO]

1.1 Objetivos

[TODO]

1.1.1 Objetivo Geral

[TODO]

1.1.2 Objetivos Específicos

[TODO]

1.2 Organização da monografia

[TODO]

Este trabalho é composto por XX capítulos. Neste Capítulo 1, proporcionamos uma introdução, justificativa e delineamos os objetivos...

2 Fundamentação Teórica

Este capítulo apresenta os conceitos necessários para a compreensão do trabalho. Inicialmente, são introduzidos fundamentos de aprendizado profundo e redes neurais artificiais, seguidos pelo processo de treinamento dessas redes. Em seguida, discute-se o problema do consumo energético em modelos de *Deep Learning* e, por fim, são apresentadas as técnicas de compressão de modelos, com destaque para a poda neural (*pruning*), que é o foco deste trabalho.

A exposição é deliberadamente progressiva e não pressupõe familiaridade prévia com aprendizado de máquina. Cada conceito é introduzido primeiro por meio de uma analogia com situações cotidianas e só então formalizado, de modo que o leitor possa acompanhar o raciocínio antes de encontrar a notação matemática que o descreve.

2.1 Aprendizado Profundo e Redes Neurais

2.1.1 Aprendizado Profundo (Deep Learning)

O Aprendizado Profundo é um campo especializado de aprendizado de máquina (GOODFELLOW; BENGIO; COURVILLE, 2016; LECUN; BENGIO; HINTON, 2015), caracterizado pelo uso de redes neurais artificiais com múltiplas camadas, o que permite aprender e extrair informações complexas a partir de grandes volumes de dados.

2.1.2 Redes Neurais Artificiais

A rede neural artificial é um modelo computacional inspirado na estrutura do cérebro humano, que busca imitar a forma como neurônios se conectam e processam sinais para aprender a partir de dados, identificando padrões e tomando decisões. Um exemplo clássico é o perceptron multicamadas (MLP), um modelo composto por funções matemáticas que mapeiam valores de entrada em valores de saída (GOODFELLOW; BENGIO; COURVILLE, 2016). Em tarefas de visão computacional, por exemplo, milhões de imagens de um objeto podem ser processadas para que a rede aprenda suas características visuais e seja capaz de reconhecê-lo posteriormente.

Uma forma de tentar enteder a definição de uma RNN é, imagine uma comissão encarregada de decidir se um pedido de empréstimo deve ser aprovado. Nenhum membro decide sozinho, cada um examina um aspecto diferentee, como a renda declarada, o histórico de pagamentos, o tempo de emprego e então, após analisar todos os aspectos, emite um parecer. Esses pareceres não têm todos o mesmo valor, pois a comissão confia mais

em uns avaliadores do que em outros, e a decisão final combina todos eles, ponderados por essa confiança. Em uma rede neural, cada nó é um desses avaliadores e o peso de cada conexão é exatamente a confiança depositada naquele parecer. A diferença essencial é que a rede não recebe essas confianças prontas, ela as descobre sozinha, por tentativa e erro, ao longo do treinamento.

Uma rede neural profunda é composta por unidades (nós) interconectadas, organizadas em camadas (GOODFELLOW; BENGIO; COURVILLE, 2016; NIELSEN, 2015).

- **Nó (neurônio):** É uma unidade computacional que calcula uma soma ponderada das entradas mais um *bias* e passa o resultado através de uma função de ativação, produzindo uma saída.
- **Camada de Entrada (Input Layer):** É onde o processo é iniciado e os dados são introduzidos na rede. O número de nós nessa camada corresponde ao número de características dos dados de entrada.
- **Camadas Ocultas (Hidden Layers):** São camadas intermediárias entre a entrada e a saída. Cada nó de uma camada oculta está conectado a todos os nós das camadas anterior e seguinte. É nelas que ocorre a maior parte do processamento e do aprendizado; a saída de uma camada oculta é utilizada como entrada da próxima, e, a cada camada, a rede passa a detectar características mais complexas e abstratas. Redes com múltiplas camadas ocultas são as chamadas redes de *Deep Learning*.
- **Camada de Saída (Output Layer):** Camada final da rede, onde o resultado é produzido. A estrutura da camada de saída depende da tarefa: em regressão, há um único nó com função de ativação linear; em classificação binária, um único nó expressa resultados do tipo sim/não; em classificação multiclasse, há um nó para cada classe possível, e o de maior ativação corresponde à predição final.

Cada conexão entre nós possui um peso associado, que determina a sua importância relativa. Pesos altos amplificam o sinal de entrada, enquanto pesos próximos de zero tornam a conexão pouco influente. Os pesos são inicializados com valores aleatórios e ajustados durante o treinamento (GOODFELLOW; BENGIO; COURVILLE, 2016).

2.1.3 Bias em Redes Neurais

O *bias* é um parâmetro adicional que ajusta a saída de um neurônio. Trata-se de um valor numérico associado a cada neurônio, não ligado a nenhuma entrada específica, atuando como um coeficiente linear. Antes da aplicação da função de ativação, o *bias* é somado ao resultado da soma ponderada das entradas.

A principal função do *bias* é deslocar a função de ativação, permitindo que o modelo se ajuste melhor aos dados. Sem ele, a soma ponderada precisaria ser alta para que o neurônio fosse ativado; com o *bias*, um neurônio pode ser ativado mesmo com uma soma ponderada baixa, caso seu *bias* seja suficientemente alto (NIELSEN, 2015). Inversamente, um *bias* muito negativo dificulta a ativação do neurônio. O *bias* é um parâmetro aprendível: inicialmente é inicializado com zero ou valores próximos de zero e, durante o treinamento, é atualizado pelo mesmo processo de retropropagação e descida de gradiente utilizado para os pesos.

Retomando com a analogia da comissão de crédito, se os pesos representam o quanto se confia em cada avaliador, o *bias* representa o quanto o avaliador é exigente. Um membro gentil aprova o pedido mesmo diante de evidências modestas; um membro rigoroso só aprova quando as evidências são fortes. São duas coisas independentes — confiar muito em alguém não diz nada sobre o quanto essa pessoa é exigente — e é por isso que a rede precisa aprender os dois conjuntos de valores separadamente.

2.1.4 Função de Ativação

A função de ativação é uma função matemática aplicada ao resultado da soma ponderada das entradas de um neurônio (já acrescido do *bias*), determinando a saída do neurônio. Sua principal função é introduzir não linearidade no modelo: sem ela, a composição de diversas camadas resultaria em uma transformação puramente linear, equivalente a uma rede com uma única camada, o que limitaria drasticamente a capacidade expressiva do modelo (GOODFELLOW; BENGIO; COURVILLE, 2016).

A razão de existir dessa função merece um exemplo concreto, pois é ela que justifica o próprio empilhamento de camadas. Considere um produto de R$ 100,00 submetido a dois descontos sucessivos, um de 10% e outro de 20%: o primeiro leva o preço a R$ 90,00 e o segundo a R$ 72,00, exatamente o mesmo resultado que um único desconto de 28% produziria. Os dois passos colapsaram em um só, e o segundo nada acrescentou que um único desconto bem escolhido não fizesse sozinho. Encadear operações lineares nunca gera nada além de outra operação linear, e com redes neurais acontece o mesmo: sem função de ativação, uma rede de cem camadas calcularia exatamente aquilo que uma única camada já calcularia, e toda a profundidade seria desperdiçada.

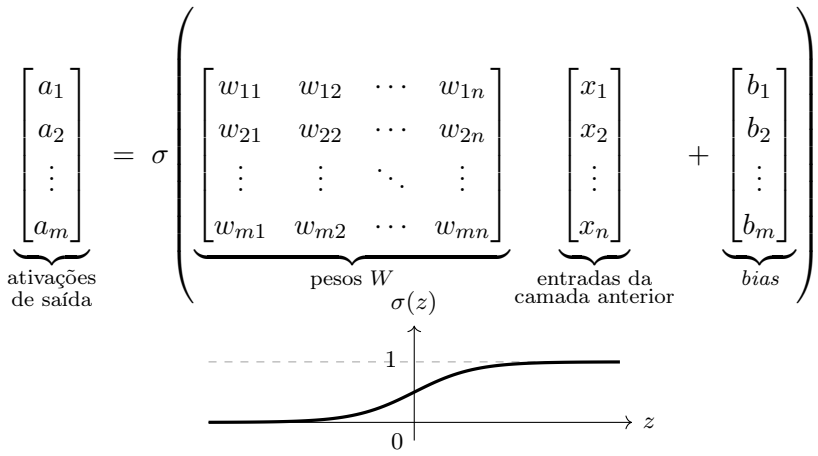
Suponha agora que a loja adote uma regra adicional, aplicada logo depois de cada desconto: nenhum produto pode ser vendido por menos de R$ 85,00. Essa regra é o análogo da função de ativação — ela não faz parte do desconto, mas incide sobre o resultado dele, antes que esse resultado siga para a etapa seguinte. Com ela, o encadeamento deixa de colapsar. O produto de R$ 100,00 cai para R$ 90,00 e depois para R$ 72,00, mas a regra o devolve a R$ 85,00, de modo que o desconto efetivo foi de 15%. Já um produto de R$ 200,00 percorre os mesmos dois descontos, chega a R$ 144,00 sem nunca esbarrar

no limite e tem desconto efetivo de 28%. A mesma sequência de operações passou a produzir resultados diferentes conforme a entrada, e nenhum desconto único reproduz esse comportamento. É esse rompimento do encadeamento que permite a cada camada acrescentar algo que a anterior não conseguia representar. A regra de preço mínimo, aliás, tem a mesma forma da ReLU, apresentada adiante nesta seção: ambas preservam os valores acima de um limiar e substituem os demais por um valor fixo.

A ativação de um neurônio ocorre em três etapas (NIELSEN, 2015):

- Soma ponderada: o neurônio multiplica o valor de ativação de cada nó da camada anterior pelo peso da respectiva conexão e soma todos os resultados.
- Adição do *bias*: ao resultado da soma ponderada é somado o valor do *bias*, que auxilia o neurônio a ativar-se mais ou menos facilidade.
- Função de ativação: o resultado final (soma ponderada acrescida do *bias*) é passado pela função de ativação, cuja saída é então transmitida aos nós da próxima camada.

Figura 1 – Representação matricial da propagação de um neurônio, da soma ponderada à função de ativação (Sigmoide).



a função de ativação comprime qualquer valor de z no intervalo $(0, 1)$

Fonte: Adaptado de Nielsen (2015).

Há diversas funções de ativação, cada uma com suas próprias características e aplicações.

- **ReLU (Rectified Linear Unit):** Função de ativação mais utilizada em redes neurais modernas, proposta para redes profundas por Nair e Hinton (2010) e popularizada por Krizhevsky, Sutskever e Hinton (2012). É uma função linear por partes, com inclinação 1 para valores positivos e 0 para valores negativos. É computacionalmente muito eficiente e não sofre do problema do desaparecimento do gradiente

para entradas positivas. Em contrapartida, pode sofrer do problema conhecido como *Dying ReLU*, no qual neurônios cujas entradas se tornam persistentemente negativas deixam de ser ativados e param de aprender.

- **Sigmoide:** Função que mapeia qualquer valor real para o intervalo $(0, 1)$, sendo útil em classificação binária, já que a saída pode ser interpretada como uma probabilidade. Caiu em desuso em camadas ocultas porque, para entradas com magnitude muito alta ou muito baixa, sua derivada se aproxima de zero, fenômeno conhecido como desaparecimento do gradiente (BENGIO; SIMARD; FRASCONI, 1994).

- **Tanh (Tangente Hiperbólica):** Semelhante à Sigmoide, porém mapeando os valores para o intervalo $(-1, 1)$, o que a torna centrada em zero e costuma favorecer a convergência. Também sofre do problema do desaparecimento do gradiente.

- **Softmax:** Diferentemente das demais, não é aplicada a neurônios individuais de camadas ocultas, mas sim ao conjunto dos neurônios da camada de saída em tarefas de classificação multiclasse. Transforma as saídas brutas da última camada em uma distribuição de probabilidades, com valores no intervalo $(0, 1)$ que somam 1. Na prática, converte pontuações sem escala definida em porcentagens comparáveis: o modelo deixa de responder "7,2 para gato e 3,1 para cachorro" e passa a responder "85% de chance de ser gato, 15% de ser cachorro".

Em cada camada, as ativações produzidas determinam as ativações da camada seguinte. De camada em camada, esses padrões tornam-se progressivamente mais complexos e abstratos, até que a camada de saída produz o resultado final. Assim, camadas iniciais aprendem características simples, enquanto camadas mais profundas combinam essas características para representar conceitos de alto nível (LECUN; BENGIO; HINTON, 2015).

2.2 Treinamento de Redes Neurais

2.2.1 Gradiente

No contexto de redes neurais, o gradiente corresponde ao vetor de derivadas parciais da função de perda em relação aos pesos da rede. Ele é o elemento central que permite a minimização da função de perda por meio do algoritmo da descida do gradiente, um método de primeira ordem que utiliza as informações do gradiente para atualizar os parâmetros da rede (GOODFELLOW; BENGIO; COURVILLE, 2016).

Formalmente, sendo L a função de perda e $\mathbf{w} = (w_1, w_2, \ldots, w_n)$ o conjunto dos n parâmetros da rede, o gradiente é o vetor que reúne a derivada parcial da perda em relação a cada um deles (GOODFELLOW; BENGIO; COURVILLE, 2016):

$$\nabla L(\mathbf{w}) = \left[\frac{\partial L}{\partial w_1},\ \frac{\partial L}{\partial w_2},\ \ldots,\ \frac{\partial L}{\partial w_n}\right] \tag{2.1}$$

Cada componente do vetor de gradiente é uma derivada parcial, calculada assumindo que as demais variáveis são mantidas constantes. A magnitude da derivada indica o quanto a função está variando; o seu sinal, a direção dessa variação: positivo, a função está aumentando; negativo, diminuindo.

Tomado como um todo, o vetor da Equação 2.1 aponta na direção em que a perda cresce mais rapidamente. É por isso que a descida do gradiente caminha no sentido oposto, $-\nabla L(\mathbf{w})$: seguir o gradiente invertido é o que aproxima a rede de um mínimo da função de perda.

Uma analogia comum é a de um caminhante que desce uma encosta em meio à neblina, enxergando apenas o solo ao seu redor: a cada passo, ele sente para qual lado o terreno mais desce (o oposto do gradiente) e avança nessa direção. Na descida do gradiente, a "encosta" é a função de perda e os "passos" são os ajustes nos pesos, repetidos até alcançar um ponto de mínimo.

2.2.2 Backpropagation

A retropropagação (*backpropagation*) é o algoritmo que permite o aprendizado das redes neurais, por possibilitar o cálculo da contribuição de cada parâmetro (peso ou *bias*) para o erro da predição (RUMELHART; HINTON; WILLIAMS, 1986). Uma vez que o erro é calculado na camada de saída, o algoritmo executa um fluxo invertido: da saída em direção à entrada, propagando o erro para as camadas anteriores.

A lógica é a mesma de uma apuração de responsabilidades em uma linha de produção. Sabe-se apenas que o produto final saiu defeituoso; para corrigir o processo, é preciso percorrer a linha de trás para frente e estimar o quanto cada etapa contribuiu para o defeito. Uma etapa que respondeu por boa parte do problema precisa de um ajuste grande; outra que quase não influiu, de um ajuste pequeno. O *backpropagation* faz esse rastreamento de forma matemática, atribuindo a cada peso da rede uma parcela de responsabilidade pelo erro.

Para saber como cada peso individual se correlaciona com o erro, o algoritmo calcula a derivada parcial da função de perda em relação a esse peso, utilizando a regra da cadeia multivariada para decompor o cálculo em derivadas intermediárias. Com todas as derivadas obtidas, um algoritmo de otimização atualiza cada peso na direção oposta ao gradiente:

$$w_{novo} = w_{antigo} - \eta \cdot \frac{\partial L}{\partial w}$$

em que η é a taxa de aprendizado, hiperparâmetro que controla o tamanho do ajuste aplicado a cada iteração.

Voltando ao caminhante na neblina, a taxa de aprendizado é o tamanho do passo que ele dá. Passos curtos demais tornam a descida segura, porém lenta a ponto de o treinamento não terminar em tempo viável, já passos longos demais fazem o caminhante descer mais rápido, mas aumenta o risco de se machucar. Encontrar um valor adequado é uma das decisões mais sensíveis do treinamento.

2.2.3 Hiperparâmetros

Hiperparâmetros são variáveis externas que definem tanto o algoritmo de aprendizado quanto a arquitetura da rede neural. Diferentemente dos parâmetros do modelo (pesos e *biases*), que são ajustados automaticamente pelo *backpropagation*, os hiperparâmetros são definidos antes do início do treinamento e controlam como a rede aprende a partir dos dados. Existem técnicas automatizadas para sua busca, como *grid search* (BERGSTRA; BENGIO, 2012) e otimização bayesiana (SNOEK; LAROCHELLE; ADAMS, 2012), mas o ajuste manual baseado em experiência ainda é amplamente empregado.

A distinção entre parâmetros e hiperparâmetros é a mesma que separa, em uma cozinha, as escolhas do cozinheiro do resultado do cozimento. A temperatura do forno e o tempo de preparo são definidos antes de o prato ir ao fogo e não se alteram sozinhos: são os hiperparâmetros. O ponto da massa e a cor da crosta, por outro lado, são produzidos pelo processo: são os parâmetros. Errar a temperatura não impede o prato de assar, mas compromete o resultado e, do mesmo modo, hiperparâmetros mal escolhidos não impedem o treinamento de ocorrer, apenas fazem com que ele chegue a um modelo pior.

Em geral, os hiperparâmetros podem ser agrupados em duas categorias:

- **Hiperparâmetros de arquitetura:** definem a estrutura da rede, como o número de camadas ocultas, o número de neurônios em cada camada e o tipo de função de ativação utilizada.
- **Hiperparâmetros de treinamento:** controlam como o modelo se ajusta aos dados, como a taxa de aprendizado, o número de épocas, o tamanho do lote (*batch size*) e a escolha do algoritmo de otimização.

2.2.4 Passo a passo do treinamento

O treinamento de uma rede neural supervisionada requer uma grande base de dados rotulada, isto é, cada exemplo de entrada deve estar associado a uma saída correta. Essa base de dados é tradicionalmente dividida em três subconjuntos (GOODFELLOW; BENGIO; COURVILLE, 2016):

- **Conjunto de treinamento**, usado para ajustar os pesos e *biases*;

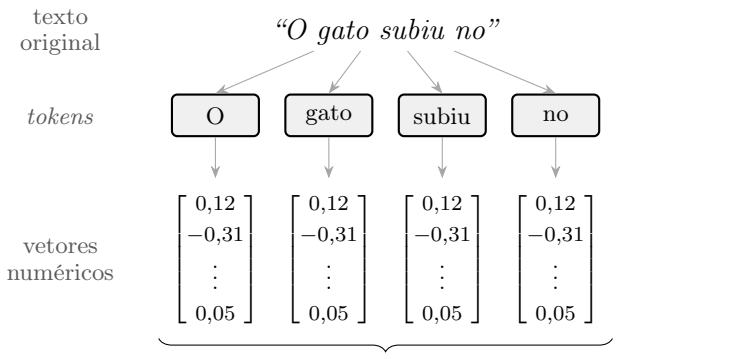
- **Conjunto de validação**, usado para monitorar o desempenho durante o treinamento e ajustar hiperparâmetros;
- **Conjunto de teste**, usado para avaliar o desempenho final do modelo de forma imparcial.

Além disso, é necessário definir a arquitetura da rede (camadas, neurônios, funções de ativação) e os hiperparâmetros de treinamento. O treinamento ocorre ao longo de diversas iterações, nas quais cada passagem completa pelo conjunto de treinamento é chamada de época (*epoch*); em cada época, os dados são processados em pequenos lotes (*batches*) (GOODFELLOW; BENGIO; COURVILLE, 2016).

A analogia mais direta é a de um estudante diante de um livro. Uma época equivale a percorrer o livro inteiro uma vez; os lotes são os trechos em que essa leitura é dividida, com uma pausa para revisão ao fim de cada um. E, assim como raramente basta uma única leitura para fixar o conteúdo, a rede precisa percorrer o conjunto de treinamento diversas vezes até que os ajustes se estabilizem.

Como exemplo, considere um modelo de linguagem que recebe a frase "O gato subiu no". Antes de qualquer cálculo, o texto precisa virar número: ele é fragmentado em unidades menores, chamadas *tokens*, e cada *token* é convertido em um vetor de valores numéricos. São esses vetores que alimentam a camada de entrada — cada posição do vetor corresponde a um nó (JURAFSKY; MARTIN, 2025).

Figura 2 – Da frase aos nós da camada de entrada: o texto é fragmentado em *tokens* e cada *token* é convertido em um vetor numérico.



Fonte: .

O ciclo de treinamento pode ser resumido nos seguintes passos (GOODFELLOW; BENGIO; COURVILLE, 2016):

- **Passo 1 – Inicialização dos parâmetros:** pesos são inicializados com valores aleatórios baixos e *biases* com zero. Essa quebra de simetria permite que diferentes neurônios aprendam características distintas.

- **Passo 2 – *Forward pass*:** um lote de dados é inserido na camada de entrada e propagado através das camadas ocultas até a camada de saída, produzindo uma predição.
- **Passo 3 – Cálculo da perda:** a predição é comparada com o rótulo verdadeiro por meio de uma função de perda, que quantifica numericamente o quão distante a predição está do valor correto.
- **Passo 4 – *Backpropagation*:** o erro é propagado de volta pela rede, calculando-se o gradiente da função de perda em relação a cada peso e *bias*.
- **Passo 5 – Atualização dos parâmetros:** um otimizador atualiza pesos e *biases* na direção oposta ao gradiente, reduzindo a função de perda.
- **Passo 6 – Repetição:** os passos 2 a 5 são repetidos para cada lote e ao longo de um número definido de épocas.

O treinamento é interrompido quando o modelo atinge uma precisão satisfatória ou quando a função de perda deixa de diminuir significativamente.

2.3 Arquitetura Transformer

A arquitetura *Transformer*, proposta por Vaswani et al. (2017) no trabalho *Attention is All You Need*, marcou uma mudança profunda na forma como modelos de aprendizado profundo processam sequências de texto. Antes dessa proposta, o campo era dominado por arquiteturas que processavam a sequência elemento por elemento, palavra por palavra. O *Transformer* rompeu com essa abordagem ao introduzir um mecanismo capaz de considerar toda a sequência de uma só vez. Esta seção apresenta, de forma progressiva, os conceitos necessários para compreender a arquitetura utilizada neste trabalho: as limitações das abordagens anteriores, o mecanismo de atenção, a operação de autoatenção e sua versão multi-cabeça, a estrutura de cada bloco da rede e, finalmente, o modelo GPT-2, que é o objeto central dos experimentos de poda.

2.3.1 O Problema que o Transformer Resolve

Toda arquitetura nasce como resposta a uma limitação da anterior, e o *Transformer* não é exceção. Compreender qual era essa limitação é o que transforma o mecanismo de atenção em uma solução, e não em uma escolha arbitrária.

Até 2017, o processamento de texto era dominado pelas redes neurais recorrentes (*Recurrent Neural Networks*, RNNs). Elas leem a frase palavra por palavra, na ordem em que aparece, carregando consigo um resumo do que já foi lido: a cada nova palavra, esse

resumo é atualizado. É, em essência, o modo como uma pessoa lê um texto em voz alta, guardando na memória o que veio antes. Dessa mecânica decorrem os dois problemas que motivaram o *Transformer*.

O primeiro é o esquecimento. Considere o trecho "A Inglaterra é minha terra natal. Passei toda a minha vida lá. Mudei-me para a Espanha há dois dias. Eu falo apenas uma língua, que é o ___". Preencher a lacuna com "inglês" exige recuperar uma palavra que apareceu muito antes. Como o resumo é reescrito a cada passo, a informação antiga vai se diluindo, e a influência de "Inglaterra" chega enfraquecida ao final. Tecnicamente, o fenômeno se manifesta durante o treinamento como gradiente desaparecente (*vanishing gradient*): os gradientes são multiplicados repetidamente pelas matrizes de peso e, quando esses valores são pequenos, encolhem até se aproximarem de zero (BENGIO; SIMARD; FRASCONI, 1994). É a limitação conhecida como incapacidade de lidar com dependências de longo alcance. Arquiteturas posteriores, como as redes LSTM (*Long Short-Term Memory*), atenuaram o esquecimento por meio de mecanismos que regulam o que deve ser mantido ou descartado (HOCHREITER; SCHMIDHUBER, 1997), mas não resolveram o segundo problema.

O segundo é a lentidão, como cada palavra só pode ser processada depois da anterior, a leitura é obrigatoriamente sequencial: não há como dividir o trabalho entre vários processadores. Isso desperdiça justamente a principal característica das unidades de processamento gráfico (GPUs) modernas, que é executar milhares de operações ao mesmo tempo.

Foi para atacar essas duas limitações simultaneamente que se desenvolveu o mecanismo de atenção.

2.3.2 Mecanismo de Atenção

O passo seguinte dessa evolução foi o mecanismo de atenção (*attention mechanism*), introduzido por Bahdanau, Cho e Bengio (2015) no contexto da tradução automática. Em vez de comprimir toda a frase em um único estado oculto, a atenção permite que o modelo "olhe" de volta e foque seletivamente em partes específicas da entrada. No exemplo anterior, ela pode consultar diretamente o termo "Inglaterra", independentemente de quão distante ele esteja da lacuna, eliminando o risco de o gradiente desaparecer pelo caminho.

Para operacionalizar essa ideia, o mecanismo utiliza três conceitos: a consulta (*query*), a chave (*key*) e o valor (*value*). Uma analogia útil é a de uma biblioteca: cada livro tem uma etiqueta na lombada (a *chave*) que descreve seu conteúdo; quando um leitor chega com uma pergunta (a *consulta*), ela é comparada com cada etiqueta para decidir quais livros são mais relevantes; o conteúdo desses livros (os *valores*) é então com-

binado, com os mais relevantes contribuindo mais para a resposta. No *Transformer*, esse processo ocorre com números: a relevância entre uma consulta e cada chave é calculada matematicamente, e os valores são somados com pesos proporcionais a essa relevância.

A inovação central de Vaswani et al. (2017), em 2017, foi construir uma arquitetura inteira baseada exclusivamente nesse mecanismo, dispensando por completo a recorrência. Com isso, todas as posições de uma sequência se comunicam diretamente em uma única operação, sem precisar "passar" por palavras intermediárias. Isso resolve as duas limitações das RNNs de uma só vez: as dependências de longo alcance tornam-se tão fáceis de capturar quanto as de curto alcance, e o cálculo passa a ser paralelizável, tornando as arquiteturas baseadas em RNN e LSTM obsoletas para muitas tarefas modernas.

2.3.3 Autoatenção e Atenção Multi-Cabeça

A variante do mecanismo de atenção utilizada no *Transformer* é chamada de autoatenção (*self-attention*). O prefixo "auto" indica que a consulta, a chave e o valor são todos derivados da mesma sequência de entrada. Ou seja, ao processar uma frase, cada palavra pergunta a si mesma: "quais outras palavras desta frase são relevantes para minha interpretação?". Exemplo: "O gato que estava no telhado dormiu". Ao processar a palavra "dormiu", o mecanismo de autoatenção calcula um peso para cada palavra da frase. A palavra "gato" recebe peso alto, pois é o sujeito do verbo; palavras como "telhado" ou "no" recebem pesos baixos, pois são menos relevantes para determinar quem dormiu.

Na prática, esses pesos são calculados da seguinte forma, a partir de cada representação de entrada, três matrizes de pesos aprendíveis durante o treinamento transformam cada representação em três vetores: o vetor de consulta Q (*query*), o vetor de chave K (*key*) e o vetor de valor V (*value*). O grau de compatibilidade entre uma consulta e cada chave é calculado pelo produto escalar entre eles. Esses valores brutos de compatibilidade passam pela função *softmax*, que os converte em uma distribuição de probabilidades, isto é, um conjunto de números entre 0 e 1 que somam exatamente 1. Esses pesos normalizados determinam com que intensidade cada valor V contribui para o resultado final, que é obtido pela soma ponderada dos valores.

Essa operação completa é denominada *Scaled Dot-Product Attention* (atenção por produto escalar escalado) e é definida formalmente por (VASWANI et al., 2017):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Em termos intuitivos, o produto $QK^\top$ mede a compatibilidade entre todas as consultas e todas as chaves de uma só vez; a divisão por $\sqrt{d_k}$ (a dimensão das chaves) é um fator de escala que estabiliza o treinamento; a *softmax* converte essas pontuações em pesos

que somam 1; e a multiplicação por V produz, para cada posição, uma média ponderada dos valores, isto é, sua representação já contextualizada pelo restante da sequência.

Uma única operação de atenção, porém, captura apenas um tipo de relação entre as palavras de cada vez. Para superar essa limitação, Vaswani et al. (2017) propõem a atenção multi-cabeça (*multi-head attention*). A analogia é a seguinte: se a atenção simples é como um único leitor relendo a frase em busca de relações gramaticais, a atenção multi-cabeça é como h leitores independentes, cada um procurando um tipo diferente de relação. Um leitor pode focar em concordância verbal ("gato"/"dormiu"), outro em relações de posse ("telhado do vizinho"), outro em referências pronominais, e assim por diante. O GPT-2 *small*, por exemplo, utiliza 12 cabeças de atenção por bloco.

Na prática, cada uma das h cabeças executa a operação *Scaled Dot-Product Attention* de forma independente, com suas próprias matrizes de projeção aprendíveis para Q, K e V. As saídas das h cabeças são depois concatenadas e projetadas por uma matriz linear aprendível, produzindo a representação final de cada posição. Desse modo, o modelo pode simultaneamente capturar relações em diferentes subespaços semânticos e sintáticos, sem custo adicional expressivo em relação à atenção simples.

Sob a perspectiva da compressão de modelos, as cabeças de atenção constituem unidades podáveis naturais para a poda estruturada: estudos da literatura demonstram que nem todas as cabeças são igualmente úteis, e que algumas podem ser removidas inteiramente sem degradação significativa da qualidade das predições (MICHEL; LEVY; NEUBIG, 2019).

2.3.4 Estrutura do Bloco Transformer

Para entender como o *Transformer* processa informação em profundidade, é útil pensar em cada bloco como uma "estação de trabalho" em uma linha de montagem. Na primeira bancada, as palavras trocam informações entre si por meio da atenção multi-cabeça: cada palavra atualiza sua representação consultando todas as demais. Na segunda bancada, cada palavra refina individualmente sua própria representação, de forma independente das outras, por meio de uma pequena rede totalmente conectada. Esse par de operações se repete em cada bloco, e os blocos são empilhados, fazendo com que as representações das palavras se tornem progressivamente mais ricas e abstratas a cada andar.

O primeiro bloco é a camada de atenção multi-cabeça, já apresentada na seção anterior, responsável por integrar informação contextual de toda a sequência. O segundo é uma rede *feedforward* totalmente conectada — um MLP (*multilayer perceptron*) aplicado de forma idêntica e independente a cada posição. Esse MLP é composto por duas transformações lineares com uma função de ativação não linear entre elas: a função GELU

(*Gaussian Error Linear Unit*) (HENDRYCKS; GIMPEL, 2016) nos modelos GPT, ou ReLU em outras variantes. Diferentemente da ReLU (NAIR; HINTON, 2010), que simplesmente zera valores negativos, a GELU faz uma transição suave em torno da origem. Na prática, essa suavidade evita o problema dos "neurônios mortos" (*dying ReLU*), em que unidades deixam de aprender por receberem gradiente nulo, e por isso Radford et al. (2019) a adotaram como ativação padrão na família GPT. A dimensão intermediária desse MLP é tipicamente quatro vezes maior do que a dimensão do modelo — no GPT-2 *small*, a dimensão do modelo é 768 e a dimensão intermediária é 3.072 — o que confere ao bloco grande capacidade de representação antes de comprimir novamente a informação.

2.3.5 Modelos de Linguagem de Grande Escala e o GPT-2

Modelos de linguagem de grande escala (*Large Language Models*, LLMs) são redes neurais profundas, tipicamente baseadas na arquitetura *Transformer*, treinadas em grandes volumes de texto com o objetivo de aprender a prever palavras. A tarefa de pré-treinamento é simples de enunciar: dado um trecho de texto, o modelo deve prever qual token vem a seguir. Um *token* é a unidade mínima de texto que o modelo processa — pode ser uma palavra, parte de uma palavra, um sinal de pontuação ou um espaço. Dada a sequência "O aluno abriu o", um LLM bem treinado atribuiria alta probabilidade a tokens como "livro", "caderno" ou "computador", e baixa probabilidade a tokens como "foguete" ou "plutônio". Repetida bilhões de vezes sobre textos variados, essa tarefa aparentemente simples força o modelo a aprender gramática, fatos sobre o mundo, raciocínio básico e muito mais (RADFORD et al., 2019).

Para que o texto possa ser processado numericamente, ele precisa primeiro ser convertido em tokens e depois em vetores numéricos. Essa conversão ocorre em duas etapas. A primeira é a tokenização, realizada por algoritmos como o BPE (*Byte Pair Encoding*), que divide o texto em unidades de comprimento variável de forma a equilibrar cobertura e eficiência. Por exemplo, a palavra "inconstitucional" pode ser dividida em tokens como "in", "constitu" e "cional". O GPT-2 possui um vocabulário de aproximadamente 50.257 tokens. A segunda etapa converte cada token em um vetor numérico denso por meio de uma camada de *embedding*: o modelo aprende, durante o treinamento, uma representação vetorial para cada token do vocabulário, de modo que tokens semanticamente próximos tendam a ter representações próximas no espaço vetorial.

O GPT-2 (*Generative Pre-trained Transformer 2*), proposto por Radford et al. (2019) pela OpenAI em 2019, é um modelo autorregressivo baseado exclusivamente no componente decodificador do *Transformer* original. Ele foi pré-treinado em uma base de dados de aproximadamente 40 GB de texto coletado da internet, abrangendo uma grande diversidade de domínios e estilos. A variante GPT-2 *small*, utilizada neste trabalho, possui 12 blocos *Transformer* empilhados, 12 cabeças de atenção por bloco, dimensão de

modelo igual a 768 e aproximadamente 124 milhões de parâmetros treináveis. Apesar de ser a menor variante da família GPT-2, esse número de parâmetros é cerca de cinco vezes maior do que o de uma ResNet-50 (25 milhões de parâmetros), arquitetura de referência nos estudos clássicos de poda — e as variantes maiores da própria família GPT-2 chegam a 1,5 bilhão de parâmetros, o que ilustra a escala característica dos modelos baseados em *Transformer*.

O crescimento em escala dos LLMs ao longo dos anos seguintes foi vertiginoso: o GPT-3, publicado em 2020, possui 175 bilhões de parâmetros; o PaLM, do Google, chega a 540 bilhões. Mesmo modelos de médio porte como o GPT-2 impõem custos energéticos e computacionais consideráveis em ambientes de produção, onde a inferência é executada milhares ou milhões de vezes por dia. A poda estruturada surge, nesse contexto, como uma estratégia concreta para reduzir esses custos: a remoção de cabeças de atenção redundantes e de neurônios MLP de baixa importância pode diminuir substancialmente a contagem de operações por inferência, com impacto controlado sobre a qualidade das predições (PATTERSON et al., 2021).

2.4 Consumo Energético em Redes Neurais

O avanço de técnicas e *hardware* voltados ao treinamento de redes neurais, motivado pela busca por maior precisão, trouxe consigo um consumo de energia considerável e, consequentemente, uma significativa emissão de dióxido de carbono. Strubell, Ganesh e McCallum (2019) relatam, por exemplo, que o treinamento de um modelo *transformer* com busca de arquitetura neural pode emitir cerca de 626.155 libras de CO_2, enquanto a emissão média de um automóvel ao longo de toda a sua vida útil é de aproximadamente 126.000 libras — cerca de cinco vezes menos.

Esse custo energético concentra-se em duas etapas do ciclo de vida de um modelo: o treinamento e a inferência.

No treinamento, o modelo é alimentado com grandes volumes de dados e ajustado iterativamente pelo *backpropagation*. Esse processo é computacionalmente intenso e geralmente requer *hardware* especializado (GPUs ou TPUs), muitas vezes organizado em *clusters* com centenas ou milhares de aceleradores (PATTERSON et al., 2021; SCHWARTZ et al., 2020).

Na inferência, o modelo já treinado é utilizado para gerar predições. O custo de uma única predição é relativamente baixo; contudo, em contextos de larga escala — como os modelos de IA generativa servindo milhões de requisições diárias — o custo energético agregado é expressivo (LUCCIONI; VIGUIER; LIGOZAT, 2022).

A diferença entre as duas etapas é de natureza, não apenas de grandeza. O trei-

namento é um gasto concentrado e único, comparável ao custo de construir uma ponte; a inferência é um gasto pequeno, porém perpétuo, comparável ao custo de mantê-la aberta ao tráfego. Uma ponte muito usada acaba custando, ao longo de décadas, mais em manutenção do que custou para ser erguida — e o mesmo ocorre com um modelo consultado milhões de vezes por dia. É por essa razão que este trabalho concentra-se na eficiência da inferência.

2.5 Compressão de Modelos

Com o crescimento do *Deep Learning*, os modelos de IA vêm dobrando em tamanho a cada poucos anos (SEVILLA et al., 2022). Modelos de alta performance costumam ser otimizados exclusivamente para acurácia, resultando em redes com grande quantidade de parâmetros, que ocupam muito espaço de armazenamento e demandam um elevado número de operações em ponto flutuante (FLOPs) para serem executadas. Isso é particularmente problemático em dispositivos com capacidade limitada, como *smartphones* e sistemas embarcados, e também em contextos de uso em larga escala, nos quais o custo energético se torna significativo.

A compressão de modelos é um campo que reúne técnicas voltadas a atenuar esses problemas, reduzindo o tamanho dos modelos e/ou a quantidade de operações necessárias para sua execução, preservando, tanto quanto possível, a acurácia. As redes neurais modernas possuem alta redundância de parâmetros (DENIL et al., 2013), o que torna viável remover ou simplificar aqueles com baixa contribuição ao resultado final.

Essa redundância não é um defeito, mas uma consequência do modo como esses modelos são construídos. Como não se sabe de antemão quantos parâmetros a tarefa exige, projeta-se a rede com folga generosa, do mesmo modo que se dimensiona uma instalação elétrica para uma carga muito acima da que será efetivamente usada. A folga facilita o treinamento, mas permanece no modelo depois que ele já aprendeu — e é justamente essa sobra que as técnicas de compressão procuram eliminar.

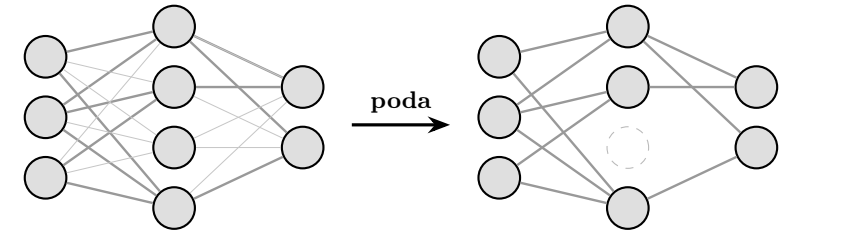
As quatro principais famílias de técnicas de compressão são:

- **Quantização (Quantization):** reduz o número de *bits* utilizados para representar cada peso do modelo. Em vez de pontos flutuantes de 32 bits, os parâmetros passam a ser representados com precisão reduzida (16 ou 8 bits, por exemplo), o que diminui o tamanho do modelo e pode acelerar operações em *hardware* que suporta aritmética de menor precisão (JACOB et al., 2018). O equivalente cotidiano é anotar preços arredondados: registrar R$ 20 em vez de R$ 19,99 ocupa menos espaço e agiliza as contas, e na maioria das situações a diferença é irrelevante.
- **Destilação de Conhecimento (Knowledge Distillation):** proposta por Hinton,

Vinyals e Dean (2015), é uma metodologia de treinamento em que um modelo menor (*aluno*) aprende a partir de um modelo maior e mais preciso (*professor*). O aluno é treinado não apenas para acertar os rótulos verdadeiros, mas também para imitar a distribuição de saída do professor, resultando em um modelo compacto que, frequentemente, alcança acurácia superior à que teria se fosse treinado do zero.

- **Fatoração de Matrizes (Matrix Factorization):** matrizes de pesos de grandes dimensões são decompostas em produto de matrizes menores cuja multiplicação aproxima a matriz original, reduzindo o custo computacional (DENTON et al., 2014).
- **Poda Neural (Neural Pruning):** processo de remoção de pesos — ou de estruturas maiores, como filtros — que contribuem pouco para a saída do modelo. É a técnica central deste trabalho e será detalhada na Seção a seguir.

Figura 3 – Ilustração do processo de poda: a rede original (densa) tem conexões e/ou neurônios removidos, tornando-se esparsa.



Fonte: Adaptado de Han et al. (2015).

2.6 Poda Neural (Pruning)

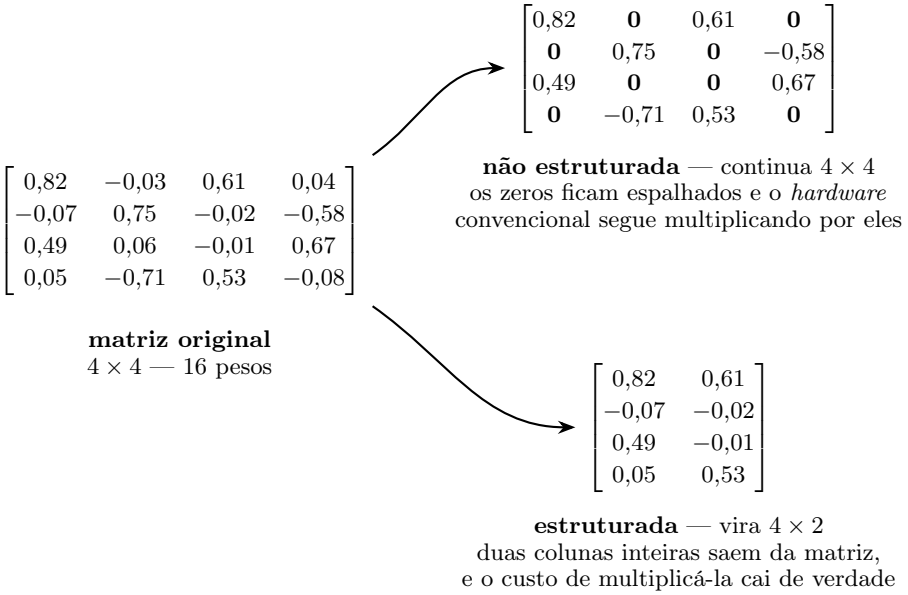
A poda neural é uma técnica de compressão que visa reduzir o tamanho do modelo e o custo computacional da inferência por meio da remoção de parâmetros que pouco contribuem para o resultado final. O processo mais comum parte de um modelo previamente treinado, cujo foco inicial foi exclusivamente a acurácia, e aplica a poda como uma etapa posterior (HAN et al., 2015; BLALOCK et al., 2020).

2.6.1 Tipos de Poda

Na literatura, duas categorias principais de poda são consideradas (BLALOCK et al., 2020):

- **Poda não estruturada:** remoção de pesos individuais, independentemente da sua posição na matriz de pesos. Esta abordagem oferece maior flexibilidade e, geralmente, taxas de compressão elevadas com perda reduzida de acurácia. Entretanto, do ponto de vista do custo de inferência, a poda não estruturada apresenta uma limitação importante: processadores e GPUs convencionais não são eficientes em pular multiplicações por zero espalhadas de forma aleatória na matriz de pesos. Assim, embora o modelo tenha muitos zeros, as operações ainda são executadas, e o ganho prático de velocidade e energia tende a ser marginal, a menos que se utilize *hardware* especializado ou formatos de armazenamento esparso.
- **Poda estruturada:** remoção de estruturas inteiras, como neurônios, filtros ou canais convolucionais, o que implica a remoção completa de detectores de características. Como o resultado é uma matriz menor e ainda densa, há um ganho direto de velocidade e eficiência em *hardware* convencional. O custo dessa abordagem é uma potencial perda maior de acurácia para uma mesma taxa de compressão.

Figura 4 – As duas categorias de poda aplicadas à mesma matriz de pesos. Na poda não estruturada os pesos removidos são apenas zerados e a matriz conserva suas dimensões; na poda estruturada, colunas inteiras são eliminadas e a matriz encolhe de fato.



A distinção entre as duas categorias é o que separa um ganho real de um ganho apenas contábil, e uma analogia com um livro a torna evidente. A poda não estruturada equivale a apagar palavras espalhadas por todas as páginas: o texto fica mais enxuto, mas o livro continua com o mesmo número de páginas, e quem for lê-lo ainda terá de folhear todas elas — inclusive as partes apagadas. A poda estruturada equivale a arrancar capítulos inteiros: o livro encolhe de fato, pesa menos e é percorrido em menos tempo. Como o *hardware* convencional não sabe pular um espaço em branco no meio de uma

multiplicação, apenas a segunda forma se converte em redução efetiva de tempo e de energia. Essa diferença é retomada no Capítulo 6, onde é verificada experimentalmente.

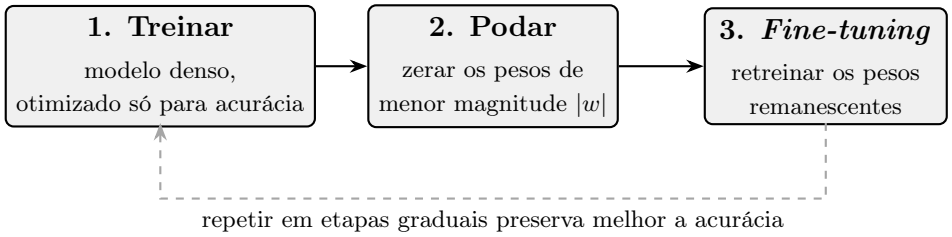
Cabe mencionar também a chamada esparsidade estruturada (por exemplo, padrões 2:4), em que o algoritmo é forçado a zerar, a cada bloco de quatro pesos, exatamente dois. Como o *hardware* sabe previamente quantos e em que formato os zeros aparecem, a matriz pode ser comprimida de maneira determinística, permitindo acelerações reais em GPUs modernas que suportam esse padrão (NVIDIA Corporation, 2020).

Assim, a poda estruturada é a que apresenta benefícios mais imediatos em termos de FLOPs e consumo de energia em *hardware* convencional (LI et al., 2017), razão pela qual ela recebe destaque neste trabalho.

2.6.2 Poda por Magnitude

A técnica mais simples e amplamente estudada é a poda por magnitude. Nela, considera-se que pesos cujos valores absolutos são próximos de zero contribuem pouco para a saída do modelo e, portanto, podem ser removidos. Define-se um limiar (ou uma taxa de esparsidade desejada) e todos os pesos abaixo desse limiar são zerados, criando redes esparsas (HAN et al., 2015).

Figura 5 – Pipeline clássico de poda por magnitude: treinamento do modelo denso, remoção dos pesos de menor magnitude e retreinamento (*fine-tuning*) dos pesos remanescentes.



Fonte: Adaptado de Han et al. (2015).

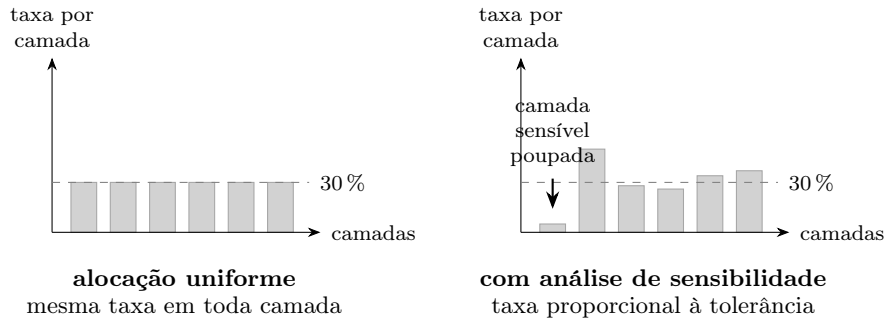
2.6.3 Sensibilidade e a Distribuição da Poda entre Camadas

A poda por magnitude responde a uma pergunta: *quais* pesos remover. Ela deixa intocada uma segunda pergunta, logicamente anterior e menos discutida: *quanto* remover de cada parte da rede. Um modelo com doze camadas podado a uma taxa de 30 % admite infinitas distribuições dessa poda — 30 % em cada camada, 60 % na metade delas e nada na outra metade, ou qualquer combinação intermediária. Todas removem a mesma quantidade de parâmetros e produzem modelos de custo praticamente idêntico, mas não produzem modelos de qualidade idêntica.

A analogia é a de uma empresa que precisa cortar 30 % das despesas. O corte linear — 30 % em todos os setores — é o mais simples de justificar e o que exige menos informação, mas trata a contabilidade e a produção como igualmente dispensáveis. Um corte melhor exige saber de antemão qual setor a empresa suporta perder e qual a paralisa. Essa informação não está na despesa de cada setor: um setor caro pode ser supérfluo, e um setor barato pode ser crítico. Ela só aparece quando se pergunta o que acontece com a empresa na ausência de cada setor.

É exatamente essa a definição de **sensibilidade** adotada neste trabalho: a sensibilidade de uma camada é o quanto o desempenho do modelo se degrada quando aquela camada, e somente ela, é podada. Trata-se de uma medida empírica e direta de importância, obtida por ablação, e não de um *proxy*. A distinção em relação à magnitude é central: a magnitude é uma propriedade dos pesos, disponível sem custo algum, mas apenas correlacionada com a importância; a sensibilidade é uma propriedade medida do comportamento do modelo, cara de obter, porém direta.

Figura 6 – Duas formas de atingir a mesma taxa de poda, de 30 %, nas camadas de uma rede. À esquerda, a alocação uniforme, que ignora qualquer medida de importância; à direita, a alocação com análise de sensibilidade, que poupa as camadas mais sensíveis e compensa nas mais tolerantes à poda. Ambas removem a mesma fração total de parâmetros: a linha tracejada indica a taxa de poda do modelo, que é a média das taxas por camada nos dois casos. Figura esquemática.



A ideia de medir importância por degradação não é nova. Ela remonta ao *Optimal Brain Damage* de LeCun, Denker e Solla (1990), que estima, por aproximação de segunda ordem, o aumento de erro provocado pela remoção de cada peso, e ordena os parâmetros por essa estimativa em vez de por magnitude. A limitação do método é o custo: a aproximação exige informação de curvatura, cujo cálculo é proibitivo em redes com centenas de milhões de parâmetros. A alternativa adotada aqui troca a estimativa analítica por medição direta e reduz drasticamente a granularidade — em vez de estimar a importância de cada peso individualmente, mede-se a de cada camada. Com doze camadas, o perfil completo custa doze avaliações do modelo, sem nenhum treinamento envolvido.

Há evidência consolidada de que essa desigualdade entre partes da rede existe e

é substancial. Denil et al. (2013) mostram que uma fração pequena dos parâmetros de uma rede é suficiente para predizer todos os demais, o que indica redundância distribuída de forma desigual. Em *Transformers* especificamente, Michel, Levy e Neubig (2019) verificam que a maioria das cabeças de atenção pode ser removida após o treinamento com perda pequena de desempenho, enquanto algumas poucas são indispensáveis — e que quais delas são indispensáveis não é previsível a partir de propriedades dos pesos. Se a importância fosse aproximadamente uniforme, a distribuição da poda entre as camadas seria irrelevante e a poda uniforme seria ótima por construção; é precisamente porque não é uniforme que existe espaço para alocar melhor.

Duas ressalvas conceituais acompanham o método e delimitam o que ele pode oferecer.

A primeira é que a sensibilidade medida por ablação de uma camada por vez não captura interações entre camadas. A degradação causada por podar duas camadas simultaneamente não é, em geral, a soma das degradações individuais, de modo que o perfil deve ser tratado como uma **ordenação relativa de tolerância à poda**, e não como um modelo capaz de prever a qualidade de uma configuração completa. A segunda é que a sensibilidade não é uma propriedade absoluta da camada: ela é medida em relação a uma estratégia de poda específica, porque remover pesos de menor magnitude e remover cabeças de atenção inteiras são operações diferentes, que danificam a camada de maneiras diferentes. O perfil precisa, portanto, ser levantado uma vez para cada estratégia.

O procedimento que converte esse perfil em taxas de poda por camada é detalhado na Seção 5.3, e ambas as ressalvas acima são verificadas experimentalmente no Capítulo 6.

2.6.4 Pipeline Geral da Poda

De forma geral, a poda pode ser dividida nos seguintes passos (BLALOCK et al., 2020):

- **Passo 1 – Definição de critério e taxa de poda:** partindo de um modelo já treinado, define-se o critério de importância dos parâmetros (magnitude absoluta, norma L_1 de filtros, sensibilidade, entre outros) e a taxa de esparsidade desejada.
- **Passo 2 – Identificação dos parâmetros a podar:** com base no critério escolhido, o algoritmo classifica os parâmetros por importância e seleciona os menos relevantes.
- **Passo 3 – Execução da poda:** os parâmetros selecionados são zerados (no caso da poda não estruturada) ou fisicamente removidos (no caso da poda estruturada), gerando um modelo esparso ou uma nova arquitetura reduzida.

- **Passo 4 – Ajuste fino (*fine-tuning*):** como a remoção tende a deteriorar a acurácia, o modelo podado é retreinado com uma taxa de aprendizado reduzida, para que os parâmetros remanescentes compensem a ausência dos que foram removidos.
- **Passo 5 – Iteração:** a poda pode ser aplicada de forma iterativa, em pequenas etapas intercaladas por *fine-tuning*, o que costuma preservar melhor a acurácia do que uma poda agressiva em um único passo.

2.6.5 Quando a Poda é Aplicada

Tradicionalmente, a poda é aplicada após o treinamento inicial do modelo, seguida de um ajuste fino. Métodos mais recentes aplicam a poda de forma gradual durante o próprio treinamento, intercalando passos de treino e poda, o que permite à rede adaptar-se progressivamente à nova estrutura (ZHU; GUPTA, 2017).

Uma linha de pesquisa mais recente investiga a possibilidade de podar a rede antes do treinamento, identificando sub-redes inerentemente promissoras dentro de uma rede densa inicializada aleatoriamente. Essa abordagem é impulsionada pela chamada *Lottery Ticket Hypothesis* (FRANKLE; CARBIN, 2019), segundo a qual, dentro de uma rede grande inicializada aleatoriamente, existe uma sub-rede pequena (o "bilhete premiado") que, quando treinada isoladamente com a mesma inicialização, atinge acurácia comparável à da rede completa.

3 Trabalhos Relacionados

Este capítulo apresenta trabalhos da literatura diretamente relacionados ao tema desta pesquisa, com foco em estratégias de poda neural e, em especial, naquelas que visam a redução do consumo energético de modelos de *Deep Learning*. Para cada trabalho, são descritos os objetivos principais, a metodologia adotada e os principais resultados obtidos.

3.1 Learning both Weights and Connections for Efficient Neural Networks

Han et al. (2015) propõem reduzir o número de parâmetros de redes neurais profundas sem perda de acurácia, a fim de diminuir a memória e a energia exigidas na inferência. A motivação é energética: segundo os dados apresentados pelos autores, ler um peso de 32 bits da memória externa (DRAM) custa 640 pJ, cerca de três ordens de grandeza a mais do que uma operação aritmética simples, e uma rede que não cabe na memória interna do processador paga esse custo a cada inferência.

O método tem três passos. Primeiro, a rede é treinada normalmente, não para obter os pesos finais, mas para identificar quais conexões são importantes. Em seguida, removem-se as conexões cujos pesos têm valor absoluto abaixo de um limiar, proporcional ao desvio-padrão dos pesos de cada camada, o que torna a rede esparsa. Por fim, a rede é retreinada para que as conexões remanescentes compensem as removidas; poda e retreinamento podem ser repetidos iterativamente. O retreinamento mostrou-se decisivo: sem ele, a acurácia começa a cair quando resta cerca de um terço das conexões; com ele, apenas quando resta um décimo. Os autores medem ainda a sensibilidade de cada camada, podando uma de cada vez e observando a queda de acurácia. As camadas convolucionais revelaram-se mais sensíveis que as totalmente conectadas, e a primeira camada convolucional, que recebe a imagem diretamente, a mais sensível de todas. Esse resultado orientou a escolha do limiar de cada camada: na AlexNet, a primeira camada convolucional reteve 84% dos pesos, e as duas primeiras totalmente conectadas, 9%.

Na base ImageNet, o método reduziu os parâmetros da AlexNet em 9×, de 61 milhões para 6,7 milhões, e os da VGG-16 em 13×, de 138 milhões para 10,3 milhões, sem perda de acurácia. O consumo de energia, embora motive o trabalho, não é medido: os resultados são expressos em parâmetros e operações, e os autores direcionam o método a *hardware* especializado em redes esparsas, dada a limitação do *hardware* de propósito geral na computação esparsa.

Este trabalho adota o critério de Han et al. (2015) como primeira estratégia de

poda (Seção 5.2.2), com três diferenças. A poda é aplicada a um *Transformer*, e não a redes convolucionais. A energia é medida, o que permitiu verificar que, em *hardware* de propósito geral, a poda por magnitude não reduz o consumo de forma detectável (Seção 6.2), como antecipavam os próprios autores. E a análise de sensibilidade por camada, que em Han et al. (2015) orienta os limiares sem que uma regra seja descrita, torna-se aqui uma regra explícita de definição das taxas por camada, comparada às alocações sem análise de sensibilidade sob a mesma taxa de poda (Seção 4.3). Também no GPT-2 a camada mais sensível é a primeira (Seção 6.3.2).

3.2 Pruning Filters for Efficient ConvNets

Li et al. (2017) partem de uma limitação da poda por magnitude: ela remove sobretudo parâmetros das camadas totalmente conectadas, que concentram os parâmetros, mas pouco do custo computacional — na VGG-16, essas camadas reúnem 90% dos parâmetros e menos de 1% das operações de ponto flutuante (FLOPs) —, e a esparsidade irregular que produz nas camadas convolucionais só reduz o tempo de inferência com bibliotecas de convolução esparsa. O objetivo dos autores é reduzir o custo de inferência de redes convolucionais com uma poda que dispense essas bibliotecas.

O método é uma poda estruturada: em vez de pesos isolados, remove filtros convolucionais inteiros, junto com os mapas de características que eles produzem e com os núcleos correspondentes da camada seguinte. A importância de cada filtro é a norma L_1 dos seus pesos, e removem-se os de menor norma — critério que, nos experimentos dos autores, preservou mais acurácia do que remover filtros aleatórios na maior parte das camadas. Como a rede resultante permanece densa, apenas menor, ela é executada pelas bibliotecas usuais de multiplicação de matrizes densas. A sensibilidade de cada camada é medida podando-a isoladamente e avaliando a acurácia no conjunto de validação; nas camadas sensíveis, poda-se uma fração menor de filtros, ou nenhum. Para evitar um hiperparâmetro por camada, as camadas de um mesmo estágio da rede recebem a mesma taxa, e todas são podadas de uma só vez, seguidas de um único retreinamento.

Na base CIFAR-10, o método reduziu os FLOPs da VGG-16 em 34,2% e seus parâmetros em 64%, e os FLOPs da ResNet-110 em 38,6%, com erro de teste próximo ao da rede original após o retreinamento: 6,60% contra 6,75% na VGG-16 e 6,70% contra 6,47% na ResNet-110. A redução de FLOPs converteu-se em redução semelhante do tempo de inferência, de 40,7% na VGG-16. Os experimentos mostraram ainda que camadas sensíveis são difíceis de recuperar pelo retreinamento e que excluí-las da poda melhora o resultado. O consumo de energia não é medido.

Este trabalho adapta o método de Li et al. (2017) ao *Transformer* como segunda estratégia de poda: as unidades estruturais passam a ser as cabeças de atenção e os

neurônios do MLP, ordenados pela norma L_1 (Seção 5.2.3). Como em Li et al. (2017), a sensibilidade de cada camada é medida podando-a isoladamente; o perfil obtido, porém, define as taxas por camada por meio de uma regra explícita, que preserva a taxa de poda do modelo e substitui a escolha empírica por estágio. Além disso, o custo é medido também em energia, e a poda é avaliada tanto sem retreinamento quanto após o *fine-tuning* de recuperação.

3.3 Designing Energy-Efficient Convolutional Neural Networks using Energy-Aware Pruning

Yang, Chen e Sze (2017) propõem um algoritmo de poda para redes neurais convolucionais (CNNs) cujo foco é minimizar o consumo real de energia, e não apenas o número de parâmetros ou de operações, preservando a acurácia. Os autores consideram especialmente o custo computacional associado a operações de multiplicação e acumulação (MAC) e o custo de acesso à memória em dispositivos periféricos, como *smartphones*.

O método proposto aplica poda camada por camada, priorizando aquelas cujo consumo energético estimado é maior. Para isso, os autores desenvolvem um *framework* de estimativa que ordena as camadas pela combinação de custo computacional (número de MACs) e custo de acesso à memória. Em cada camada podada, parte dos pesos é removida; em seguida, alguns pesos são restaurados para minimizar o erro no mapa de características de saída; por fim, os pesos remanescentes são ajustados localmente por meio de uma solução de mínimos quadrados. Após o processamento de todas as camadas, a rede passa por um *fine-tuning* global utilizando *backpropagation*.

Os autores reportam redução de 3,7× no consumo de energia da AlexNet e 1,6× no da GoogLeNet, com perda de acurácia inferior a 1%. O trabalho também demonstra empiricamente que as camadas convolucionais são as que mais consomem energia, principalmente devido ao volume de acessos à memória, e que a simples redução do número de classes tem impacto limitado na redução do consumo energético, uma vez que as camadas convolucionais não são significativamente afetadas.

A fazer: adicionar resenhas de outros trabalhos fundamentais para esta pesquisa. Sugestões: Frankle e Carbin (2019) (Lottery Ticket Hypothesis); Blalock et al. (2020) (revisão crítica de métodos de poda); Liu et al. (2019) (*Rethinking the Value of Network Pruning*). Para cada um, seguir o mesmo padrão de resenha: objetivo, método, resultados principais.

4 Metodologia

Este capítulo apresenta a metodologia adotada neste trabalho. A Seção 4.1 descreve os procedimentos utilizados para selecionar o modelo de referência, as bases de dados e as métricas empregadas na avaliação dos modelos. A Seção 4.2 apresenta as estratégias clássicas de poda aplicadas ao modelo de referência. A Seção 4.3 descreve a estratégia de poda otimizada proposta neste trabalho, baseada na definição de taxas de poda variáveis para as diferentes camadas do modelo. Por fim, a Seção 4.4 apresenta a estratégia de retreinamento dos modelos podados, com o objetivo de avaliar em que medida a degradação de desempenho decorrente da poda pode ser revertida.

Este capítulo se limita à descrição metodológica das estratégias adotadas, apresentando os procedimentos gerais e os critérios que orientam as decisões. As escolhas específicas de implementação, incluindo o modelo de referência, as bases de dados, as configurações de poda e os parâmetros de retreinamento, são detalhadas no Capítulo 5, que segue a mesma estrutura deste capítulo. Essa divisão tem como finalidade distinguir as decisões metodológicas, que definem os procedimentos e critérios da investigação, das decisões de implementação, que especificam como esses procedimentos são concretizados.

4.1 Modelo Base, Base de Dados e Métricas

Esta seção apresenta os procedimentos adotados para a seleção do modelo de referência, das bases de dados e das métricas utilizadas na avaliação dos modelos testados. O modelo de referência fornece os valores iniciais das métricas e constitui o ponto de partida para a geração dos modelos podados. As bases de dados são utilizadas para avaliar o desempenho dos modelos, enquanto as métricas permitem quantificar e comparar os resultados obtidos de acordo com os objetivos do trabalho.

4.1.1 Seleção do Modelo

Nesta primeira etapa, seleciona-se o modelo de referência (*baseline*), que é a versão original de um modelo de linguagem de grande escala (*Large Language Model* — LLM), antes de qualquer processo de poda. O modelo é executado e avaliado sobre uma base de dados, registrando-se métricas de desempenho preditivo, de custo computacional e de consumo de energia. Os valores obtidos constituem o referencial de comparação de todo o trabalho.

Para a seleção do modelo base, foram adotados os seguintes critérios:

- **C1 — Arquitetura:** ser um *Transformer* exclusivamente decodificador, treinado de forma autorregressiva para predizer o próximo *token*. Esse critério delimita a classe arquitetural de interesse, representada por modelos generativos de pesos abertos, como OPT e Llama 2 (ZHANG et al., 2022; TOUVRON et al., 2023). Além disso, essa arquitetura deve ser compatível com a métrica *perplexity*.

- **C2 — Disponibilidade de pesos pré-treinados:** disponibilização de pesos pré-treinados para *download* direto, sob licença que permita o uso acadêmico. Esse critério dispensa o pré-treinamento dos modelos, atividade fora do escopo deste trabalho devido aos custos computacionais e energéticos envolvidos. A dimensão desses custos é ilustrada pelo pré-treinamento da família GPT-2, que utilizou o WebText, uma base composta por mais de 8 milhões de documentos e aproximadamente 40 GB de texto (RADFORD et al., 2019), e apresentou elevado custo computacional e energético (STRUBELL; GANESH; MCCALLUM, 2019).

- **C3 — Viabilidade do *fine-tuning*:** a memória exigida pelo *fine-tuning* completo do modelo deve caber na GPU disponível. Como estimativa, o treinamento com o otimizador Adam em precisão mista exige, no mínimo, 16 bytes por parâmetro apenas para pesos, gradientes e estados do otimizador (RAJBHANDARI et al., 2020); as ativações somam-se a esse valor, de modo que a estimativa constitui um limite inferior de memória necessária. No ambiente adotado — GPU NVIDIA Tesla T4, com 16 GB de memória (NVIDIA Corporation, 2019), disponibilizada pela plataforma Kaggle —, o critério restringe os candidatos a modelos de até cerca de 1 bilhão de parâmetros (16 GB $\div$ 16 bytes por parâmetro); como a estimativa não inclui as ativações, o limite prático é inferior.

- **C4 — Modelo original:** não ser derivado de um processo prévio de compressão (destilação, poda ou quantização), de modo que a degradação medida ao longo deste trabalho seja atribuível exclusivamente à poda aqui aplicada.

- **C5 — Resultado de referência:** ter *perplexity* na base de dados de avaliação adotada publicada em artigo científico — pelos autores do modelo ou em trabalho posterior, o que permite situar o modelo base reproduzido em relação à literatura.

- **C6 — Implementação disponível:** possuir arquitetura implementada nativamente na biblioteca `transformers` (WOLF et al., 2020), que opera sobre a biblioteca PyTorch, dispensando a implementação própria da arquitetura.

Os critérios C1 a C4 e C6 dizem respeito apenas ao modelo. O critério C5, ao contrário, depende também da base de dados de avaliação, cuja seleção segue critérios próprios (Seção 4.1.2), dois dos quais, D1 e D4, dependem, por sua vez, do modelo. Por essa razão, modelo e base de dados são selecionados em conjunto: um par formado por

modelo e base de dados é admissível quando o modelo atende a C1–C6 e a base de dados atende a D1–D4 em relação a esse modelo.

Havendo mais de um candidato que atenda simultaneamente a todos os critérios, adota-se o de menor número de parâmetros: as varreduras experimentais deste trabalho (Seção 4.2.2) exigem um grande número de avaliações completas do modelo, e o custo computacional de cada avaliação cresce com o tamanho do modelo. A aplicação desses critérios a um conjunto de modelos candidatos é apresentada no Capítulo 5 (Tabela 3).

4.1.2 Seleção da Base de Dados

O modelo base e todos os modelos podados nas etapas seguintes são avaliados sobre uma mesma base de dados — a coleção de textos sobre a qual se mede o desempenho dos modelos —, selecionada pelos seguintes critérios:

- **D1 — Resultado de referência:** *perplexity* publicada em artigo científico para o modelo base avaliado na base de dados; é a exigência do critério C5 vista do lado da base de dados.
- **D2 — Texto sem pré-processamento destrutivo:** a base de dados preserva caixa, pontuação, números e palavras raras, e mantém a continuidade dos documentos; modelos com tokenização por subpalavras são pré-treinados sobre texto bruto e seriam avaliados fora de sua distribuição em texto normalizado.
- **D3 — Divisão oficial:** partições oficiais de treino, validação e teste, de modo que o *fine-tuning* use o treino e a avaliação use o teste, sem particionamento arbitrário.
- **D4 — Ausência de sobreposição com o pré-treinamento:** a base de dados não integra nem reproduz os dados de pré-treinamento do modelo; do contrário, a *perplexity* mediria em parte memorização.

Os critérios D2 e D3 dizem respeito apenas à base de dados; D1 e D4 dependem do modelo, e por isso modelo e base de dados são selecionados em conjunto (Seção 4.1.1). Havendo mais de uma base de dados que atenda a todos os critérios, adota-se a de menor conjunto de treino, pois é ele que determina o custo do *fine-tuning*. A aplicação desses critérios a um conjunto de bases de dados candidatas é apresentada no Capítulo 5 (Tabela 4).

4.1.3 Métricas de Avaliação

As métricas de avaliação são organizadas em três dimensões: desempenho preditivo, custo computacional e impacto ambiental. Elas são registradas pelo mesmo procedimento, e sobre a mesma base de dados, para o modelo base e para cada modelo podado

nas Etapas 2 a 4. Para cada métrica, descreve-se o que ela representa e como é obtida operacionalmente.

Desempenho preditivo

Como o modelo base é um modelo de linguagem autorregressivo, a métrica de desempenho preditivo adotada é a *perplexity*, padrão para essa classe de modelos. Ela quantifica o grau de "surpresa" do modelo diante de cada *token* do conjunto de avaliação, constituindo uma medida da qualidade da modelagem probabilística da linguagem (GOODFELLOW; BENGIO; COURVILLE, 2016). Valores mais baixos de *perplexity* indicam melhor capacidade preditiva.

A adoção da *perplexity*, em lugar de métricas de tarefas descendentes — como a acurácia em uma tarefa de classificação —, decorre de ela ser uma métrica intrínseca: pode ser medida diretamente sobre a base de dados de avaliação, sem exigir o *fine-tuning* do modelo em uma tarefa específica, procedimento que tornaria a comparação entre configurações dependente de um segundo treinamento. O procedimento de cálculo adotado é descrito no Capítulo 5.

Custo computacional

O custo computacional é avaliado por meio de quatro indicadores complementares:

- **Número de parâmetros remanescentes:** contagem direta dos tensores de pesos não-zerados (no caso de poda não estruturada) ou existentes (no caso de poda estruturada) no modelo após a aplicação da técnica;
- **Operações de ponto flutuante (FLOPs):** contagem das operações matemáticas necessárias para uma inferência completa, obtida por análise estática do grafo computacional do modelo: ferramentas de contagem percorrem cada camada do modelo e acumulam as operações correspondentes. A automação, porém, é parcial: a contagem cobre apenas os tipos de camada previstos no catálogo da ferramenta, de modo que camadas fora dele exigem o registro de regras de contagem próprias, sob pena de serem silenciosamente ignoradas. O tratamento efetivamente necessário no modelo adotado, bem como as omissões remanescentes, são detalhados no Capítulo 5;
- **Tempo de inferência:** medido empiricamente, registrando o tempo decorrido durante o processamento de uma entrada representativa em condições controladas de *hardware*. Múltiplas medições são agregadas por meio de média e desvio-padrão para mitigar a variância natural de execução;

- **Tamanho do modelo:** memória ocupada pelos parâmetros, calculada como o produto entre o número de parâmetros e o número de *bytes* usado para representar cada um.

Impacto ambiental

O impacto ambiental é mensurado por meio de dois indicadores:

- **Consumo energético:** estimado por meio de ferramentas de monitoramento do uso de *hardware* (CPU e GPU), que integram leituras periódicas do consumo elétrico dos componentes e registram a energia total consumida (em kWh) durante o intervalo de inferência;
- **Emissões equivalentes de CO_2:** calculadas a partir do consumo energético registrado, multiplicado por um fator de intensidade carbônica da matriz energética da região onde os experimentos são executados. As mesmas ferramentas de monitoramento mantêm bases desses fatores e realizam essa conversão automaticamente. Cabe uma ressalva sobre o alcance desse indicador: como o fator de intensidade carbônica depende da localidade em que o código executa, ele não é controlado pelo experimento e pode variar entre execuções. As emissões devem, por isso, ser lidas como aproximações de ordem de grandeza, e a comparação entre configurações apoia-se no consumo energético, não nas emissões dele derivadas.

Comparação entre configurações

As configurações são comparadas taxa a taxa: em cada taxa de poda, a *perplexity* e a energia de cada alocação são confrontadas com as do modelo base e com as das demais alocações. Três indicadores sintetizam essa comparação, em linha com a recomendação de tratar a eficiência como critério de avaliação ao lado do desempenho preditivo (SCHWARTZ et al., 2020) e de relatar sistematicamente a energia consumida (HENDERSON et al., 2020). Definir o critério de forma explícita responde, ainda, à falta de padronização das métricas, que dificulta a comparação entre métodos de poda (BLALOCK et al., 2020).

Redução relativa de energia (ΔE): fração da energia do modelo base economizada pelo modelo podado,

$$\Delta E = \frac{E_0 - E}{E_0} \times 100 \ [\%], \tag{4.1}$$

em que E é a energia consumida pelo modelo podado e E_0, a do modelo base medida na mesma sessão de execução. A referência na mesma sessão é necessária porque a energia medida de um mesmo modelo varia entre sessões do ambiente de execução; por isso, a energia é sempre comparada em termos relativos, e nunca em valores absolutos.

Eficiência relativa (η): relaciona o desempenho preditivo à energia consumida. Como valores menores de *perplexity* indicam melhor desempenho, a razão de qualidade é tomada em relação ao modelo base, de modo invertido:

$$\eta = \frac{\mathrm{PPL}_0}{\mathrm{PPL}} \times \frac{E_0}{E}, \tag{4.2}$$

em que PPL e PPL_0 são as *perplexities* do modelo podado e do modelo base. O modelo base tem $\eta = 1$; valores acima de 1 indicam mais desempenho preditivo por unidade de energia do que ele. Como usa apenas razões, o indicador respeita a restrição de comparar a energia em termos relativos. Quando a diferença de energia está abaixo do ruído de medição, porém, η passa a refletir só a *perplexity* e esse ruído.

Ponto de eficiência (S_E^*): maior taxa de poda cuja *perplexity* não excede em mais de 5% a do modelo base:

$$S_E^* = \max\left\{s \mid \mathrm{PPL}(s) \leq 1{,}05 \cdot \mathrm{PPL}_0\right\}, \tag{4.3}$$

em que s é a taxa de poda. A referência é o modelo base no mesmo regime: sem retreinamento, o modelo pré-treinado; após o *fine-tuning*, o modelo base submetido ao mesmo retreinamento. O limite de 5% foi fixado antes da análise dos resultados, e não ajustado a eles.

Resumo por configuração: para comparar estratégias e alocações por um único valor, adota-se a média sobre as taxas de poda consideradas. Para a *perplexity*, a média é geométrica: como a *perplexity* de modelos podados sem retreinamento varia por ordens de grandeza entre taxas, a média aritmética seria determinada quase só pela pior taxa; a média geométrica equivale à média da degradação logarítmica, a mesma escala da análise de sensibilidade. Para ΔE, a média é aritmética, e η é calculado a partir das duas médias. Entram na média as taxas até a maior em que nenhuma camada atinge o teto da alocação com análise de sensibilidade (Seção 4.3): acima dela, a alocação deixa de diferenciar as camadas, e a comparação entre alocações perde o objeto. As taxas acima desse corte são reportadas, mas não entram nas médias. O resumo aplica-se às varreduras sem retreinamento, que cobrem todas as taxas; as configurações submetidas ao *fine-tuning*, avaliadas em poucas taxas, são comparadas taxa a taxa.

4.2 Etapa 2 — Poda sem Otimização

Na segunda etapa, aplicam-se ao modelo base estratégias clássicas de poda, sem nenhuma técnica de otimização. Cada estratégia, em cada taxa de poda avaliada, é aplicada de forma independente e sempre a partir do modelo base original, nunca de um modelo já podado, de modo que o resultado de uma configuração não dependa das anteriores. Os modelos podados são avaliados pelas mesmas métricas e sobre a mesma

base de dados da Etapa 1 (Seção 4.1). As métricas de cada modelo podado, nesta e nas etapas seguintes, são comparadas às do modelo base, o que permite mensurar a perda de desempenho e o ganho de eficiência introduzidos pela compressão.

As estratégias de poda sem otimização têm por objetivo reduzir o número de parâmetros de um modelo pré-treinado, eliminando pesos ou estruturas avaliadas como menos relevantes para o desempenho preditivo. A relevância é estimada por um critério de importância, que atribui uma pontuação a cada parâmetro ou a cada unidade arquitetural removível; os elementos de menor pontuação são removidos até que se atinja a taxa de poda pretendida.

A **taxa de poda** é a fração dos elementos podáveis do modelo — pesos ou estruturas, conforme a estratégia — que é removida, como 30% ou 50%. O critério de importância pode ser aplicado de duas formas, que decidem quanto sai de cada camada. Na **alocação uniforme**, cada camada perde a mesma fração, e o critério decide, dentro de cada uma, quais elementos saem. Na **alocação não uniforme**, uma única ordenação de todos os elementos do modelo decide o que sai, de modo que as camadas cujos elementos têm pontuação mais baixa perdem mais. Como ambas se baseiam apenas em pontuações calculadas a partir dos pesos, nenhuma mede o efeito da remoção sobre o desempenho do modelo; essa questão é tratada na Etapa 3 (Seção 4.3). A implementação das duas alocações é apresentada no Capítulo 5 (Seção 5.2.4).

4.2.1 Parâmetros Podáveis e Não Podáveis

A taxa de poda não é absoluta: ela é relativa aos **parâmetros podáveis**, o conjunto de parâmetros que as estratégias de poda podem remover, e não ao total de parâmetros do modelo. Os demais, denominados **não podáveis**, permanecem intactos em todas as configurações, qualquer que seja a estratégia ou a taxa de poda.

Em modelos baseados na arquitetura *Transformer*, adotam-se como podáveis, por convenção consolidada na literatura de poda de LLMs (FRANTAR; ALISTARH, 2023; SUN et al., 2024), apenas as matrizes de peso das projeções lineares internas às camadas: as da atenção multi-cabeça, que produzem a consulta, a chave e o valor e projetam a saída das cabeças (Seção 2.3.3), e as das duas transformações lineares do MLP (Seção 2.3.4). É sobre essas matrizes que incidem as multiplicações de matriz das camadas, responsáveis pela maior parte do custo de inferência — no GPT-2 *small*, por exemplo, 87,0 dos 126,6 GFLOPs do modelo (Seção 5.1.3.2). Nelas estão também os elementos podáveis da definição de taxa de poda: os pesos individuais são valores dessas matrizes, e as estruturas, como as cabeças de atenção e os neurônios do MLP, são fatias delas.

Ficam fora do conjunto podável os demais parâmetros, cada grupo por uma razão

própria:

- as matrizes de *embedding* de *token* e de posição (Seção 2.3.5). Seu uso não envolve multiplicação de matrizes: a cada *token*, o modelo apenas copia as linhas correspondentes ao *token* e à sua posição. Anular valores dessas matrizes reduziria o armazenamento, mas não o custo computacional, cuja redução é o objetivo deste trabalho. Elas tampouco contêm cabeças de atenção ou neurônios do MLP: remover uma linha eliminaria um *token* do vocabulário ou uma posição da sequência, e remover uma coluna alteraria a dimensão das representações, que é a dimensão de entrada e de saída de todas as camadas;

- a cabeça de linguagem, matriz que converte a representação entregue pela última camada em uma pontuação para cada *token* do vocabulário. Diferentemente dos *embeddings*, ela efetua multiplicação de matrizes, mas também não contém as unidades da poda estruturada: cada uma de suas linhas corresponde a um *token*. Além disso, em modelos que reutilizam na cabeça a matriz de *embedding* de *token*, como o GPT-2, um peso anulado na cabeça seria anulado também no *embedding*, e a poda alteraria simultaneamente a entrada e a saída do modelo, o que impediria atribuir seu efeito a uma única camada, premissa da análise de sensibilidade por camada (Seção 4.3);

- os vieses e os parâmetros de normalização de camada. São uma fração ínfima do modelo — menos de 0,1% no GPT-2 *small* — e efetuam apenas somas e produtos elemento a elemento, de custo desprezível diante das multiplicações de matriz: mesmo eliminados por inteiro, não reduziriam o custo de forma mensurável. O risco, em contrapartida, é alto: um parâmetro de normalização multiplica uma dimensão inteira da representação que entra na atenção ou no MLP, enquanto um peso de matriz é apenas uma entre centenas ou milhares de parcelas de uma soma. Kovaleva et al. (2021) mostraram que anular os parâmetros de normalização associados a uma única dimensão — menos de 0,0001% dos pesos do modelo — degrada significativamente o desempenho de modelos *Transformer* pré-treinados, efeito também identificado no GPT-2. Os vieses não são removidos isoladamente; na poda estruturada, o viés de uma estrutura removida sai junto com ela.

Como os parâmetros não podáveis permanecem no modelo, a fração do total de parâmetros removida é sempre menor que a taxa de poda. No GPT-2 *small*, por exemplo, os *embeddings* reúnem 31,6% dos 124,4 milhões de parâmetros, e o conjunto podável, cerca de 85 milhões, 68,3% do total. Uma taxa de poda de 50% remove, assim, cerca de 42,5 milhões de parâmetros, metade do conjunto podável, e não 62,2 milhões, metade do modelo: a redução no total de parâmetros é de 34%, e não de 50%. Por essa

razão, a fração removida do conjunto podável e o número de parâmetros remanescentes no modelo inteiro (Seção 4.1.3) são reportados separadamente.

O conjunto podável é o mesmo para todas as estratégias de poda, o que mantém comparáveis as suas taxas: uma taxa de 50%, em qualquer estratégia, incide sobre as mesmas matrizes. A identificação dos parâmetros podáveis no modelo selecionado é apresentada no Capítulo 5 (Seção 5.2.2 e Figura 8).

4.2.2 Taxas de Poda Avaliadas

Cada estratégia de poda é avaliada, com cada alocação, em dez taxas de poda igualmente espaçadas: 0%, 10%, 20% e assim por diante, até 90%. O conjunto das dez avaliações de uma mesma estratégia com uma mesma alocação é denominado, ao longo do texto, **varredura**: as dez avaliações de uma estratégia com a alocação uniforme, por exemplo, formam a varredura uniforme dessa estratégia. As alocações com análise de sensibilidade da Etapa 3 (Seção 4.3) são avaliadas nas mesmas taxas, o que permite comparar todas as alocações de uma estratégia taxa a taxa, como prevê a Seção 4.1.3.

Avalia-se toda a faixa, de 10% a 90%, porque não se sabe de antemão a partir de qual taxa de poda cada estratégia passa a degradar o modelo de forma acentuada, e não há razão para supor que essa taxa seja a mesma em estratégias de granularidades diferentes (Seção 2.6), que removem elementos de tamanhos muito diferentes. A poda de granularidade fina remove pesos individuais; a de granularidade grossa remove estruturas inteiras, cada uma formada por muitos pesos — no GPT-2 *small*, por exemplo, um neurônio do MLP reúne 1.536 pesos, e uma cabeça de atenção, 196.608 (Seção 5.2.3). Avaliar apenas parte da faixa, como somente as taxas baixas, poderia deixar de fora justamente a taxa em que a degradação de uma delas se acentua.

A taxa de 0% corresponde ao modelo base, sem nenhuma poda, e é incluída em cada varredura com duas funções. A primeira é de verificação: avaliado pelo mesmo procedimento das demais taxas, o modelo base deve reproduzir a *perplexity* medida na Etapa 1 (Seção 4.1), e uma divergência indicaria erro no procedimento de poda ou de avaliação, e não efeito da poda. A segunda é de referência: a energia medida a 0% é a energia E_0 do modelo base na mesma sessão de execução das demais taxas da varredura, contra a qual se calcula a redução relativa de energia (Equação 4.1).

Por fim, como estabelecido no início desta seção, cada taxa parte do modelo base original, e não do modelo podado na taxa anterior: a configuração de 30%, por exemplo, é obtida removendo 30% dos elementos podáveis do modelo base, e não acrescentando 20 pontos percentuais à poda da configuração de 10%. A aplicação dessas taxas às estratégias selecionadas é apresentada no Capítulo 5 (Seção 5.2.5).

4.2.3 Seleção das Estratégias

As estratégias desta etapa não constituem a contribuição deste trabalho: desempenham o papel de linha de base. São aplicadas com os critérios de importância propostos por seus autores, e os modelos que produzem servem de referência para avaliar a estratégia com otimização (Seção 4.3), que constitui a contribuição central do trabalho.

A escolha das estratégias, entre as alternativas disponíveis na literatura, seguiu três critérios:

- **P1 — Importância calculada apenas a partir dos pesos:** o critério de importância não utiliza dados de calibração nem gradientes. Neste trabalho, a informação dependente de dados entra na decisão de poda exclusivamente pela análise de sensibilidade por camada (Seção 4.3), cuja contribuição se pretende medir; um critério-base que já utilizasse dados misturaria as duas fontes de informação e impediria atribuir à alocação por sensibilidade a diferença observada.
- **P2 — Aplicação *one-shot*:** a poda é aplicada ao modelo pré-treinado sem treinamento durante o processo, de modo que o efeito da remoção seja medido separadamente do efeito do *fine-tuning* de recuperação (Seção 4.4).
- **P3 — Cobertura das granularidades:** o conjunto de estratégias inclui uma de granularidade fina, que remove parâmetros individuais, e uma de granularidade grossa, que remove unidades arquiteturais inteiras.

O critério P3 decorre de as duas granularidades oferecerem vantagens opostas (Seção 2.6, Figura 4). A poda de granularidade fina alcança, em geral, taxas de compressão elevadas com perda reduzida de desempenho preditivo (BLALOCK et al., 2020); os pesos removidos, porém, são apenas anulados: as matrizes conservam suas dimensões, o *hardware* convencional continua a executar as multiplicações por zero, e a redução do número de parâmetros não se converte em redução de tempo nem de energia. A poda de granularidade grossa produz matrizes menores e densas, o que reduz de fato o custo de inferência em *hardware* convencional (LI et al., 2017), ao preço de uma perda potencialmente maior de desempenho preditivo para uma mesma taxa de compressão (BLALOCK et al., 2020). Uma estratégia preserva melhor o desempenho preditivo; a outra converte a compressão em economia efetiva de tempo e de energia. Avaliá-las sob as mesmas condições permite medir esse compromisso, que nenhuma das duas revelaria isoladamente e que constitui uma das perguntas do trabalho (Capítulo 5).

A aplicação desses critérios a um conjunto de estratégias candidatas, as estratégias selecionadas e os detalhes de sua implementação são apresentados no Capítulo 5 (Tabela 6).

4.3 Etapa 3 — Poda com Otimização

Esta é a etapa central do trabalho. Toda poda a uma dada taxa precisa decidir quanto remover de cada camada do modelo. Esta etapa investiga se medir o que cada camada suporta perder, em vez de supô-lo, melhora essa decisão.

4.3.1 O Problema: Quanto Podar em Cada Camada

A fração removida dentro de uma camada é a **taxa de poda por camada**. A taxa de poda do modelo, definida na Etapa 2, é a média das taxas por camada; quando as camadas têm tamanhos diferentes, a média é ponderada pelo tamanho de cada uma. O conjunto de taxas por camada adotado para atingir uma taxa de poda é a **alocação**.

Uma mesma taxa de poda admite muitas alocações. Em um modelo de quatro camadas de mesmo tamanho, podar 30% de cada camada e podar 20%, 50%, 10% e 40% das camadas 1 a 4 são duas alocações para a mesma taxa de poda de 30%: ambas removem o mesmo número de elementos e diferem apenas nas camadas de onde eles saem. Como as camadas não necessariamente reagem da mesma forma à remoção, as alocações podem produzir modelos de qualidades diferentes. Chama-se **sensível** a camada cuja poda degrada muito o desempenho preditivo do modelo, e **tolerante** à poda, a que o degrada pouco.

As duas alocações da Etapa 2 (Seção 4.2) têm uma limitação comum: nenhuma mede o quanto cada camada é sensível. A uniforme ignora a questão e trata as camadas como intercambiáveis. A não uniforme a infere dos pesos, o que é uma aproximação, e não uma medida. A Seção 2.6.3 (Figura 6) ilustra a diferença entre a alocação uniforme e uma alocação que segue a sensibilidade.

4.3.2 Hipótese, Desenho e Critérios de Escolha da Técnica

A hipótese é a de que podar mais as camadas tolerantes e menos as sensíveis produz, na mesma taxa de poda, menor perda de desempenho preditivo do que as alocações uniforme e não uniforme. Para testá-la, fixa-se a taxa de poda e varia-se apenas a alocação, e os modelos obtidos são comparados segundo as métricas e o critério da Seção 4.1.3. Como a taxa de poda é a mesma, a técnica não busca reduzir o custo, e sim a perda de desempenho preditivo que acompanha essa redução.

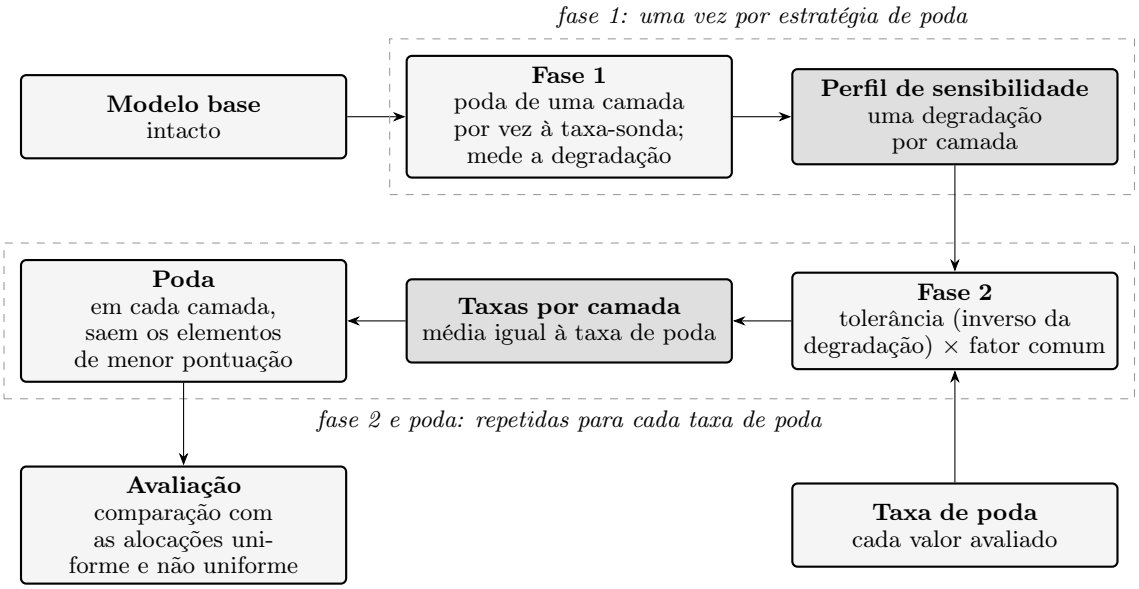
Mantidos o modelo, o critério de importância, a taxa de poda e a ausência de treinamento, qualquer diferença de desempenho entre os dois pode ser atribuída à forma como a poda se distribui entre as camadas.

4.3.3 Técnica Adotada: Análise de Sensibilidade por Camada

A técnica de otimização adotada neste trabalho é a **análise de sensibilidade por camada**. A ideia é medir a sensibilidade de cada camada e podar mais as tolerantes e menos as sensíveis. A medição resulta no **perfil de sensibilidade**: uma degradação por camada.

A técnica tem duas fases (Figura 7). A fase 1 mede o perfil e roda uma única vez por estratégia de poda. A fase 2 converte o perfil em uma alocação e é refeita para cada taxa de poda avaliada, sem nova medição.

Figura 7 – Fluxo da análise de sensibilidade por camada. A fase 1 é executada uma vez por estratégia de poda; a fase 2 e a poda são repetidas para cada taxa de poda, a partir do mesmo perfil.



Fonte: Elaboração própria.

O procedimento, para uma estratégia de poda e uma taxa de poda dadas, tem cinco passos.

1. **Medir o perfil (fase 1).** Para cada camada, parte-se do modelo base e remove-se, só daquela camada, uma fração dos elementos denominada **taxa-sonda**. Mede-se a *perplexity* (Seção 4.1.3) e compara-se com a do modelo base; a **degradação** da camada é a medida desse aumento. Antes de passar à camada seguinte, o modelo é restaurado. A taxa-sonda é a mesma para todas as camadas, para que as degradações sejam comparáveis. Ela serve apenas à medição e não gera modelo final. O perfil é medido uma só vez por estratégia e reaproveitado em todas as taxas de poda.

2. **Converter degradação em tolerância.** A **tolerância à poda** de uma camada, ou simplesmente tolerância, é o inverso de sua degradação: quanto menos a camada

degrada o modelo, mais tolerante ela é. As tolerâncias fixam apenas a proporção entre as taxas por camada, e não o seu valor.

3. **Escalar à taxa de poda.** Todas as tolerâncias são multiplicadas por um mesmo fator, escolhido para que a média das taxas resultantes seja a taxa de poda pretendida. As taxas resultantes formam a **alocação com análise de sensibilidade**. Um teto impede que uma camada seja removida por inteiro: quando uma camada o atinge, o excedente passa às demais. A regra admite ainda um parâmetro que controla a intensidade com que as diferenças do perfil são seguidas.

4. **Podar.** Em cada camada, o critério de importância da estratégia remove os elementos de menor pontuação, até atingir a taxa daquela camada. A sensibilidade decide *quanto* podar em cada camada; a estratégia decide *quais* elementos saem.

5. **Avaliar e comparar.** O modelo podado é avaliado pelas métricas da Seção 4.1.3 e comparado aos modelos das alocações uniforme e não uniforme, na mesma taxa de poda.

Os passos 2 a 5 repetem-se para cada taxa de poda avaliada; só o passo 1 não se repete.

Exemplo

A Tabela 1 percorre os passos 1 a 3 em um modelo hipotético de quatro camadas de mesmo tamanho, podado à taxa de poda de 30%.

Tabela 1 – Exemplo dos passos 1 a 3 da análise de sensibilidade em um modelo hipotético de quatro camadas de mesmo tamanho, à taxa de poda de 30%. Valores ilustrativos, não medidos; a tolerância é o inverso da degradação, e cada taxa da alocação com análise de sensibilidade é a tolerância multiplicada por 0,10. A medida de degradação adotada é definida na Seção 5.3.1.

	Camada 1	**Camada 2**	**Camada 3**	**Camada 4**	**Média**
Degradação (passo 1)	0,50	0,20	1,00	0,25	—
Tolerância (passo 2)	2	5	1	4	3
Taxa de poda por camada, por alocação (passo 3)					
Uniforme	30%	30%	30%	30%	30%
Com análise de sensibilidade	20%	50%	10%	40%	30%

No passo 1, cada camada é podada sozinha à taxa-sonda, e a *perplexity* do modelo resultante é comparada à do modelo intacto. Supõe-se que a camada 3 produza a maior degradação e a camada 2, a menor, com os valores da primeira linha da tabela: a camada 3 é a mais sensível, e a camada 2, a mais tolerante. No passo 2, a degradação é invertida: a camada 2, que degradou o modelo cinco vezes menos que a camada 3, é cinco vezes mais

tolerante. As tolerâncias 2, 5, 1 e 4 indicam que a camada 2 deve perder cinco vezes mais elementos que a camada 3.

No passo 3, todas as tolerâncias são multiplicadas pelo mesmo fator. Como a média das tolerâncias é 3, o fator que leva a média das taxas a 30% é 0,10, e as taxas por camada resultam em 20%, 50%, 10% e 40% — a mesma alocação usada como exemplo no início da seção. Se a taxa de poda fosse de 15%, o fator seria 0,05, e as taxas, 10%, 25%, 5% e 20%. No passo 4, cada camada perde essa fração dos elementos de menor pontuação segundo o critério da estratégia. O perfil de sensibilidade decide, portanto, como a poda se distribui entre as camadas; a taxa de poda decide quanto se remove no total.

As duas alocações da Tabela 1 têm a mesma média e, por isso, removem o mesmo número de elementos; diferem apenas nas camadas de onde eles saem. A alocação não uniforme da Etapa 2 também atribui taxas diferentes às camadas, mas elas resultam da pontuação dos pesos, e não de uma medida de degradação.

Como cada estratégia de poda remove unidades de natureza distinta — pesos individuais ou estruturas inteiras —, o perfil é levantado separadamente para cada uma delas.

O Capítulo 5 (Seção 5.3) apresenta o que aqui ficou genérico, a forma exata da medida de degradação, o valor da taxa-sonda, o valor do teto, o parâmetro de intensidade e o cálculo do fator, e a aplicação ao modelo escolhido.

4.4 Etapa 4 — *Fine-tuning* de Recuperação

As Etapas 2 e 3 operam em regime *one-shot*: o modelo é podado e avaliado imediatamente, sem nenhum treinamento após a poda. Esse regime é deliberado, pois mede o dano causado pela poda sem que nenhuma recuperação posterior o atenue. Ele difere, porém, do procedimento original das estratégias clássicas de poda, que retreinam o modelo depois de podá-lo, para que os parâmetros remanescentes compensem a ausência dos removidos (HAN et al., 2015; LI et al., 2017) (Seção 2.6). Esta etapa incorpora esse retreinamento ao experimento, com o objetivo de medir quanto da degradação causada pela poda pode ser recuperada.

O *fine-tuning* de recuperação consiste em continuar o treinamento do modelo já podado. Os parâmetros remanescentes são ajustados sobre a partição de treino da base de dados de avaliação, com o mesmo objetivo do pré-treinamento — a predição do próximo *token* —, por um número fixo de passos de otimização, igual para todas as configurações retreinadas. Ao final, o modelo é avaliado novamente na partição de teste, pelas mesmas métricas da Seção 4.1.3. A recuperação é medida pela comparação entre a *perplexity* do modelo podado antes e depois do retreinamento.

5 Desenvolvimento

Este capítulo descreve as decisões concretas que decorrem dos critérios estabelecidos no Capítulo 4 e o experimento tal como foi efetivamente implementado. Após a apresentação das perguntas que orientam o trabalho, o capítulo segue as mesmas quatro etapas da metodologia, na mesma ordem: modelo base (Seção 5.1); poda sem otimização (Seção 5.2); poda com otimização (Seção 5.3); e *fine-tuning* de recuperação (Seção 5.4). As seções finais tratam de aspectos comuns a todas as etapas: o *framework* e as bibliotecas empregadas, a organização do *pipeline* experimental, o ambiente de execução, a síntese das decisões de implementação e as limitações reconhecidas.

A pergunta que orienta o trabalho é empírica e comparativa. Não se pretende demonstrar que a poda comprime modelos, resultado já consolidado pela literatura (HAN et al., 2015; LI et al., 2017; BLALOCK et al., 2020), mas responder a duas questões mais específicas, sob condições controladas e reprodutíveis:

(A) Em que medida a redução *teórica* de parâmetros se converte em redução *real* de tempo de inferência e de consumo de energia, e como essa conversão depende da granularidade da poda?

(B) Uma alocação da poda entre as camadas definida por uma análise de sensibilidade por camada melhora o compromisso entre compressão e qualidade em relação às alocações sem análise de sensibilidade?

Responder a essas duas perguntas exige que modelos comprimidos por estratégias distintas sejam avaliados exatamente pelo mesmo conjunto de métricas, na mesma base de dados e no mesmo *hardware*. Essa simetria de avaliação é condição necessária para que qualquer comparação seja interpretável, e é o princípio que organiza todo o desenvolvimento descrito adiante.

5.1 Modelo Base

Na primeira etapa, o GPT-2 *small* (RADFORD et al., 2019) foi selecionado como modelo base. Utilizou-se a versão pré-treinada disponibilizada na plataforma Hugging Face, executada sem nenhuma modificação e avaliada no conjunto de teste da base de dados WikiText-2 (MERITY et al., 2017). Registraram-se a *perplexity*, a contagem de parâmetros, o tamanho em memória, os FLOPs, o tempo de inferência e o consumo de energia: as três primeiras métricas foram obtidas com a biblioteca PyTorch; os FLOPs, com a biblioteca `thop`; o tempo de inferência, com o temporizador `perf_counter` da

linguagem Python; e o consumo de energia, com a biblioteca CodeCarbon (Tabela 5). O modelo base obteve *perplexity* de 25,17 (Tabela 2), valor contra o qual são comparadas todas as configurações podadas das etapas seguintes. As subseções a seguir apresentam a seleção do modelo (Seção 5.1.1), a seleção da base de dados (Seção 5.1.2) e as métricas registradas (Seção 5.1.3).

5.1.1 Seleção do Modelo

O modelo base é o GPT-2 *small*, proposto por Radford et al. (2019) e descrito na Seção 2.3.5. Trata-se de um modelo autorregressivo composto exclusivamente pelo componente decodificador da arquitetura *Transformer*. Os pesos pré-treinados foram obtidos pela plataforma Hugging Face, que os disponibiliza publicamente, e carregados por meio da biblioteca PyTorch (PASZKE et al., 2019).

A Tabela 2 resume a configuração da variante utilizada. Ao longo deste trabalho, cada um dos 12 blocos *Transformer* do modelo é denominado **camada**, e as camadas são numeradas de 0 a 11, na ordem em que processam a entrada, conforme a indexação adotada na implementação. É nessa unidade que se definem a análise de sensibilidade por camada e as taxas de poda por camada.

Tabela 2 – Configuração do GPT-2 *small* utilizado como modelo base.

Característica	**Valor**
Blocos *Transformer* empilhados (camadas)	12
Cabeças de atenção por camada	12
Dimensão do modelo (d_{model})	768
Dimensão intermediária do MLP (d_{ff})	3.072
Tamanho do vocabulário	50.257
Janela de contexto máxima	1.024 *tokens*
Total de parâmetros	124.439.808
Tamanho em memória	474,70 MB
FLOPs por janela de 512 *tokens*	126,6 G
Perplexity no WikiText-2 (teste)	25,17

Fonte: Elaboração própria.

A Seção 4.1.1 estabeleceu seis critérios objetivos (C1 a C6) para a seleção do modelo base. A Tabela 3 aplica esses critérios a nove candidatos: as quatro variantes do GPT-2 (RADFORD et al., 2019), o DistilGPT2 (SANH et al., 2019), o OPT-125M (ZHANG et al., 2022), o Pythia-160M (BIDERMAN et al., 2023), o BERT-base (DEVLIN et al., 2019) e o Llama 2 7B (TOUVRON et al., 2023). Os candidatos compreendem as quatro variantes da família GPT-2; três modelos abertos de porte próximo ao do GPT-2 *small*; e dois modelos de classes distintas, incluídos para verificar os limites dos critérios:

um codificador e um modelo com bilhões de parâmetros. Como a seleção é conjunta (Seção 4.1.1), a tabela verifica também o critério D4 de cada candidato em relação ao WikiText-2.

Avaliar a inclusão de modelos pequenos posteriores a 2023 (por exemplo, SmolLM2, Qwen2.5-0.5B, Llama 3.2 1B), que a banca pode questionar.

Tabela 3 – Candidatos ao modelo base e verificação dos critérios de seleção.

Modelo	**Parâm.**	**Mem. FT (GB)**	**Downl. (mi)**	**C1**	**C2**	**C3**	**C4**	**C5**	**C6**	**D4**
GPT-2 *small*	124M	2,0	930,1	✓	✓	✓	✓	✓	✓	✓
GPT-2 *medium*	355M	5,7	29,8	✓	✓	✓	✓	✓	✓	✓
GPT-2 *large*	774M	12,4	61,0	✓	✓	✓	✓	✓	✓	✓
GPT-2 XL	1,56B	24,9	17,0	✓	✓	×	✓	✓	✓	✓
DistilGPT2	82M	1,3	256,8	✓	✓	✓	×	—	✓	—
OPT-125M	125M	2,0	215,8	✓	✓	✓	✓	✓	✓	×
Pythia-160M	162M	2,6	27,2	✓	✓	✓	✓	—	✓	×
BERT-base	110M	1,8	3.246,2	×	✓	✓	✓	×	✓	×
Llama 2 7B	6,74B	107,8	34,6	✓	×	×	✓	✓	✓	—

C1: arquitetura decodificadora autorregressiva; C2: pesos abertos; C3: viabilidade do *fine-tuning*; C4: modelo original; C5: resultado de referência publicado; C6: implementação disponível (critérios definidos na Seção 4.1.1); D4: ausência de sobreposição entre o pré-treinamento e o WikiText-2 (Seção 4.1.2). —: não verificado, candidato já eliminado por outro critério. Mem. FT: memória mínima para o *fine-tuning* completo, a 16 bytes por parâmetro. Downl.: *downloads* acumulados na plataforma Hugging Face, em milhões.

Fonte: Elaboração própria, com dados de Radford et al. (2019), Rajbhandari et al. (2020), Frantar e Alistarh (2023), Sun et al. (2024), Gao et al. (2020) e da plataforma Hugging Face (acesso em 28 set. 2026).

As quatro variantes do GPT-2 atendem a C5 porque Radford et al. (2019) publicam, na Tabela 3 do artigo original, a *perplexity* de cada uma no WikiText-2: 29,41 (*small*), 22,76 (*medium*), 19,93 (*large*) e 18,34 (XL). A relação entre o valor publicado para o *small* e o medido neste trabalho, obtidos por protocolos distintos, é discutida na Seção 6.1.

O GPT-2 *small* acumula, além disso, 930,1 milhões de *downloads* na plataforma Hugging Face, o maior valor entre os candidatos de geração de texto considerados — o BERT-base tem mais *downloads*, mas é um codificador, já excluído por C1. Nos 30 dias anteriores ao acesso, o modelo somou 15,4 milhões de *downloads*, o segundo maior volume entre todos os modelos de geração de texto da plataforma (acesso em 28 set. 2026). Esse dado reforça a representatividade do modelo, sem substituir os critérios de seleção.

Dos nove candidatos, seis não atendem a todos os critérios. O BERT-base cai em C1: sua arquitetura é apenas codificadora, pré-treinada com modelagem de linguagem mascarada (DEVLIN et al., 2019), de modo que a *perplexity* autorregressiva não se aplica — ela não é bem definida para modelos de linguagem mascarada (Hugging Face, 2026b) —, o que o faz cair também em C5; e cai em D4, por ser pré-treinado sobre a Wikipédia em inglês (DEVLIN et al., 2019). O Llama 2 7B cai em C2: o acesso a seus pesos na

plataforma Hugging Face está condicionado a aprovação manual (verificado em 28 set. 2026). Cai também em C3 — seus 6,74 bilhões de parâmetros exigiriam 107,8 GB para o *fine-tuning* completo, muito acima dos 16 GB disponíveis. Atende, porém, a C5: Sun et al. (2024) reportam *perplexity* de 5,12 no WikiText-2 para o modelo denso. O GPT-2 XL cai isoladamente em C3: Rajbhandari et al. (2020) apontam que um modelo de 1,5 bilhão de parâmetros exige, no mínimo, 24 GB de memória para o treinamento em precisão mista com Adam, acima do limite disponível. O DistilGPT2 cai em C4, por ser obtido por destilação de conhecimento supervisionada pelo GPT-2 de 124M (SANH et al., 2019).

O OPT-125M e o Pythia-160M exigem exame mais detido, pois atendem a C1–C4 e C6. O OPT-125M atende também a C5: Frantar e Alistarh (2023) reportam *perplexity* de 27,66 para o modelo denso no WikiText-2, em estudo de poda. Ambos, porém, caem em D4 em relação ao WikiText-2, pois incluem a Wikipédia no pré-treinamento: o OPT foi pré-treinado sobre uma seleção de componentes do The Pile que inclui a Wikipédia (ZHANG et al., 2022), e o Pythia sobre o The Pile completo (BIDERMAN et al., 2023), cujo componente Wikipedia (en) soma 6,38 GiB (GAO et al., 2020). O GPT-2, ao contrário, teve os documentos da Wikipédia removidos de sua base de dados de pré-treinamento (RADFORD et al., 2019) (Seção 5.1.2). Nenhum dos dois modelos forma par admissível com as demais bases de dados candidatas (Tabela 4): o WikiText-103 cai em D4 pelo mesmo motivo; o Penn Treebank e o OpenWebText caem em critérios que independem do modelo (D2 e D3, respectivamente); e The Pile cai em D4, por ser a base de dados de pré-treinamento do Pythia e fornecer parte do pré-treinamento do OPT.

Restam três candidatos que atendem a todos os critérios: as variantes *small*, *medium* e *large* do GPT-2, esta última com margem estreita em C3 — dos 12,4 GB estimados, restam cerca de 3,6 GB para as ativações. Aplicou-se, então, a regra de desempate da Seção 4.1.1: entre os candidatos que atendem a todos os critérios, adota-se o de menor número de parâmetros. O GPT-2 *medium* e o *large* têm, respectivamente, cerca de 2,9 e 6,2 vezes mais parâmetros que o *small*; a diferença é relevante porque a campanha experimental deste trabalho registrou 195 execuções completas de avaliação — 20 da poda por magnitude, 60 da poda estruturada, 48 do perfil de sensibilidade nas duas taxas-sonda, 60 da alocação por sensibilidade e 7 de *fine-tuning* de recuperação.

No ambiente adotado, uma época de *fine-tuning* do GPT-2 *small* sobre o conjunto de treino do WikiText-2 (4.743 blocos de 512 *tokens*, isto é, 2.428.416 *tokens*) levou 274 s, cerca de 4,6 minutos, o que corresponde a aproximadamente 8,9 mil *tokens* por segundo; os sete *fine-tunings* da campanha somaram cerca de 31 minutos. Supondo custo proporcional ao número de parâmetros — aproximação coerente com a contagem de FLOPs da Tabela 2, em que 126,6 GFLOPs por janela de 512 *tokens* correspondem a cerca de 2 operações por parâmetro por *token* —, o mesmo conjunto de *fine-tunings* levaria cerca de 1,5 hora com o *medium* e 3,2 horas com o *large*; trata-se de estimativas, não de medições diretas. A

escolha recaiu, portanto, sobre o GPT-2 *small*.

Cabe observar que, embora seja a menor variante da família GPT-2, o modelo é cerca de cinco vezes maior que a ResNet-50, arquitetura tradicionalmente usada em estudos de poda em visão computacional. Essa diferença de escala é justamente o que torna o trabalho pertinente: as conclusões da literatura de poda foram estabelecidas majoritariamente em redes convolucionais, e não é evidente que se transfiram para modelos com esse perfil de parâmetros.

5.1.2 Seleção da Base de Dados

O WikiText-2 é uma base de dados de língua inglesa extraída de artigos verificados da Wikipédia, proposta por Merity et al. (2017), com *perplexity* do GPT-2 nessa base de dados reportada por Radford et al. (2019). Diferentemente de bases de dados construídas a partir de frases isoladas, o WikiText preserva a estrutura original dos artigos — parágrafos completos, pontuação e capitalização mantidas —, o que o torna adequado para medir a capacidade de um modelo de acompanhar contexto ao longo de textos extensos.

Empregou-se especificamente a variante `wikitext-2-raw-v1`, na qual o texto não sofre substituição de palavras raras por um marcador genérico. Essa escolha é necessária porque o GPT-2 utiliza tokenização por *subwords*, capaz de representar palavras fora do vocabulário decompondo-as em fragmentos; a variante processada anularia essa capacidade e distorceria a perplexity medida.

A Seção 4.1.2 estabeleceu quatro critérios objetivos (D1 a D4) para a seleção da base de dados de avaliação. A Tabela 4 aplica esses critérios a cinco candidatos: o WikiText-2 e o WikiText-103 (MERITY et al., 2017), o Penn Treebank (MERITY et al., 2017), o OpenWebText (GOKASLAN; COHEN, 2019) e The Pile (GAO et al., 2020). Como D1 e D4 dependem do modelo, a tabela os verifica para a família GPT-2, adotada na Seção 5.1.1; a verificação recíproca, para os demais candidatos a modelo, consta na Tabela 3.

Tabela 4 – Candidatas a base de dados de avaliação e verificação dos critérios de seleção.

Base de dados	**Treino**	**D1**	**D2**	**D3**	**D4**
WikiText-2	2,1 mi *tokens*	✓	✓	✓	✓
WikiText-103	103,2 mi *tokens*	✓	✓	✓	✓
Penn Treebank	0,93 mi *tokens*	✓	×	✓	✓
OpenWebText	39,8 GB	—	✓	×	×
The Pile	825 GiB	✓	✓	✓	×

D1: resultado de referência; D2: texto sem pré-processamento destrutivo; D3: divisão oficial; D4: ausência de sobreposição com o pré-treinamento (critérios definidos na Seção 4.1.2). D1 e D4 verificados para a família GPT-2. —: não verificado, candidato já eliminado por outro critério.

Fonte: Elaboração própria, com dados de Merity et al. (2017), Radford et al. (2019), Gao et al. (2020) e da plataforma Hugging Face (acesso em 28 set. 2026).

Dos cinco candidatos, três não atendem a todos os critérios. O Penn Treebank cai em D2: na versão usual, as palavras estão em caixa baixa, a pontuação foi removida e o vocabulário foi limitado a 10 mil palavras (MERITY et al., 2017), ao passo que o WikiText mantém pontuação, caixa original e números (MERITY et al., 2017), e a variante *raw* adotada neste trabalho não substitui palavras raras. O OpenWebText cai em D3, pois é distribuído com uma única partição, de treino, sem divisão oficial em validação e teste (8.013.769 documentos, 39,8 GB, verificado na plataforma Hugging Face); e em D4, por ser uma reprodução aberta do WebText, a base de dados de pré-treinamento do GPT-2 (GOKASLAN; COHEN, 2019). The Pile atende a D1 — Gao et al. (2020) avaliam as quatro variantes do GPT-2 em seu conjunto de teste, com a *perplexity* convertida em bits por *byte* — e a D3, por dispor de partições oficiais de treino, validação e teste — validação e teste com cerca de 0,1% dos dados cada, mais de 1 GiB cada (GAO et al., 2020); cai em D4 porque inclui o OpenWebText2 (62,77 GiB), construído pelo mesmo método do WebText, com votos no Reddit como filtro de qualidade dos links (GAO et al., 2020). Em sentido oposto, os autores do GPT-2 removeram do WebText todos os documentos da Wikipédia justamente para evitar sobreposição com conjuntos de avaliação (RADFORD et al., 2019); a sobreposição de 8-gramas medida por eles entre os conjuntos de teste e o treino do WebText é de 1,63% no WikiText-2, 2,42% no WikiText-103 e 0,88% no Penn Treebank (Tabela 6 de Radford et al. (2019)).

Restam dois candidatos que atendem a todos os critérios: o WikiText-2 e o WikiText-103. Ambos compartilham os mesmos conjuntos de validação e teste, com 217.646 e 245.569 *tokens*, respectivamente (MERITY et al., 2017); diferem apenas no conjunto de treino, cerca de 49 vezes maior no WikiText-103. Como o conjunto de teste é o mesmo, a avaliação de *perplexity* é idêntica nos dois; a diferença está inteiramente no custo do *fine-tuning*, determinado pelo treino. Com a vazão medida na Seção 5.1.1 — uma época sobre o treino do WikiText-2 em cerca de 4,6 minutos —, uma época sobre o WikiText-103 levaria cerca de 3,8 horas por *fine-tuning*, e os sete *fine-tunings* da campanha passariam de cerca de 31 minutos para cerca de 25 horas (estimativa proporcional ao número de *tokens* de treino). Aplicou-se, então, a regra de desempate da Seção 4.1.2: adotou-se o de menor conjunto de treino, o WikiText-2.

Registre-se que a base de dados é parametrizável na implementação: a substituição pelo WikiText-103, de mesma natureza e cerca de cinquenta vezes maior, exige apenas a alteração de um argumento de linha de comando. Essa flexibilidade foi mantida deliberadamente para que trabalhos futuros possam verificar a generalidade dos resultados sem reescrever o código.

5.1.2.1 Pré-processamento e Tokenização

O pré-processamento foi intencionalmente mínimo, para que a perplexity medida refletisse a base de dados e não decisões de limpeza. As linhas do conjunto foram unidas por quebra dupla, preservando a separação entre parágrafos tal como na base de dados original, e o texto resultante foi tokenizado como um fluxo contínuo único.

A tokenização empregou o tokenizador original do GPT-2, baseado no algoritmo BPE (*Byte Pair Encoding*), com vocabulário de 50.257 *tokens*. Manter o tokenizador original é indispensável: os *embeddings* do modelo foram aprendidos para esse vocabulário específico, e qualquer substituição invalidaria os pesos pré-treinados.

5.1.2.2 Divisão dos Dados

Adotou-se a divisão oficial da base de dados. O **conjunto de teste** foi utilizado em todas as medições de perplexity reportadas, tanto do modelo base quanto de todas as configurações comprimidas. O **conjunto de treinamento** foi utilizado exclusivamente na etapa de *fine-tuning* de recuperação (Seção 5.4). O **conjunto de validação** foi empregado apenas para acompanhar a evolução do treinamento ao longo dos passos, quando essa curva foi solicitada, e nunca para selecionar resultados reportados.

Essa separação estrita importa: como as varreduras *one-shot* não realizaram treinamento algum, elas não tiveram contato com o conjunto de treinamento, e a perplexity de teste é uma medida limpa do dano causado pela poda.

5.1.3 Métricas de Avaliação

Toda configuração — o modelo base, as podadas pelos métodos da literatura e as podadas pela estratégia otimizada — foi avaliada pelo mesmo conjunto de métricas, cobrindo as três dimensões definidas na Seção 4.1.3. A Tabela 5 as resume.

5.1.3.1 Perplexity

A perplexity é a métrica de desempenho preditivo adotada. Ela foi calculada pelo método da janela deslizante, padrão para modelos autorregressivos: o fluxo de *tokens* do conjunto de teste foi percorrido em janelas do tamanho máximo de contexto do modelo, com passo menor que a janela, de modo que cada *token* fosse previsto dispondo de contexto anterior substancial. Apenas os *tokens* ainda não avaliados contribuíram para a perda em cada janela; os demais entraram como contexto.

Empregou-se janela de 1.024 *tokens* com passo de 512. Passos menores produzem estimativas mais precisas ao custo de mais computação; o valor adotado é o compromisso usual na literatura (Hugging Face, 2026b), e foi mantido idêntico em todas as configurações avaliadas.

Tabela 5 – Métricas de avaliação coletadas para cada configuração.

Métrica	**O que mede**	**Unidade**	**Ferramenta**
Perplexity	Qualidade da modelagem da linguagem; quanto menor, melhor	—	PyTorch
Parâmetros totais	Parâmetros existentes na arquitetura	unidades	PyTorch
Parâmetros não nulos	Parâmetros efetivamente diferentes de zero	unidades	PyTorch
Esparsidade real	Fração de parâmetros podáveis eliminados	%	PyTorch
Tamanho do modelo	Memória ocupada pelos parâmetros	MB	PyTorch
FLOPs	Operações de ponto flutuante por inferência	FLOPs	`thop`
Tempo de inferência	Tempo médio de uma passagem direta	ms	`perf_counter`
Energia consumida	Energia gasta durante a avaliação	kWh	`CodeCarbon`
Emissões de CO_2	Emissões equivalentes ao consumo	kg	`CodeCarbon`

Fonte: Elaboração própria.

5.1.3.2 Custo Computacional

A contagem de **parâmetros** é reportada em duas formas complementares. O total reflete o que existe na arquitetura; a contagem de não nulos reflete o que sobrou depois da poda. Na poda não estruturada as duas divergem — há zeros, mas a arquitetura é a mesma. Na poda estruturada, as duas contagens do modelo podado coincidem, e ambas ficam abaixo das do modelo base: as estruturas removidas deixam de existir, em vez de permanecerem como zeros. Essa divergência é, por si só, um resultado: ela evidencia a diferença entre compressão contábil e compressão física.

A **esparsidade real** reportada nas tabelas foi sempre calculada sobre o conjunto podável, mas a natureza do cálculo acompanha a estratégia: na poda por magnitude é a fração de pesos anulados nas 48 matrizes; na poda estruturada é a fração de parâmetros que deixaram de existir nas mesmas projeções, vieses incluídos, já que a remoção de uma estrutura elimina também o viés que lhe corresponde. As duas grandezas medem a mesma coisa — quanto do conjunto podável foi eliminado.

Os **FLOPs** foram contabilizados por uma ferramenta que percorre os módulos do modelo — as unidades que o compõem na implementação, como as projeções lineares — e soma o custo de cada um, segundo uma regra associada ao tipo do módulo. Em um módulo linear, o custo é de duas operações, uma multiplicação e uma soma, por peso da matriz, para cada *token* processado. No GPT-2, as projeções das camadas efetuam essa mesma operação, mas são implementadas por um tipo de módulo que a ferramenta não reconhece e ao qual atribui custo nulo. Sem tratamento, a contagem ignoraria as matrizes que a poda modifica, responsáveis por 87,0 dos 126,6 GFLOPs do modelo base,

e permaneceria constante sob qualquer poda. Por isso, aplicou-se a essas projeções a mesma regra de contagem dos módulos lineares.

As multiplicações de matriz internas ao mecanismo de atenção não são executadas por um módulo próprio, e sim diretamente no cálculo da atenção, e não foram contabilizadas em nenhuma configuração. Elas representam cerca de 7% do custo do modelo base. Na poda por magnitude, essa parcela é constante; na poda estruturada, ela diminui com a remoção de cabeças de atenção, de modo que a redução de FLOPs reportada é ligeiramente inferior à real.

A implementação prevê ainda um estimador analítico de reserva — duas operações por parâmetro não pertencente aos *embeddings*, por *token* processado —, acionado apenas se a contagem por módulos falhar. Todos os valores reportados no Capítulo 6 provêm da contagem por módulos, o que se verifica pelo fato de os FLOPs variarem com a poda estruturada; o estimador de reserva produziria uma grandeza de natureza diferente e não deve ser misturado a eles.

O **tempo de inferência** foi medido sobre uma entrada representativa de 512 *tokens*, com execuções de aquecimento descartadas — para mitigar efeitos de inicialização da GPU — seguidas de execuções cronometradas, das quais se reporta média e desvio-padrão.

5.1.3.3 Impacto Ambiental

O consumo de **energia** foi medido com o `CodeCarbon`, que monitora o *hardware* durante a execução do bloco de avaliação e reporta a energia consumida em quilowatts-hora. As **emissões de CO_2** foram estimadas a partir desse consumo e da intensidade de carbono da rede elétrica onde o código executa.

Sobre esta última métrica cabe uma ressalva importante, identificada durante os experimentos: a intensidade de carbono utilizada variou conforme a sessão de execução. Em consequência, as emissões não são comparáveis entre execuções realizadas em sessões distintas, e a análise dos resultados apoia-se no consumo de energia, não nas emissões derivadas dele.

5.2 Poda sem Otimização

Após a seleção do modelo base, da base de dados e das métricas de avaliação (Seção 5.1), seguiu-se a escolha das estratégias de poda que poderiam ser aplicadas a esse modelo.

5.2.1 Seleção das Estratégias

Na seleção das estratégias, aplicaram-se os critérios definidos na Metodologia (Seção 4.2). Para colocá-los em prática, realizou-se uma pré-seleção de seis estratégias candidatas na revisão de Cheng, Zhang e Shi (2024), que organiza em uma taxonomia as estratégias de poda de redes neurais profundas: as duas estratégias clássicas, a poda por magnitude e a poda estruturada por norma L_1, e quatro alternativas propostas para modelos *Transformer*, o SparseGPT (FRANTAR; ALISTARH, 2023), o Wanda (SUN et al., 2024), a *movement pruning* (SANH; WOLF; RUSH, 2020) e a poda de cabeças por gradiente (MICHEL; LEVY; NEUBIG, 2019). A Tabela 6 apresenta a verificação dos critérios para as seis candidatas.

Tabela 6 – Estratégias de poda candidatas e verificação dos critérios de seleção.

Estratégia	**Granularidade**	**Critério de importância**	**Ano**	**Citações**	**P1**	**P2**
Magnitude	fina	$\|w\|$ de cada peso	2015	8.047	✓	✓
Norma L_1	grossa	norma L_1 dos pesos da unidade	2017	4.214	✓	✓
SparseGPT	fina	reconstrução com dados de calibração	2023	1.552	×	✓
Wanda	fina	$\|w\|$ × norma das ativações	2024	999	×	✓
Movement pruning	fina	movimento dos pesos no *fine-tuning*	2020	654	×	×
Cabeças por gradiente	grossa	gradiente da perda em relação à máscara	2019	1.513	×	✓

P1: importância calculada apenas a partir dos pesos; P2: aplicação *one-shot* (critérios definidos na Seção 4.2). P3 refere-se ao conjunto de estratégias e é discutido no texto. Ano: ano de publicação do artigo que propôs a estratégia. Citações: citações desse artigo na base Semantic Scholar, indicador complementar de representatividade, que não integra os critérios.

Fonte: Elaboração própria, com base em Han et al. (2015), Li et al. (2017), Frantar e Alistarh (2023), Sun et al. (2024), Sanh, Wolf e Rush (2020) e Michel, Levy e Neubig (2019), e com dados da base Semantic Scholar (acesso em 3 out. 2026).

As quatro alternativas caem em P1, pois todas estimam a importância com base em dados. O SparseGPT e o Wanda, referências recentes da poda não estruturada de LLMs, utilizam 128 sequências de calibração extraídas da base de dados C4: o primeiro para reconstruir, com informação de segunda ordem, os pesos remanescentes de cada camada (FRANTAR; ALISTARH, 2023); o segundo para ponderar a magnitude de cada peso pela norma da ativação de entrada correspondente (SUN et al., 2024). A importância das cabeças em Michel, Levy e Neubig (2019) é estimada pelo gradiente da perda sobre uma base de dados. A *movement pruning* cai também em P2, pois a importância de cada peso é aprendida ao longo do *fine-tuning* (SANH; WOLF; RUSH, 2020). A exclusão dessas estratégias não decorre de desempenho inferior: elas já incorporam o tipo de informação que a análise de sensibilidade introduz, e sua combinação com a alocação por sensibilidade fica fora do escopo deste trabalho.

Portanto, conclui-se que, entre as seis candidatas, apenas a poda por magnitude e a poda estruturada por norma L_1 atendem aos critérios estabelecidos: cada uma atende a P1 e a P2, e as duas, juntas, atendem a P3, pois a primeira opera sobre pesos individuais e a segunda, sobre unidades arquiteturais inteiras.

Quanto ao indicador complementar de representatividade, os artigos que propuseram as duas estratégias adotadas são os mais citados entre as seis candidatas: 8.047 citações para Han et al. (2015) e 4.214 para Li et al. (2017), contra 1.552 do SparseGPT, o terceiro (Semantic Scholar, acesso em 3 out. 2026). Como as citações se acumulam com o tempo, a diferença reflete em parte a antiguidade dos trabalhos — as quatro alternativas foram publicadas entre 2019 e 2024. O dado reforça a condição de referência das duas estratégias na literatura de poda, sem substituir os critérios de seleção. A mesma condição é corroborada pela meta-análise de Blalock et al. (2020), que reuniu os resultados de 81 trabalhos de poda e aponta como um dos resultados consistentes da área que a poda pela magnitude dos pesos comprime substancialmente as redes sem reduzir a acurácia.

A seguir, cada uma das estratégias selecionadas é detalhada em uma subseção própria; depois delas, são tratados os aspectos comuns às duas: a distribuição da poda entre as camadas e as taxas de poda avaliadas.

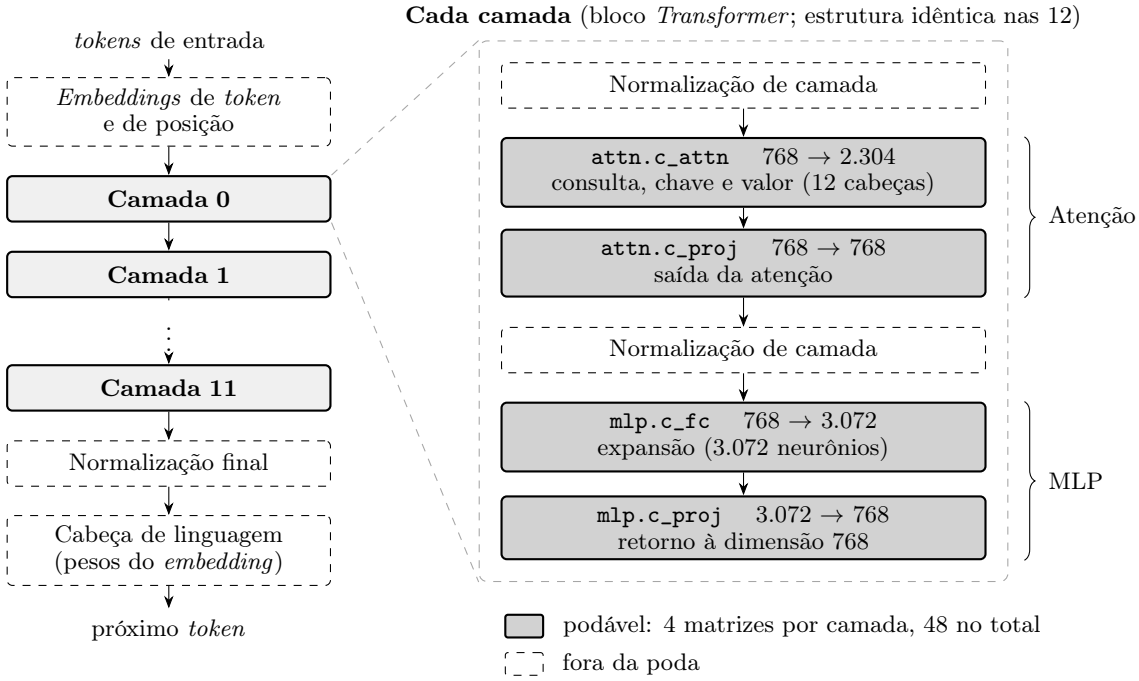
5.2.2 Poda por Magnitude

O primeiro método, de poda não estruturada, segue Han et al. (2015). O critério de importância é o valor absoluto do peso: assume-se que pesos próximos de zero contribuem pouco para a saída e podem ser anulados. Dada uma taxa de poda, calculou-se o limiar correspondente ao quantil apropriado da distribuição de $|w|$ e zeraram-se todos os pesos abaixo dele.

Essa taxa, como toda taxa de poda deste trabalho, é relativa aos parâmetros podáveis, e não ao total de parâmetros do modelo (Seção 4.2.1): o limiar é calculado e aplicado apenas sobre eles. No GPT-2 *small*, os parâmetros podáveis são as matrizes de peso das quatro projeções lineares de cada camada, duas na atenção — `attn.c_attn`, que produz consulta, chave e valor, e `attn.c_proj`, que projeta a saída das cabeças — e duas no MLP, `mlp.c_fc` e `mlp.c_proj`. Nas 12 camadas, são 48 matrizes e 84.934.656 pesos, 68,3% dos 124.439.808 parâmetros do modelo (Figura 8). Ficam fora da poda, pelas razões expostas na Metodologia, as matrizes de *embedding* de *token* (`wte`) e de posição (`wpe`); a cabeça de linguagem (`lm_head`), que no GPT-2 é o mesmo tensor de `wte` e cujo custo, 39,5 dos 126,6 GFLOPs do modelo base, permanece constante em todas as configurações; e os vieses e parâmetros de normalização de camada.

A implementação preserva a característica essencial do método: os pesos são **zerados**, não removidos. As matrizes conservam suas dimensões originais e a arquitetura permanece intacta — o que, como discutido na Seção 2.6, é precisamente a razão pela qual esse método não reduz o custo de inferência em *hardware* convencional.

Figura 8 – Localização dos parâmetros podáveis no GPT-2 *small*. O modelo empilha 12 blocos *Transformer* de estrutura idêntica, aqui denominados camadas e numerados de 0 a 11; a estrutura de cada camada está detalhada à direita. Em cada camada, as quatro matrizes de projeção, em destaque, são podáveis, o que totaliza 48 matrizes. As cabeças de atenção e os neurônios do MLP não são matrizes à parte, e sim fatias que atravessam duas projeções. Cada uma das 12 cabeças de uma camada ocupa 192 colunas de `attn.c_attn` (64 para consulta, 64 para chave e 64 para valor) e as 64 linhas de `attn.c_proj` que recebem sua saída. Cada um dos 3.072 neurônios ocupa uma coluna de `mlp.c_fc`, que o produz, e uma linha de `mlp.c_proj`, que o consome. A poda estruturada remove a fatia inteira, nas duas matrizes. No modelo inteiro, são 144 cabeças e 36.864 neurônios. Os componentes tracejados ficam fora da poda.



5.2.3 Poda por Norma L_1

O segundo método, de poda estruturada, adapta Li et al. (2017) ao *Transformer*. O trabalho original poda filtros convolucionais ordenados por norma L_1; aqui, as unidades estruturais equivalentes são as **cabeças de atenção** e os **neurônios do MLP**, os 3.072 de sua dimensão intermediária. Para cada uma dessas estruturas calculou-se a norma L_1 dos pesos que lhe correspondem, e removeram-se as de menor norma. Também aqui a poda se restringe aos parâmetros podáveis (Seção 4.2.1): cada cabeça e cada neurônio é uma fatia de duas das matrizes podáveis (Figura 8), e os *embeddings*, a cabeça de linguagem e os parâmetros de normalização permanecem intactos em todas as taxas de poda.

A diferença decisiva em relação ao método anterior é que a remoção é **física**. As matrizes foram efetivamente reconstruídas com dimensões menores: as colunas de

consulta, chave e valor associadas às cabeças removidas foram eliminadas de `c_attn`, as linhas correspondentes saíram de `c_proj`, e a contabilidade interna do módulo de atenção — número de cabeças e dimensão de divisão — foi atualizada de acordo. O resultado não é um modelo esparso, mas uma arquitetura menor e densa.

A implementação admite três alvos: apenas cabeças, apenas neurônios do MLP, ou ambos simultaneamente. Os resultados do Capítulo 6 empregam os dois alvos simultâneos, com a mesma taxa aplicada a cada tipo de estrutura; os alvos isolados aparecem apenas na comparação entre cabeças e neurônios da Seção 6.4.2. Uma salvaguarda impede que qualquer camada fique sem nenhuma cabeça ou sem nenhum neurônio: sem ela, a poda deixaria de remover estruturas e passaria a remover subcamadas inteiras — a atenção ou o MLP de uma camada —, granularidade mais grossa que a adotada e fora do escopo deste trabalho.

Convém registrar que a taxa de poda, neste método, é expressa como fração de **estruturas** removidas, não de parâmetros. Duas razões fazem a fração de parâmetros efetivamente eliminada divergir da taxa solicitada, e por isso ela é reportada separadamente em todas as tabelas. A primeira é que cabeças e neurônios têm custos diferentes em parâmetros, já que cada estrutura é removida com todos os pesos que lhe pertencem, e uma cabeça de atenção reúne muito mais pesos que um neurônio do MLP (Figura 8). Cada cabeça ocupa 192 colunas de `attn.c_attn` e 64 linhas de `attn.c_proj`, todas com 768 pesos, o que soma 196.608 pesos; cada neurônio ocupa apenas uma coluna de `mlp.c_fc` e uma linha de `mlp.c_proj`, também com 768 pesos cada, o que soma 1.536. Remover uma única cabeça elimina, portanto, equivale a remover 128 neurônios. Como a taxa conta estruturas, e não pesos, a fração de parâmetros eliminada depende de quais estruturas são removidas: as 12 cabeças de uma camada concentram um terço de seus pesos podáveis (2.359.296 de 7.077.888), e os 3.072 neurônios, os outros dois terços. Uma taxa de 50% aplicada apenas às cabeças elimina, assim, cerca de 16,7% dos parâmetros podáveis, um terço da taxa; aplicada apenas aos neurônios, cerca de 33,3%, dois terços dela. Quando os dois alvos recebem a mesma taxa, como nos resultados do Capítulo 6, as duas parcelas somam a própria taxa, e a divergência passa a vir da segunda razão, descrita a seguir, cujo efeito a diferença de tamanho amplia: cada cabeça que o arredondamento deixa de remover conserva tantos pesos quanto 128 neurônios.

A segunda razão é a granularidade discreta das estruturas: o número de unidades a remover é a parte inteira do produto entre a taxa e a contagem disponível, o que nos neurônios do MLP — 3.072 por camada — é praticamente imperceptível, mas nas cabeças de atenção, que são apenas 12 por camada, produz arredondamentos visíveis. Uma taxa de 90%, por exemplo, remove 10 das 12 cabeças, ou seja, 83%.

5.2.4 Distribuição de Poda entre as Camadas

Ambos os métodos foram avaliados sob dois escopos, que correspondem às alocações uniforme e não uniforme definidas na Seção 4.2 e representam formas distintas de distribuir a poda entre as camadas:

- **Uniforme:** cada camada recebe exatamente a mesma fração de poda, decidida isoladamente dentro dela. É a alocação mais simples possível, pois ignora qualquer diferença de importância entre camadas.
- **Não uniforme:** o critério de importância é aplicado ao modelo inteiro de uma só vez. Um único limiar — ou uma única ordenação de estruturas — decide o que sai, de modo que camadas com pesos sistematicamente menores cedem proporcionalmente mais. Na poda estruturada com os dois alvos simultâneos, o escopo não uniforme compreende duas ordenações independentes, uma de cabeças e outra de neurônios, cada uma abrangendo as doze camadas: as normas L_1 de uma cabeça de atenção e de um neurônio do MLP não são grandezas comparáveis, pois agregam números distintos de pesos, e ordená-las em conjunto faria a escolha depender do tamanho da estrutura em vez de sua importância relativa. A norma L_1 de uma estrutura é a soma dos valores absolutos de seus pesos, e uma cabeça soma 196.608 pesos, 128 vezes os 1.536 de um neurônio (Seção 5.2.3). Ainda que os pesos das duas estruturas tivessem o mesmo valor típico, a norma de uma cabeça seria cerca de 128 vezes a de um neurônio, apenas por somar mais parcelas. É o que ocorre no GPT-2: o valor absoluto médio de um peso é praticamente o mesmo nas duas estruturas, cerca de 0,1, e a cabeça de menor norma tem norma 14 vezes maior que a do neurônio de maior norma. Em uma ordenação conjunta, portanto, todos os neurônios viriam antes da primeira cabeça, e nenhuma cabeça seria removida em nenhuma das taxas avaliadas, até 90%: a poda dos dois alvos se reduziria à poda apenas de neurônios. As duas ordenações independentes evitam esse efeito, já que cada estrutura passa a ser comparada somente com estruturas do mesmo tipo e do mesmo tamanho, e garantem que a taxa de poda incida igualmente sobre os dois tipos: a 50%, por exemplo, removem-se metade das cabeças e metade dos neurônios.

O contraste entre esses dois escopos é o que estabelece a linha de base contra a qual a estratégia otimizada é julgada. Adianta-se que nenhum deles domina o outro em toda a faixa de esparsidade, e é essa constatação que motiva a análise de sensibilidade. Na poda por magnitude, o escopo uniforme obteve *perplexity* menor entre 30% e 70%, e o não uniforme, nas demais taxas; na poda estruturada, o não uniforme obteve *perplexity* menor em todas as taxas, exceto 20% (Seções 6.4.1 e 6.4.2).

Nenhum dos dois domina porque nenhum deles mede quanto cada camada tolera ser podada. O escopo uniforme trata todas as camadas como igualmente tolerantes e poda a mesma fração de cada uma, inclusive das mais sensíveis. O escopo não uniforme supõe que um peso, ou uma estrutura, de menor magnitude é menos importante, qualquer que seja a camada em que se encontra, e por isso concentra o corte nas camadas em que esses elementos predominam. Quando essas camadas são também as que melhor toleram a poda, o escopo não uniforme leva vantagem; quando não são, ele concentra a poda justamente em camadas sensíveis, e o uniforme, que não a concentra em nenhuma, sai à frente. Como essa correspondência difere de uma estratégia para outra e de uma taxa de poda para outra, a vantagem muda de lado ao longo da faixa (Seção 6.3.3). A análise de sensibilidade parte dessa constatação para que a alocação deixe de depender de uma suposição: em vez de inferir a tolerância de cada camada a partir da magnitude de seus pesos, ela a mede diretamente, podando cada camada isoladamente e observando a degradação resultante (Seção 5.3.1).

5.2.5 Taxas de Poda Avaliadas

As dez taxas de poda definidas na Metodologia (Seção 4.2.2), de 0% a 90%, foram aplicadas às duas estratégias selecionadas, cada uma com as duas alocações, o que resultou em quatro varreduras: a uniforme e a não uniforme da poda por magnitude e a uniforme e a não uniforme da poda estruturada. Nesta última, a taxa conta cabeças de atenção e neurônios do MLP, e não pesos (Seção 5.2.3), e as mesmas taxas foram aplicadas também aos alvos isolados, apenas cabeças ou apenas neurônios, usados na comparação entre os dois tipos de estrutura. A verificação prevista para a taxa de 0% foi satisfeita em todas as varreduras, inclusive nas da Etapa 3: o modelo base reproduziu, com todos os dígitos registrados, a *perplexity* de 25,17 medida na Etapa 1 (Seção 5.1).

5.3 Poda com Otimização

Na terceira etapa, aplicou-se a técnica descrita na Seção 4.3 — a análise de sensibilidade por camada, cujo procedimento está na Figura 7 — às duas estratégias de poda, nas mesmas taxas de poda da Etapa 2 (Seção 5.2.5). As subseções trazem os valores adotados: a medida da degradação e a taxa-sonda da fase 1, e a regra de alocação da fase 2, com o teto e o parâmetro de intensidade.

5.3.1 Fase 1 — Perfil de Sensibilidade

O perfil foi levantado conforme o passo 1 do procedimento da Seção 4.3: cada camada ℓ foi podada isoladamente, a uma taxa-sonda fixa, e a *perplexity* resultante foi medida. A degradação foi registrada em escala logarítmica:

$$\Delta_\ell = \ln\left(\frac{\mathrm{PPL}_\ell}{\mathrm{PPL}_{\mathrm{base}}}\right), \tag{5.1}$$

onde PPL_ℓ é a perplexity do modelo com apenas a camada ℓ podada. O logaritmo é necessário porque a perplexity de modelos podados sem recuperação varia por ordens de grandeza; em escala linear, uma única camada catastrófica tornaria todas as demais indistinguíveis entre si.

Adotou-se taxa-sonda de 50%. O procedimento não envolveu treinamento e produziu, ao final, um perfil com uma medida de sensibilidade por camada, para cada estratégia. Como as duas estratégias removem coisas diferentes, os perfis foram levantados separadamente e não são intercambiáveis — ponto que a Seção 6.3.3 demonstra experimentalmente.

Os perfis não são intercambiáveis porque, à mesma taxa-sonda de 50%, as duas estratégias causam a uma camada danos de natureza diferente. A poda por magnitude anula metade dos pesos podáveis da camada, escolhidos um a um entre os de menor valor absoluto, onde quer que estejam. Os pesos anulados ficam distribuídos entre as cabeças e os neurônios, de modo que nenhum deles é eliminado por inteiro: as 12 cabeças e os 3.072 neurônios continuam em operação, cada um com parte de seus pesos. A poda estruturada, por sua vez, remove 6 das 12 cabeças e 1.536 dos 3.072 neurônios, cada um com todos os seus pesos, pequenos ou grandes, e mantém intactos os demais. A diferença se assemelha à de duas formas de cortar pela metade as horas de trabalho de uma equipe: reduzir a jornada de todos os membros ou dispensar metade deles. O total cortado é o mesmo, mas, no primeiro caso, todas as funções da equipe continuam sendo exercidas, ainda que com menos tempo, e, no segundo, as funções dos membros dispensados deixam de ser exercidas.

Em consequência, a degradação medida pelas duas estratégias reflete propriedades diferentes da camada: na poda por magnitude, o quanto ela perde ao ter anulados seus pesos de menor valor absoluto; na poda estruturada, o quanto ela perde ao ficar sem parte de suas cabeças e de seus neurônios. Nada garante que uma camada que tolera bem um desses danos tolere também o outro, e por isso o perfil de uma estratégia não serve para alocar a outra: usá-lo seria distribuir a poda segundo a reação das camadas a um dano diferente do que de fato se aplica. Cada perfil foi obtido podando as camadas com a própria estratégia, para que medisse a reação ao mesmo dano que a alocação depois aplica, e orientou apenas a alocação dessa estratégia.

A taxa-sonda de 50%, porém, é uma escolha arbitrária: nenhum critério a torna preferível a outras taxas próximas. Isso levanta uma dúvida: a ordenação das camadas — quais são as mais sensíveis e quais as mais tolerantes — reflete uma característica das próprias camadas ou apenas da taxa-sonda escolhida? A dúvida importa porque o perfil é medido uma única vez, a 50%, mas orienta a alocação em todas as taxas de poda avaliadas,

de 10% a 90%. Se a ordenação mudasse com a taxa-sonda, uma camada classificada como tolerante na medição a 50% poderia não o ser em outras taxas, e a alocação podaria mais justamente onde não deveria.

Para responder a essa dúvida, o perfil completo foi medido novamente, nas duas estratégias, a uma segunda taxa-sonda, e as duas ordenações foram comparadas. O raciocínio é o mesmo de aplicar duas provas de dificuldades diferentes a uma mesma turma: se a classificação dos alunos se repete nas duas, ela reflete os alunos, e não a prova. Do mesmo modo, se as camadas aparecem na mesma ordem nas duas taxas-sonda, a ordenação é uma propriedade das camadas.

A segunda taxa-sonda foi de 30%, valor que atende a três condições. Primeiro, ela precisava diferir o bastante de 50% para que a comparação fosse informativa: com duas taxas muito próximas, a coincidência das ordenações seria esperada e nada provaria. Segundo, convinha que ficasse abaixo de 50%, e não acima: acima dessa taxa, cada camada perde mais da metade de seus elementos, e a medição se aproxima da remoção da camada inteira, granularidade mais grossa que a adotada neste trabalho (Seção 5.2.3). Terceiro, ela não podia ser baixa demais: a 10%, por exemplo, cada camada seria tão pouco alterada que as degradações ficariam todas pequenas e próximas entre si, e a ordenação passaria a depender de diferenças mínimas. A taxa de 30%, 20 pontos percentuais abaixo da primeira, fica entre esses extremos.

A segunda medição serviu apenas como verificação e não foi usada em nenhuma alocação: todas as taxas de poda por camada reportadas derivam do perfil de 50%. O resultado da comparação é apresentado na Seção 6.3.5.

5.3.2 Fase 2 — Alocação Adaptativa de Taxas

A fase 2 transforma o perfil de sensibilidade em uma alocação, isto é, em uma taxa de poda para cada camada. Ela segue os passos 2 e 3 do procedimento da Seção 4.3, já ilustrados pela Tabela 1 com um modelo hipotético de quatro camadas. Esta subseção retoma o mesmo exemplo para apresentar a regra adotada e os três elementos que a compõem: o fator, o teto e o parâmetro de intensidade.

A regra parte da ideia da Tabela 1: podar mais as camadas tolerantes e menos as sensíveis. As tolerâncias indicam apenas a proporção entre as taxas por camada. No exemplo, as tolerâncias 2, 5, 1 e 4 indicam que a camada 2 deve perder cinco vezes mais elementos que a camada 3, mas não quanto cada uma perde. Esse valor é dado pelo **fator**: todas as tolerâncias são multiplicadas por um mesmo número, escolhido para que a média das taxas por camada seja igual à taxa de poda pretendida. À taxa de poda de 30%, o fator é 0,10, e as taxas por camada são 20%, 50%, 10% e 40%, cuja média é 30%. À taxa de 15%, o fator cai pela metade, para 0,05, e todas as taxas também. Em resumo, o perfil

decide como a poda se distribui entre as camadas, e o fator decide quanto se remove no total.

O **teto** limita a taxa de cada camada a 95%. Sem ele, taxas de poda altas poderiam levar a camada mais tolerante a perder todos os seus elementos. No mesmo exemplo, à taxa de poda de 60%, o fator dobraria para 0,20, e a camada 2, de tolerância 5, receberia 100%: seria inteiramente podada. Com o teto, ela fica em 95%, e os 5 pontos percentuais que deixa de perder passam às outras três camadas, para que a média continue em 60%. O fator sobe, então, para cerca de 0,207, e as camadas 1, 3 e 4 passam a 41,4%, 20,7% e 82,9%. Como, nessa situação, o fator não resulta de uma simples divisão, ele foi calculado por tentativas sucessivas: ajusta-se o fator até que a média das taxas por camada coincida com a taxa de poda.

O **parâmetro de intensidade**, representado pelo expoente β, define quanto das diferenças de tolerância entre as camadas passa para as taxas por camada. Cada tolerância é elevada a β antes de ser multiplicada pelo fator, e o efeito depende do valor adotado (Tabela 7). Com $\beta = 1$, as diferenças passam integralmente: as taxas seguem as tolerâncias na proporção exata, como na Tabela 1, e a camada 2, cinco vezes mais tolerante que a camada 3, perde cinco vezes mais elementos. Com $\beta = 0{,}5$, passam parcialmente: cada tolerância é substituída por sua raiz quadrada, e a camada 2 passa a perder 2,24 vezes mais elementos que a camada 3. Com $\beta = 0$, não passam: toda tolerância elevada a zero vale 1, todas as camadas recebem a mesma taxa, como na alocação uniforme da Etapa 2, e o perfil deixa de ter efeito. Este último caso não foi usado como alocação, e sim como verificação, descrita ao final desta subseção.

O parâmetro de intensidade não altera a taxa de poda, que o fator mantém igual à média das taxas por camada, nem a ordem das camadas: com qualquer β maior que zero, a camada mais tolerante continua a ser a mais podada. Ele altera apenas a distribuição da poda entre as camadas. Na Tabela 7, a passagem de $\beta = 1$ para $\beta = 0{,}5$ retira 9,7 pontos percentuais da camada 2, a mais tolerante, e acrescenta 8 pontos percentuais à camada 3, a mais sensível. O efeito se assemelha ao do controle de contraste de uma imagem: reduzi-lo aproxima os tons entre si sem inverter a ordem do mais claro ao mais escuro, e anulá-lo deixa a imagem com um único tom.

Tabela 7 – Taxas de poda por camada no modelo hipotético da Tabela 1, à taxa de poda de 30%, para três valores do parâmetro de intensidade β. Em todas as linhas a média é 30%, e nenhuma camada atinge o teto.

β	Fator	Camada 1	Camada 2	Camada 3	Camada 4	Média
1,0	0,100	20,0%	50,0%	10,0%	40,0%	30%
0,5	0,180	25,5%	40,3%	18,0%	36,1%	30%
0	0,300	30,0%	30,0%	30,0%	30,0%	30%

Aplicado ao GPT-2, o parâmetro de intensidade atua sobre as razões entre as

taxas por camada. Enquanto nenhuma camada atinge o teto, a razão entre as taxas de poda de duas camadas é igual à razão entre suas tolerâncias elevada a β. Com $\beta = 1$, a camada mais tolerante recebe, portanto, uma taxa 42,9 vezes maior que a da mais sensível na poda estruturada e 11,3 vezes maior na poda por magnitude, as mesmas razões do perfil de sensibilidade (Tabela 13). Com $\beta = 0{,}5$, essas razões caem para as suas raízes quadradas, 6,5 e 3,4. À taxa de poda de 10%, por exemplo, a poda estruturada com $\beta = 1$ atribuiu 0,4% à camada 0, a mais sensível, e 16,9% à camada 9, a mais tolerante; com $\beta = 0{,}5$, as mesmas camadas receberam 2,1% e 13,7%.

Sem o parâmetro de intensidade, a regra equivaleria a fixar $\beta = 1$: a alocação seguiria integralmente as diferenças do perfil, quaisquer que fossem, o que traria dois problemas. O primeiro é que não há limite para a diferença de tolerância entre duas camadas: uma camada que quase não degrada o modelo teria tolerância muito alta e, sem amortecimento, concentraria praticamente toda a poda. O segundo é que o perfil é uma medição aproximada. Ele é obtido com cada camada podada isoladamente, a uma única taxa-sonda, e a degradação de camadas podadas em conjunto supera a soma de suas degradações individuais (Seção 6.3.6). Por isso, o perfil é mais confiável quanto à ordem das camadas do que quanto à proporção exata entre elas, e, com β fixo em 1, um erro nessa proporção passaria inteiro às taxas por camada. Valores de β entre 0 e 1 preservam a ordem medida e atenuam a proporção, e a comparação entre intensidades indica o quanto convém confiar nela.

Os experimentos avaliaram $\beta = 1$ e $\beta = 0{,}5$ sobre o mesmo perfil, o que permitiu comparar as duas intensidades sem repetir a fase 1, a etapa de maior custo. O valor 0,5 corresponde ao ponto intermediário entre os dois extremos em escala multiplicativa: com ele, a razão entre as taxas extremas é a média geométrica entre a razão da alocação uniforme, igual a 1, e a do perfil seguido integralmente. Na poda estruturada, 6,5 está para 1 assim como 42,9 está para 6,5. A comparação entre as duas intensidades, o efeito de cada uma sobre a *perplexity* e as razões desse efeito são apresentados na Seção 6.4.4.

Para referência, a regra completa pode ser escrita de forma compacta na Equação 5.2:

$$r_\ell = \min\Big(\alpha \cdot \Delta_\ell^{-\beta},\ r_{\max}\Big), \qquad \frac{1}{12}\sum_{\ell=0}^{11} r_\ell = s, \tag{5.2}$$

em que r_ℓ é a taxa de poda da camada ℓ; Δ_ℓ é a sua degradação (Equação 5.1), cujo inverso é a tolerância; α é o fator; β, o parâmetro de intensidade; $r_{\max} = 0{,}95$, o teto; e s, a taxa de poda. A segunda parte da equação exige que a média das taxas das 12 camadas seja igual à taxa de poda. Na implementação, essa média é ponderada pelo número de parâmetros podáveis de cada camada, o que permite aplicar a regra a modelos com camadas de tamanhos diferentes; no GPT-2, cujas camadas têm o mesmo tamanho,

ela coincide com a média simples.

O valor $\beta = 0$ também foi avaliado, mas como verificação, e não como alocação candidata. Como, com ele, todas as camadas recebem a mesma taxa — última linha da Tabela 7 —, a regra deve reproduzir a varredura uniforme da Etapa 2. Se reproduzir, confirma-se que a regra está corretamente implementada. Na poda estruturada, a reprodução deve ser exata. Na poda por magnitude, não: a regra usa um único limiar para as quatro matrizes de cada camada, enquanto a varredura uniforme usa um limiar para cada matriz. As duas removem a mesma fração de cada camada, mas não exatamente os mesmos pesos. A verificação é apresentada na Seção 6.4.3.

Por fim, a implementação inclui uma precaução que a equação não mostra. Se a poda de uma camada na fase 1 não aumentasse a *perplexity* — o que pode ocorrer, pois há casos em que remover cabeças de atenção a *melhora* (MICHEL; LEVY; NEUBIG, 2019) —, a degradação dessa camada seria nula ou negativa, e a tolerância, que é o seu inverso, não poderia ser calculada. Por isso, no cálculo da tolerância, a degradação nunca fica abaixo de um valor mínimo positivo, 0,0001, e uma camada nessa situação entra na alocação como a mais tolerante, já que, com a degradação fixada nesse valor mínimo, sua tolerância passa a ser 10.000, maior que a de qualquer camada cuja degradação supere esse valor. O tratamento é coerente com a própria medição: se a poda da camada não piorou o modelo, ela é, pelo critério do perfil, a que melhor tolera a poda. Nos perfis usados nas alocações, essa precaução não chegou a ser acionada: a menor degradação foi de 0,0346, mais de 300 vezes esse valor mínimo.

5.4 *Fine-tuning* de Recuperação

As Etapas 2 e 3 operaram em regime *one-shot*, isto é, podaram e avaliaram sem retreinamento, de modo a isolar o dano causado pela poda. Esse regime, porém, não corresponde ao procedimento da literatura: tanto Han et al. (2015) quanto Li et al. (2017) retreinam o modelo após podá-lo. Na quarta etapa, esse retreinamento foi incorporado ao experimento: sete configurações foram submetidas ao *fine-tuning* de recuperação, e a *perplexity* de cada uma foi medida antes e depois do retreinamento, o que indica quanto da degradação é recuperável. As subseções a seguir apresentam as configurações retreinadas, o procedimento aplicado a cada uma, os cuidados que condicionam a validade da medição e os parâmetros do treinamento.

5.4.1 Configurações Retreinadas

O retreinamento foi aplicado às seguintes configurações das Etapas 2 e 3:

- **Controle denso:** o modelo base, sem poda, cuja função é descrita na Seção 5.4.3;

- **Poda não estruturada — poda por magnitude**, com escopo uniforme, a 30% e a 50% de esparsidade;
- **Poda estruturada — poda de cabeças de atenção e de neurônios do MLP**, com os dois alvos simultâneos e escopo não uniforme, a 10% e a 30% de estruturas removidas;
- **Poda estruturada com análise de sensibilidade**, com a alocação definida pelo perfil da própria poda estruturada, com $\beta = 1$, nas mesmas duas taxas.

As configurações da lista foram escolhidas a partir dos resultados das Etapas 2 e 3 em regime *one-shot*, apresentados no Capítulo 6. A escolha respondeu a três perguntas.

A primeira é qual dos dois escopos sem análise de sensibilidade, uniforme ou não uniforme, retreinar em cada estratégia. Escolheu-se, em cada uma, o de menor *perplexity* nas taxas de poda em que a escolha faz diferença. Na poda por magnitude, foi o uniforme, que supera o não uniforme entre 30% e 70%. Fora dessa faixa, a escolha pouco importa: até 20%, os dois quase não degradam o modelo, e a partir de 80% ambos já o destroem (Seção 6.4.1). Na poda estruturada, foi o não uniforme, que supera o uniforme em todas as taxas, exceto 20% (Seção 6.4.2).

A segunda é em qual estratégia retreinar também a alocação com análise de sensibilidade. Escolheu-se apenas a poda estruturada, por ter sido a única a reduzir o tempo de inferência e o consumo de energia (Seção 6.2). Na poda por magnitude, os pesos são zerados, mas não removidos (Seção 5.2.2), e o custo não cai. Usou-se o parâmetro de intensidade $\beta = 1$, o de melhor desempenho na poda estruturada (Seção 6.4.4).

A terceira é em quais taxas de poda retreinar. Na poda estruturada, escolheram-se 10% e 30%. São as mesmas taxas nas duas alocações, não uniforme e com análise de sensibilidade, o que permite compará-las também depois do retreinamento, e ambas estão na faixa de 10% a 50% em que, em regime *one-shot*, a alocação com análise de sensibilidade obteve *perplexity* menor que a não uniforme (Seção 6.4.2). Na poda por magnitude, escolheram-se duas taxas com danos de intensidades diferentes: 30%, a primeira taxa acima da região utilizável em regime *one-shot* — as taxas de até 20%, em que a poda quase não degrada o modelo —, e 50%, em que a degradação já é severa, com *perplexity* de 473,28 (Seção 6.4.1). Com isso, o retreinamento é observado tanto sobre um dano moderado quanto sobre um dano severo.

5.4.2 Procedimento

Cada configuração passou pelo mesmo procedimento, implementado no módulo `finetune` (Tabela 9):

1. o modelo base foi recarregado a partir dos pesos pré-treinados e podado pelas mesmas funções das Etapas 2 e 3, de modo que o modelo retreinado fosse idêntico ao avaliado em regime *one-shot*;

2. mediu-se a *perplexity* do modelo podado, ponto de partida da recuperação; nas sete configurações, o valor obtido reproduziu, em todos os dígitos registrados, o das varreduras *one-shot*;

3. na poda não estruturada, registrou-se a **máscara binária** do modelo podado, que marca com 1 os pesos que permaneceram e com 0 os que foram anulados, para mantê-los em zero durante o retreinamento (Seção 5.4.3);

4. o modelo foi retreinado sobre a partição de treino do WikiText-2, com os parâmetros da Tabela 8;

5. o modelo retreinado foi avaliado na partição de teste por todas as métricas da Etapa 1 (Tabela 5), pelo mesmo procedimento aplicado aos modelos não retreinados.

O retreinamento atualizou todos os parâmetros do modelo podado — inclusive *embeddings*, vieses e parâmetros de normalização —, e não apenas as matrizes podáveis (Seção 4.2.1), já que o efeito da poda não fica restrito às matrizes de onde os elementos foram removidos. As camadas do GPT-2 são empilhadas (Seção 2.3.4): a saída de cada uma é a entrada da seguinte, e a saída da última alimenta a normalização final e a cabeça de linguagem. Ao podar uma camada, altera-se a representação que ela entrega, e todos os componentes posteriores, podados ou não, passam a receber entradas diferentes daquelas para as quais foram pré-treinados. Recuperar o modelo exige, portanto, não só reajustar os pesos que restaram nas matrizes podadas, mas também readaptar esses componentes às novas entradas. Os parâmetros de normalização, por exemplo, controlam a escala de cada dimensão da entrada da atenção e do MLP e podem reajustá-la às representações alteradas; restringir o retreinamento às matrizes podáveis os manteria fixos nos valores do pré-treinamento, calibrados para o modelo sem poda. Do mesmo modo, a cabeça de linguagem, que no GPT-2 compartilha os pesos com o *embedding* de *token*, precisa readaptar-se às representações que recebe da última camada, o que só é possível se esse *embedding* também for atualizado. Atualizar todos os parâmetros, por outro lado, não desfaz a poda: na poda estruturada, as estruturas removidas deixaram de existir, e, na poda por magnitude, os pesos anulados foram mantidos em zero por uma máscara (Seção 5.4.3).

O modelo avaliado é o obtido ao final do último passo do otimizador: a partição de validação não foi utilizada, e não houve parada antecipada nem seleção do melhor ponto do treinamento. Com isso, a quantidade de retreinamento é idêntica em todas as

configurações, condição para que suas *perplexities* pós-retreinamento sejam comparáveis entre si.

5.4.3 Controle Denso e Preservação da Esparsidade

Duas decisões de implementação merecem registro por afetarem a validade dos resultados.

A primeira é o **controle denso**. O GPT-2 não foi pré-treinado no WikiText-2, e sim no WebText, composto por páginas da web obtidas de *links* publicados no Reddit e do qual os documentos da Wikipédia foram removidos (Seção 5.1.2). Por isso, o simples *fine-tuning* do modelo base no WikiText-2 já reduz a *perplexity* por **adaptação de domínio**, sem poda alguma envolvida. A adaptação de domínio é o ganho de desempenho que um modelo pré-treinado obtém quando seu treinamento continua sobre textos do domínio em que ele será aplicado (GURURANGAN et al., 2020). Aqui, esse domínio são os artigos da Wikipédia, com vocabulário, estilo e estrutura próprios: retreinado sobre eles, o modelo aprende essas regularidades e passa a prever melhor o conjunto de teste, formado pelo mesmo tipo de texto. Sem essa linha de controle, seria impossível separar a recuperação do dano da poda da mera adaptação à base de dados. O modelo base foi, portanto, retreinado pelo mesmo número de passos e avaliado junto às demais configurações.

A segunda é a **preservação da esparsidade**. Na poda não estruturada, os pesos podados não são removidos, e sim zerados: continuam ocupando suas posições nas matrizes (Seção 5.2.2). Para o otimizador, um peso zerado é um parâmetro como outro qualquer. Seu gradiente, que indica em que direção alterar o peso para reduzir a perda, em geral não é nulo, e o otimizador o alteraria já no primeiro passo. Ao final do retreinamento, os pesos anulados teriam voltado a valores diferentes de zero, o modelo estaria novamente denso, e o resultado deixaria de medir a recuperação de um modelo podado.

Para evitar isso, usou-se uma **máscara binária fixa**, como em Han et al. (2015). A máscara é uma matriz do mesmo tamanho de cada matriz de pesos podável, com valor 1 nas posições dos pesos que permaneceram após a poda e 0 nas posições dos pesos anulados. Ela é capturada uma única vez, logo após a poda, e não muda durante o treinamento, razão pela qual é chamada de fixa. Depois de cada passo do otimizador, cada matriz de pesos é multiplicada, elemento a elemento, por sua máscara: os pesos nas posições de valor 1 conservam o valor que o otimizador acabou de lhes atribuir, e os pesos nas posições de valor 0 voltam a zero. Por exemplo, com valores ilustrativos, em uma linha de quatro pesos com máscara (1; 0; 1; 0), se um passo do otimizador levar os pesos a (0,80; 0,02; −0,30; 0,01), a multiplicação os devolve a (0,80; 0; −0,30; 0). Assim, os pesos que permaneceram são retreinados normalmente, enquanto os podados ficam em zero do início ao fim do treinamento. Como a máscara age sobre os próprios pesos,

depois de cada passo, esse resultado não depende da forma como o otimizador calcula a atualização.

A esparsidade medida ao final do treinamento foi registrada como verificação de integridade e coincidiu, nas duas configurações de magnitude, com a medida logo após a poda (Seção 6.5.4). Na poda estruturada não houve máscara, pois as estruturas já haviam sido fisicamente removidas: as matrizes ficaram menores, e não restou nenhuma posição zerada a preservar.

5.4.4 Parâmetros do Treinamento

Para o treinamento, as linhas da partição de treino do WikiText-2 foram concatenadas em um único texto, tokenizado e dividido em blocos contíguos e disjuntos de 512 *tokens*, isto é, sem sobreposição entre blocos; o resto final, menor que um bloco, foi descartado. Resultaram 4.743 blocos, ou 2.428.416 *tokens*. É o procedimento indicado na documentação da biblioteca `transformers` para o *fine-tuning* de modelos de linguagem causais, como o GPT-2 (Hugging Face, 2026a).

Essa divisão difere da adotada na avaliação, que percorre o texto por janelas deslizantes de 1.024 *tokens* com passo de 512, sobrepostas em metade de seu comprimento (Seção 5.1.3.1), porque as duas etapas têm objetivos diferentes. Em ambas, uma única passagem do modelo sobre um trecho de texto produz uma previsão para cada *token* do trecho, feita a partir dos *tokens* que o antecedem dentro dele. O primeiro *token* de um trecho é, portanto, previsto quase sem contexto, e o último, com o trecho inteiro como contexto. Na avaliação, o objetivo é medir o desempenho do modelo, e previsões feitas com pouco contexto o subestimariam. A sobreposição evita isso: cada janela repete os 512 *tokens* finais da anterior apenas como contexto, sem contabilizá-los na perda, de modo que, a partir da segunda janela, cada *token* avaliado dispõe de pelo menos 512 *tokens* anteriores e entra no cálculo uma única vez.

No treinamento, o objetivo é ajustar os pesos a partir do texto, usando cada *token* como alvo de previsão uma vez por época. Previsões com pouco contexto não prejudicam esse objetivo, pois também são exemplos legítimos da tarefa de prever o próximo *token*, e os blocos disjuntos o atingem sem desperdício: cada *token* é alvo exatamente uma vez, e cada passagem do modelo aproveita todas as previsões que produz. Usar no treinamento as janelas da avaliação levaria a uma de duas situações, ambas desvantajosas. Se todos os *tokens* de cada janela contassem na perda, cada *token* seria usado duas vezes por época, já que cada janela repete metade da anterior: a época equivaleria a duas passagens pelo texto, com cerca do dobro do custo, e janelas consecutivas seriam amostras parcialmente repetidas, e não independentes. Se apenas os *tokens* novos contassem, como na avaliação, metade de cada janela serviria só de contexto: o modelo processaria dois *tokens* para cada *token* de treino, o que dobraria, aproximadamente, o tempo e o consumo de energia do

retreinamento sem acrescentar nenhum *token* de treino.

A diferença entre as duas divisões não afeta a comparação entre os modelos: o treinamento usa apenas a partição de treino, e todas as *perplexities*, antes e depois do retreinamento, foram medidas na partição de teste pelo mesmo procedimento de janelas deslizantes. A Tabela 8 reúne os parâmetros adotados, idênticos nas sete configurações.

Tabela 8 – Parâmetros do *fine-tuning* de recuperação.

Parâmetro	**Valor**
Blocos de treino (512 *tokens* cada)	4.743
Blocos por lote	4
Lotes acumulados por passo do otimizador	4
Lote efetivo por passo	16 blocos (8.192 *tokens*)
Passos do otimizador	297 (uma época)
Otimizador	AdamW
Taxa de aprendizado máxima	5×10^{-5}
Aquecimento linear da taxa de aprendizado	17 passos (6% do total, truncado)
Decaimento da taxa de aprendizado	linear, até zero no passo 297
Decaimento de pesos	0,01
Limite da norma do gradiente	1,0
Precisão numérica	mista (FP16 e FP32)
Semente aleatória	42

Fonte: Elaboração própria.

Os gradientes de quatro lotes consecutivos, de quatro blocos cada, foram acumulados antes de cada passo do otimizador, o que equivale a um lote efetivo de 16 blocos; a perda de cada lote foi dividida por quatro, de modo que o gradiente acumulado correspondesse à média dos lotes, e não à soma. O número de passos foi calculado para corresponder a uma época, isto é, a uma passagem pelo conjunto de treino: os 4.743 blocos, divididos em lotes efetivos de 16, resultam em 297 passos, com arredondamento para cima.

O otimizador AdamW (LOSHCHILOV; HUTTER, 2019) aplica o decaimento de pesos separadamente da atualização pelo gradiente. O decaimento foi aplicado apenas às matrizes de peso, deixando de fora vieses e parâmetros de normalização, conforme prática consolidada. A taxa de aprendizado cresceu linearmente durante os 17 primeiros passos e decresceu linearmente até zero no último, e a norma do gradiente foi limitada a 1,0 antes de cada passo. A taxa de aprendizado e o lote efetivo estão entre os valores recomendados por Devlin et al. (2019) para o *fine-tuning* de *Transformers* pré-treinados — taxa de 2×10^{-5} a 5×10^{-5} e lotes de 16 ou 32 exemplos —; o decaimento de pesos de 0,01 e o aquecimento seguido de decaimento linear são os adotados por esses autores no pré-treinamento do BERT. Nenhum desses valores foi ajustado para este experimento (Seção 5.9). A quantidade de retreinamento, uma época, fica abaixo das duas a quatro

épocas recomendadas pelos mesmos autores; o que essa limitação impede de concluir é discutido na Seção 6.5.4.

A passagem direta e a retropropagação executaram em **precisão mista** (MICIKEVICIUS et al., 2018): as operações foram realizadas em meia precisão (FP16), com os pesos mantidos em precisão simples (FP32) e escalonamento dinâmico da perda, que evita o subtransbordamento dos gradientes em meia precisão. A escolha aproveita as unidades de cálculo especializadas da GPU Tesla T4, que alcança 65 TFLOPS em precisão mista contra 8,1 TFLOPS em precisão simples (NVIDIA Corporation, 2019), e corresponde à configuração pressuposta na estimativa de memória do critério C3 (Seção 4.1.1). Ela introduz, porém, uma fonte adicional de variação numérica que não existe nas etapas *one-shot*, todas executadas em precisão simples. O consumo de energia do treinamento foi medido pela biblioteca CodeCarbon separadamente do consumo da avaliação: trata-se de um custo pago uma única vez, que precisa ser amortizado contra a economia por inferência para que o balanço energético do trabalho feche corretamente.

Diferentemente de todas as etapas anteriores, esta é estocástica — a ordem dos lotes e o *dropout* introduzem variabilidade — e, portanto, é a única em que a semente aleatória efetivamente altera o resultado. Cada configuração foi retreinada uma única vez, com a semente 42, reiniciada antes de cada configuração. A ordem dos lotes, sorteada por um gerador próprio iniciado com essa semente, foi a mesma nas sete configurações, de modo que as diferenças entre elas não decorrem da ordem em que os dados foram apresentados. A ausência de repetições com sementes distintas é discutida entre as limitações (Seção 5.9).

5.5 *Framework* de Implementação

A implementação foi feita em Python, com a biblioteca PyTorch (PASZKE et al., 2019) para construção, manipulação e treinamento dos modelos. O PyTorch foi escolhido por seu sistema de diferenciação automática, que constrói dinamicamente o grafo computacional e calcula os gradientes da retropropagação durante o *fine-tuning*, e por seu suporte nativo à aceleração em GPU.

Os pesos pré-treinados foram obtidos na plataforma Hugging Face por meio da biblioteca `transformers` (WOLF et al., 2020), que implementa sobre o PyTorch as arquiteturas dos modelos candidatos. A Hugging Face é uma plataforma colaborativa de hospedagem e distribuição de modelos, e não uma biblioteca: em 28 set. 2026, hospedava mais de 3,1 milhões de modelos, entre eles diversas famílias de modelos de linguagem, como GPT-2, OPT, Pythia, Llama e BERT.

As demais bibliotecas empregadas são:

- `datasets` (LHOEST et al., 2021): carregamento do WikiText-2 a partir da plataforma Hugging Face, já dividido em suas partições oficiais de treino, validação e teste;
- `thop` (ZHU, 2022): contagem do custo computacional de uma inferência por análise do grafo computacional. A biblioteca conta multiplicações seguidas de soma (MACs, do inglês *multiply-accumulate operations*), e cada uma foi convertida em duas operações de ponto flutuante (FLOPs). Como a biblioteca não reconhece o módulo `Conv1D`, com que a `transformers` implementa as projeções lineares do GPT-2, acrescentou-se uma regra de contagem para ele;
- `CodeCarbon` (COURTY et al., 2023): medição empírica do consumo de energia e estimativa das emissões de CO_2, a partir do monitoramento do *hardware* combinado à intensidade de carbono da rede elétrica local.

As duas estratégias de poda foram implementadas diretamente sobre as matrizes de pesos, sem bibliotecas dedicadas à poda. Na poda estruturada, essa implementação própria foi necessária: a versão 5 da biblioteca `transformers` removeu a interface de poda de cabeças de atenção que existia nas versões anteriores. A remoção física das estruturas foi, portanto, feita no próprio código: as matrizes foram reconstruídas sem as linhas e colunas das estruturas removidas, e os atributos do módulo de atenção que registram o número de cabeças e a largura das projeções foram atualizados, para que o modelo continue dividindo as matrizes corretamente entre as cabeças restantes.

A implementação da poda é verificada por um conjunto de 15 testes automatizados (`test_poda`), executados sobre um GPT-2 de dimensões reduzidas e pesos aleatórios: o que se verifica é o funcionamento da poda, que não depende dos pesos pré-treinados. Os 15 testes foram aprovados. O teste central é o de **equivalência numérica**. Remover fisicamente um conjunto de cabeças de atenção, ou de neurônios do MLP, deve produzir as mesmas saídas que apenas anular os pesos correspondentes no modelo de dimensões originais, a menos de diferenças de arredondamento (tolerância absoluta de 10^{-5} e relativa de 10^{-4}). As duas operações têm de ser equivalentes: anular as fatias de consulta, chave e valor de uma cabeça zera seu vetor de valores, de modo que sua contribuição à saída da atenção se anula qualquer que seja a distribuição de atenção calculada; e anular os pesos de entrada e o viés de um neurônio do MLP zera sua ativação, pois a função GELU vale zero em zero. Por isso, qualquer erro de indexação na reconstrução das matrizes, como remover a linha ou a coluna errada, quebraria a equivalência e seria detectado pelo teste.

Os demais testes verificam que os atributos do módulo de atenção permanecem coerentes com as dimensões das matrizes; que a poda a taxa zero não altera o modelo; que a salvaguarda da poda estruturada (Seção 5.2.3) preserva ao menos uma cabeça e um neurônio por camada, mesmo com taxa de poda de 100%; que as estruturas removidas

são as de menor norma L_1; que a poda por magnitude atinge a esparsidade pedida, zera os pesos de menor valor absoluto e preserva as dimensões das matrizes; que a regra de alocação mantém a média das taxas por camada igual à taxa de poda e poda menos a camada mais sensível; que, com $\beta = 0$, a alocação reproduz a varredura uniforme na poda estruturada e difere dela na poda por magnitude (Seção 5.3.2); e que a máscara binária mantém os pesos podados em zero após um passo do otimizador (Seção 5.4.3).

5.6 *Pipeline* Experimental

O código está organizado em módulos, cada um responsável por uma única etapa do experimento, o que permite que todas as estratégias de poda reutilizem exatamente a mesma rotina de avaliação. Essa é a condição para que as diferenças medidas entre as configurações se devam à poda, e não a diferenças na forma de medir. A Tabela 9 descreve os módulos e a Figura 9 representa o fluxo experimental.

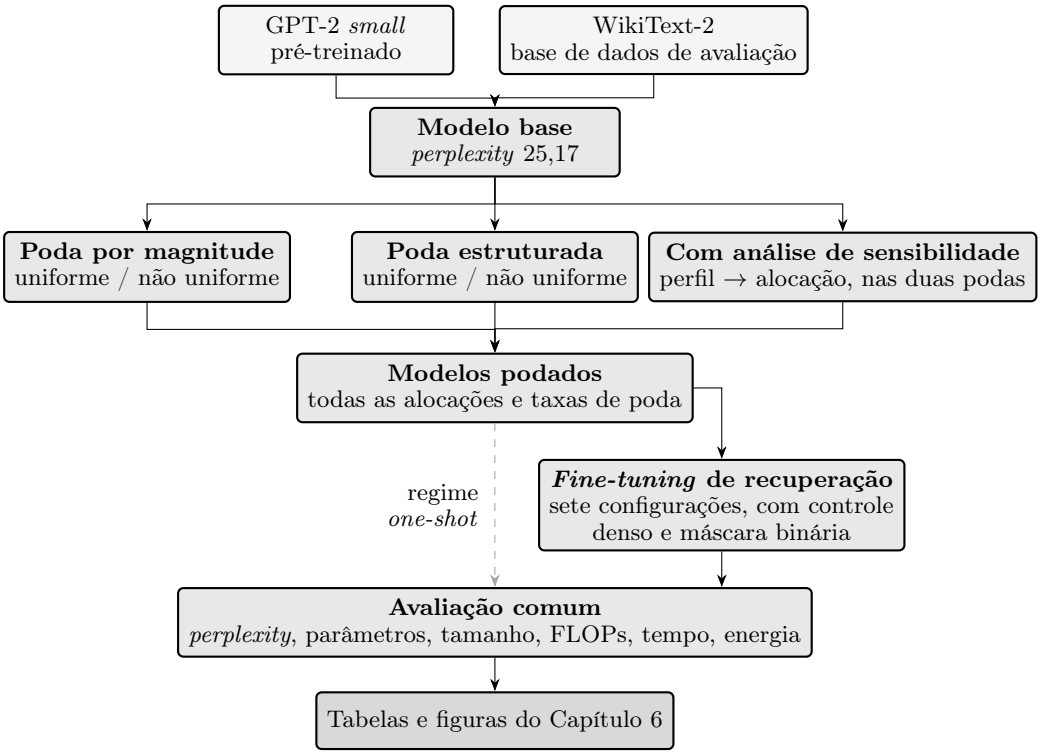
Tabela 9 – Organização modular da implementação.

Módulo	**Responsabilidade**
`config`	Configuração central: modelo, base de dados, parâmetros de avaliação, semente e ambiente.
`utils`	Fixação das sementes e escrita incremental dos resultados em arquivo.
`data`	Carregamento e tokenização da base de dados.
`model`	Carregamento do GPT-2 pré-treinado.
`eval`	*Perplexity* por janela deslizante e métricas de custo computacional.
`energy`	Medição de energia e emissões.
`prune_magnitude`	Poda não estruturada por magnitude, nos dois escopos.
`prune_structured`	Poda estruturada de cabeças e neurônios, com remoção física.
`sensitivity`	Perfil de sensibilidade (fase 1) e alocação adaptativa (fase 2).
`finetune`	*Fine-tuning* de recuperação, com preservação de esparsidade.
`run`	Orquestração da avaliação do modelo base.
`test_poda`	Testes de corretude da poda, descritos na Seção 5.5.

Fonte: Elaboração própria.

Como indica a linha tracejada da figura, todos os modelos podados foram avaliados em regime *one-shot*, isto é, logo após a poda, sem retreinamento; apenas as sete configurações da Seção 5.4.1 passaram também pelo *fine-tuning* antes de uma nova avaliação. Essa bifurcação é o que permite separar, nos resultados, o dano causado pela poda daquilo que o retreinamento consegue recuperar.

Figura 9 – Fluxo experimental do trabalho. Todas as estratégias convergem para a mesma rotina de avaliação, o que garante que todas as configurações sejam medidas da mesma forma.



Fonte: Elaboração própria.

5.7 Ambiente de Execução e Reprodutibilidade

Os experimentos foram executados na plataforma Kaggle, escolhida por oferecer acesso gratuito a GPU dedicada, com sessões longas o bastante para as varreduras completas (Tabela 10). Todas as sessões usaram uma GPU NVIDIA Tesla T4, com 16 GB de memória (NVIDIA Corporation, 2019). A implementação detecta automaticamente o dispositivo disponível, o que permite executar o código localmente, em CPU, para testes rápidos, sem alteração de código.

Quanto à reprodutibilidade, dois aspectos merecem registro.

O primeiro é que as varreduras *one-shot* são **determinísticas**. Não há treinamento, o modelo opera em modo de avaliação, o conjunto de teste é fixo e os critérios de poda são ordenações determinísticas sobre pesos fixos. Verificou-se que execuções independentes, em sessões distintas, reproduzem a *perplexity* em todos os dígitos registrados: as sete configurações do *fine-tuning*, podadas novamente em outra sessão, partiram exatamente dos valores das varreduras *one-shot* (Seção 5.4.2). Repetições com sementes diferentes, nessas etapas, produziriam resultados idênticos e não acrescentariam informação. A semente só influencia o resultado no *fine-tuning*, a única etapa estocástica do trabalho.

O segundo é que as medições de **tempo e energia dependem da sessão**. O mesmo modelo base, sem qualquer poda, registrou tempos de inferência de 40,5, 54,0 e 46,3 ms por janela em três sessões diferentes, e consumos de energia entre 1.176 e 1.572 mWh por avaliação completa do conjunto de teste (Seção 6.1). A variação é atribuída às diferenças entre as máquinas físicas alocadas a cada sessão e à carga concorrente nelas. Por essa razão, comparações de custo entre varreduras executadas em sessões distintas foram sempre feitas em termos relativos ao modelo base da própria sessão, nunca em valores absolutos.

5.8 Síntese das Decisões de Implementação

Todo desenho experimental implica escolhas que condicionam o escopo dos resultados. A Tabela 10 sintetiza as principais decisões adotadas ao longo deste capítulo, as alternativas consideradas e a justificativa de cada uma.

Tabela 10 – Síntese das principais decisões de implementação do trabalho.

Decisão	**Alternativas consideradas**	**Escolha**	**Justificativa**
Base de dados	WikiText-103, Penn Treebank, OpenWebText, The Pile	**WikiText-2**	Atende aos quatro critérios da Seção 4.1.2; entre os que atendem, tem o menor conjunto de treino (Tabela 4).
Modelo	GPT-2 *medium*/*large*/XL, DistilGPT2, OPT-125M, Pythia-160M, BERT, Llama 2	**GPT-2 *small***	Atende aos seis critérios da Seção 4.1.1 e forma com o WikiText-2 um par que atende a D1–D4; entre os que atendem, é o de menor número de parâmetros (Tabela 3).
Estratégias de poda	SparseGPT, Wanda, *movement pruning*, poda de cabeças por gradiente	**Duas** (magnitude e estruturada)	Únicas alternativas que atendem a P1 e P2; juntas, atendem a P3 (Tabela 6). A restrição de tempo experimental inviabilizaria uma terceira com a mesma profundidade.
Regime de poda	Iterativo (podar e retreinar em ciclos)	***One-shot* primeiro**	Isola o efeito da poda do efeito do retreinamento; o *fine-tuning* entra depois, como etapa separada e mensurável.
Estratégia otimizada	Taxas dinâmicas, variação do momento da poda, destilação de conhecimento, quantização	**Sensibilidade por camada**	Única que atende a O1–O3 (Seção 4.3): altera apenas a distribuição da poda entre as camadas, objeto da hipótese do trabalho.
Métrica principal	*Accuracy* em tarefas descendentes	**Perplexity**	Métrica intrínseca padrão para modelos de linguagem, mensurável sem *fine-tuning* em tarefa específica.
Ambiente	Máquina local, Google Colab	**Kaggle (GPU T4)**	Acesso gratuito a GPU dedicada com sessões longas o bastante para as varreduras completas.

Fonte: Elaboração própria.

5.9 Limitações Metodológicas

Reconhecem-se, desde o desenho experimental, limitações que condicionam o escopo dos resultados:

- **Um único modelo e uma única base de dados.** Os experimentos empregaram exclusivamente o GPT-2 *small* sobre o WikiText-2. Os resultados podem não se transferir diretamente para modelos de escala substancialmente maior ou para bases de dados de natureza distinta. A implementação foi mantida parametrizável justamente para viabilizar essa verificação em trabalhos futuros.

- **Duas estratégias de poda.** As estratégias foram escolhidas pelos critérios P1 a P3 (Seção 5.2.1), que excluem as que estimam a importância com dados ou ao longo do treinamento, como o SparseGPT e o Wanda, referências recentes da poda de LLMs. As conclusões referem-se, portanto, a critérios de importância calculados apenas a partir dos pesos, e não se avaliou a alocação com análise de sensibilidade aplicada a essas estratégias.

- **Faixa restrita de taxas-sonda no perfil de sensibilidade.** O perfil que alimenta a alocação foi levantado a uma única taxa-sonda, de 50%, e sua estabilidade foi verificada por uma réplica a 30% (Seção 6.3.5). As duas taxas pertencem, porém, ao mesmo regime intermediário de poda: nada garante que a ordenação das camadas por sensibilidade se mantenha em taxas muito menores ou muito maiores.

- **Sensibilidade medida em isolamento.** A taxa-sonda é aplicada a uma camada por vez, o que ignora as interações entre camadas. Como mostra a Seção 6.3.6, a degradação é fortemente superaditiva: na poda por magnitude, a soma das degradações individuais das camadas é 1,238, enquanto a poda simultânea de todas elas a 50% produz degradação de 2,934, mais que o dobro. O perfil deve, por isso, ser lido como uma ordenação das camadas por sensibilidade, e não como um modelo capaz de prever o desempenho de uma configuração completa.

- **Dependência do *hardware*.** Tempo e energia dependem da máquina em que são medidos. Os valores absolutos não devem ser comparados entre ambientes distintos, nem mesmo entre sessões da mesma plataforma; a análise apoia-se em comparações relativas ao modelo base medido na mesma sessão (Seção 5.7).

- **Hiperparâmetros não otimizados.** Os hiperparâmetros do *fine-tuning* foram tomados de valores recomendados na literatura (Seção 5.4.4), sem busca sistemática, e valores melhores podem existir. A quantidade de retreinamento, uma época, fica abaixo das duas a quatro épocas recomendadas por Devlin et al. (2019).

- **Semente única no *fine-tuning*.** Esta é a única etapa estocástica do experimento, e todas as configurações foram executadas com uma única semente. As *perplexities* pós-retreinamento não vêm, portanto, acompanhadas de estimativa de variância, e diferenças pequenas entre configurações retreinadas devem ser lidas com a cautela correspondente. A comparação principal da etapa — alocação com análise de sensibilidade contra alocação não uniforme — é afetada por essa limitação justamente na taxa de poda de 10%, em que as duas praticamente empatam após o retreinamento: *perplexity* de 25,96 com análise de sensibilidade e de 25,33 na alocação não uniforme (Seção 6.5).
- **Estimativa de emissões.** A conversão de energia em emissões depende de tabelas regionais de intensidade de carbono, que carregam incerteza e variaram entre as sessões de execução. As emissões devem ser lidas como aproximações de ordem de grandeza.

Apesar dessas limitações, o desenho descrito é suficiente para responder às duas perguntas enunciadas no início deste capítulo, que são o objeto do Capítulo 6.

6 Resultados

Este capítulo apresenta os resultados experimentais obtidos com o GPT-2 *small* sobre o WikiText-2, organizados por tipo de métrica, de modo que cada tabela compare uma única grandeza. Após o protocolo (Seção 6.1), a Seção 6.2 apresenta o custo computacional e o consumo de energia das estratégias de poda, que respondem à primeira pergunta do trabalho. A Seção 6.3 apresenta o perfil de sensibilidade por camada, que alimenta a alocação com análise de sensibilidade, e a Seção 6.4 compara a qualidade preditiva das alocações com e sem essa análise, o que responde à segunda pergunta. A Seção 6.5 submete as configurações mais relevantes ao *fine-tuning* de recuperação, a Seção 6.6 combina qualidade e energia nos indicadores da Seção 4.1.3, e a Seção 6.7 sintetiza os achados.

6.1 Protocolo e Modelo Base

Todos os experimentos partem do GPT-2 *small* pré-treinado (124.439.808 parâmetros), avaliado no conjunto de teste do WikiText-2 por janela deslizante com *stride* de 512 *tokens*. A perplexity do modelo base é de **25,17**. O valor é inferior aos 29,41 publicados por Radford et al. (2019), e a diferença é compatível com a do protocolo de avaliação: com janelas deslizantes sobrepostas, cada *token* é predito com pelo menos 512 *tokens* de contexto, o que reduz a *perplexity* em relação à avaliação em janelas disjuntas. A documentação da biblioteca `transformers` registra esse efeito no GPT-2 *large*: 19,44 com janelas disjuntas de 1.024 *tokens*, valor próximo dos 19,93 publicados, e 16,44 com *stride* de 512 (Hugging Face, 2026b), redução de cerca de 15%. Redução da mesma ordem, cerca de 14%, separa os 29,41 publicados para o *small* dos 25,17 medidos aqui, com o mesmo protocolo daquela documentação. As medições de custo do modelo base são: 474,70 MB de memória de parâmetros e 126,6 GFLOPs por janela de 512 *tokens*.

Duas ressalvas metodológicas condicionam a leitura das tabelas que se seguem.

A primeira é que **todos os resultados das varreduras são *one-shot***, com exceção da Seção 6.5, dedicada justamente ao retreinamento: poda-se o modelo pré-treinado e mede-se imediatamente, sem qualquer *fine-tuning* de recuperação. Essa escolha isola o efeito da poda do efeito do retreinamento, mas implica que as perplexities aqui reportadas são substancialmente piores que as da literatura, em que a poda é seguida de retreinamento. As curvas não devem, portanto, ser lidas como proposta de configuração de uso, e sim como medida do dano que cada estratégia de alocação causa por si só. A Seção 6.5 mostra que esse dano é, em boa parte, reversível.

A segunda é que as varreduras foram executadas em sessões distintas do ambiente Kaggle, e as medições de **custo dependem da sessão**. O mesmo modelo base registrou 40,5 ms por janela em uma sessão, 54,0 ms em outra e 46,3 ms em uma terceira; o consumo de energia do modelo base variou de forma análoga, entre 1176 e 1572 mWh por avaliação completa do conjunto de teste. Por essa razão, a energia é sempre expressa pela redução relativa ΔE (Equação 4.1), calculada em relação ao modelo base medido na mesma sessão, e nunca em valores absolutos; o tempo segue a mesma regra. As emissões de CO_2, que dependem adicionalmente do fator de carbono da rede elétrica do *datacenter* — que também variou entre sessões —, não são comparadas entre varreduras.

Os resumos por configuração (Seção 4.1.3) usam as taxas de 10% a 50%. O corte em 50% segue o critério daquela seção: até essa taxa, nenhuma camada atinge o teto $r_{\max} = 0{,}95$ em nenhuma das alocações com análise de sensibilidade, ao passo que a 60% uma camada já o atinge na poda por magnitude e duas na estruturada, com $\beta = 1{,}0$. O corte coincide com o ponto a partir do qual todas as configurações estão inutilizáveis: a 60%, a menor perplexity entre as oito avaliadas é de 1524,55, cerca de 61 vezes a do modelo base. As taxas de 60% a 90% continuam reportadas nas tabelas, mas não entram nas médias.

6.2 Custo Computacional e Consumo de Energia

Esta seção responde à primeira pergunta do trabalho: em que medida a redução de parâmetros se converte em redução real de custo. A Tabela 11 apresenta as grandezas calculadas — parâmetros, tamanho e FLOPs —, e a Tabela 12, a grandeza medida: a redução relativa de energia.

Na poda por magnitude, o resultado é negativo: **o custo não cai**. Entre 0 % e 90 %, o número de parâmetros não nulos cai de 124,4 M para 48,0 M — uma redução de 61 % —, enquanto o tamanho em memória e os FLOPs permanecem rigorosamente constantes: 474,70 MB e 126,58 G em todas as dez taxas, valores idênticos dígito a dígito. A explicação é direta: a poda não estruturada substitui pesos por zeros, mas não remove nada da arquitetura. Os tensores mantêm as mesmas dimensões, e a GPU multiplica os zeros exatamente como multiplicava os valores originais. O ganho de 61 % em parâmetros é contábil, não físico.

As grandezas medidas comportam-se de modo ligeiramente diferente das calculadas: ΔE cresce de forma pequena e monótona ao longo da varredura, até cerca de 9 % a 90 %, e o tempo de inferência cai 5,4 % entre os extremos (de 53,96 para 51,04 ms, alocação uniforme). Essa deriva é da ordem da variação observada entre execuções do mesmo modelo base — de 40,5 a 54,0 ms e de 1176 a 1572 mWh conforme a sessão (Seção 6.1) — e não pode ser atribuída à poda, uma vez que a arquitetura executada é a mesma

Tabela 11 – Custo calculado dos modelos podados, por taxa de poda. Na poda por magnitude, os parâmetros são os não nulos, e os valores referem-se à alocação uniforme; a não uniforme produz os mesmos valores, pois nenhuma das duas altera a arquitetura. Na poda estruturada, a taxa de poda é a fração de estruturas removidas, e os valores referem-se à alocação não uniforme; as demais alocações removem frações de parâmetros que diferem desta em até 2,1 pontos percentuais.

	Parâmetros (M)		**Tamanho (MB)**		**FLOPs (G)**	
Taxa de poda	**Magn.**	**Estrut.**	**Magn.**	**Estrut.**	**Magn.**	**Estrut.**
0 %	124,4	124,4	474,7	474,7	126,6	126,6
10 %	115,9	116,0	474,7	442,6	126,6	118,0
20 %	107,5	107,6	474,7	410,5	126,6	109,3
30 %	99,0	99,0	474,7	377,6	126,6	100,5
40 %	90,5	90,6	474,7	345,5	126,6	91,9
50 %	82,0	81,9	474,7	312,6	126,6	83,1
60 %	73,5	73,5	474,7	280,5	126,6	74,5
70 %	65,0	65,1	474,7	248,3	126,6	65,9
80 %	56,5	56,5	474,7	215,5	126,6	57,0
90 %	48,0	48,1	474,7	183,3	126,6	48,4

em todas as taxas. Serve, na verdade, como calibração do ruído de medição: qualquer efeito de poda inferior a cerca de 10 % em tempo ou energia está abaixo do limiar de detecção deste protocolo. Na Tesla T4 utilizada, sem suporte de *hardware* ou de *kernels* para esparsidade, a poda não estruturada não entrega ganho de eficiência algum.

Na poda estruturada, ao contrário, **o custo cai, e cai proporcionalmente aos parâmetros**: a 90 % de estruturas removidas, com a alocação não uniforme, o tamanho em memória cai 61 %, os FLOPs 62 %, a energia 59 % e o tempo de inferência 56 %, acompanhando a redução de 61 % no número de parâmetros. A redução de energia já supera o limiar de detecção a 30 % (13,5 % na alocação não uniforme) e, a 90 %, é quase seis vezes maior que ele. As duas estratégias formam, juntas, a resposta à primeira pergunta: a redução de parâmetros só se converte em redução de consumo quando a poda remove estruturas inteiras da arquitetura, e não quando apenas as zera.

As alocações com análise de sensibilidade preservam esse comportamento, o que era esperado, uma vez que alteram a distribuição da poda, e não sua natureza. Na poda por magnitude, ΔE permanece abaixo do limiar de detecção em todas as alocações. Na poda estruturada, as quatro alocações têm ΔE próximo na mesma taxa: a 50 %, 28,6 % (não uniforme), 34,3 % (uniforme), 32,6 % ($\beta = 1{,}0$) e 33,1 % ($\beta = 0{,}5$). As diferenças, de até 6,3 pontos percentuais, são da ordem da variação do próprio modelo base dentro de um mesmo arquivo de resultados, que mediu 1,176 Wh na série não uniforme e 1,261 Wh

Tabela 12 – Redução relativa de energia ΔE (%, Equação 4.1) em relação ao modelo base medido na mesma sessão. Na poda por magnitude, os valores estão abaixo do limiar de detecção do protocolo, de cerca de 10%. β é o expoente de intensidade da Equação 5.2, que controla o quanto a alocação segue o perfil de sensibilidade: com $\beta = 1{,}0$ o perfil é seguido integralmente, e com $\beta = 0{,}5$ as diferenças entre camadas são atenuadas.

		Taxa de poda								
Análise	**Alocação**	10 %	20 %	30 %	40 %	50 %	60 %	70 %	80 %	90 %
Poda por magnitude										
Sem análise de sensibilidade	Não uniforme	1,7	2,6	2,8	3,7	4,1	5,3	6,2	7,7	9,0
	Uniforme	2,1	3,0	2,4	3,1	4,4	5,0	5,9	7,4	8,9
Com análise de sensibilidade	$\beta = 1{,}0$	3,8	3,8	3,9	4,7	5,8	5,8	6,4	6,9	6,8
	$\beta = 0{,}5$	3,5	3,5	3,8	4,3	5,0	5,6	6,3	6,9	7,1
Poda poor Normal L1										
Sem análise de sensibilidade	Não uniforme	2,5	5,5	13,5	21,4	28,6	36,2	44,2	51,1	58,7
	Uniforme	5,3	11,8	17,6	24,8	34,3	40,9	45,8	54,5	60,0
Com análise de sensibilidade	$\beta = 1{,}0$	3,4	11,0	18,1	25,0	32,6	39,9	47,1	54,4	61,6
	$\beta = 0{,}5$	2,6	10,0	17,3	24,5	33,1	40,5	46,9	55,0	61,6

na uniforme, 7 % de diferença. A alocação não uniforme registra o menor ΔE em todas as taxas, mas essa diferença não se separa da variação de medição, e não é possível atribuir a nenhuma alocação vantagem de energia.

6.3 Perfil de Sensibilidade por Camada

Antes da comparação de qualidade entre as alocações, esta seção apresenta o perfil de sensibilidade que alimenta a alocação com análise de sensibilidade, levantado conforme a Seção 5.3.1: para cada uma das 12 camadas do GPT-2 *small* e para cada estratégia, poda-se **apenas** aquela camada à taxa-sonda, sem *fine-tuning*, e a degradação Δ_ℓ (Equação 5.1) mede o aumento logarítmico da perplexity em relação ao modelo base. O levantamento foi feito a duas taxas-sonda, 50% e 30%; as alocações usam apenas o perfil de 50%, e o de 30% serve de verificação (Seção 6.3.5).

6.3.1 Perfil Obtido

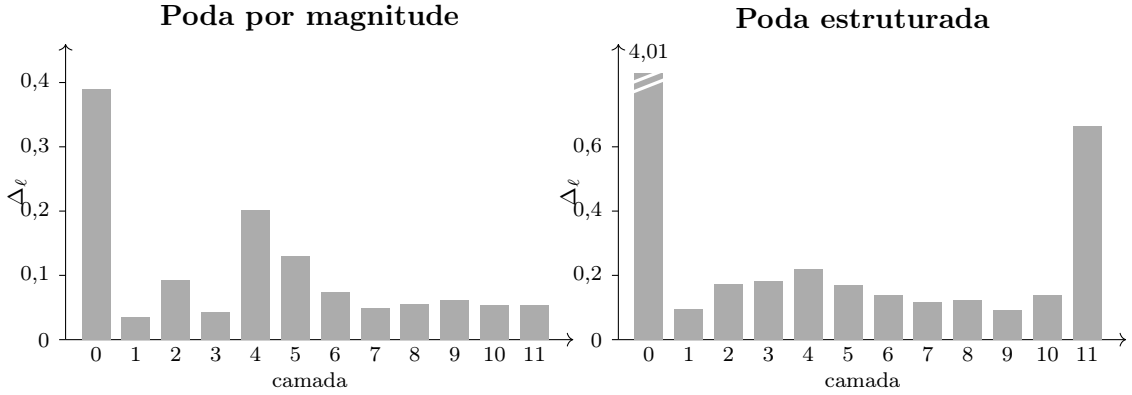
A Tabela 13 apresenta os dois levantamentos, e a Figura 10 representa graficamente o de 50%.

O primeiro resultado confirma a premissa da técnica: a sensibilidade está longe de ser uniforme. Sob poda por magnitude, a camada mais sensível degrada o modelo 11,3 vezes mais que a mais tolerante; sob poda estruturada, 42,9 vezes mais, à taxa-sonda de

Tabela 13 – Perfil de sensibilidade por camada do GPT-2 *small* no WikiText-2: degradação Δ_ℓ (Equação 5.1) causada pela poda exclusiva da camada indicada, sem *fine-tuning*, a duas taxas-sonda. Entre parênteses, o posto da camada na ordenação de sensibilidade (1 = mais sensível). As alocações usam apenas o perfil de 50 %.

	Poda por magnitude		**Poda estruturada**	
Camada	**Sonda 30 %**	**Sonda 50 %**	**Sonda 30 %**	**Sonda 50 %**
0	0,041 (1)	0,390 (1)	3,423 (1)	4,009 (1)
1	0,007 (12)	0,035 (12)	0,159 (3)	0,094 (11)
2	0,012 (7)	0,093 (4)	0,130 (7)	0,173 (5)
3	0,007 (11)	0,043 (11)	0,143 (5)	0,183 (4)
4	0,039 (2)	0,202 (2)	0,156 (4)	0,218 (3)
5	0,035 (3)	0,130 (3)	0,093 (8)	0,169 (6)
6	0,016 (4)	0,074 (5)	0,132 (6)	0,138 (7)
7	0,008 (10)	0,049 (10)	0,053 (12)	0,118 (10)
8	0,011 (8)	0,055 (7)	0,065 (10)	0,122 (9)
9	0,014 (5)	0,061 (6)	0,060 (11)	0,093 (12)
10	0,008 (9)	0,054 (9)	0,088 (9)	0,138 (8)
11	0,013 (6)	0,054 (8)	0,539 (2)	0,663 (2)
Razão máx./mín.	6,1×	11,3×	65,1×	42,9×

Figura 10 – Degradação Δ_ℓ causada pela poda isolada de cada camada, à taxa-sonda de 50 %. Note-se que as escalas verticais diferem entre os dois gráficos; na poda estruturada, a barra da camada 0 excede o eixo e está truncada.



Fonte: Elaborada pelo autor.

50%. Tratar as 12 camadas como intercambiáveis — que é exatamente o que a alocação uniforme faz — ignora uma diferença de uma ordem de grandeza no custo de podar cada uma delas.

6.3.2 A Camada 0 como Gargalo

O segundo resultado é a magnitude do papel da primeira camada. Nas duas estratégias ela é a mais sensível, mas o efeito é qualitativamente distinto no caso estruturado: remover metade das cabeças de atenção e dos neurônios MLP **apenas da camada 0** eleva a perplexity de 25,17 para 1386,43, ou seja, 55 vezes o valor do modelo base. Para dimensionar esse número, a poda estruturada uniforme a 50 % — que poda *todas* as 12 camadas — atinge perplexity 4573,00. Em escala logarítmica, a camada 0 sozinha responde por $4{,}01/5{,}20 \approx 77\,\%$ de toda a degradação produzida pela poda uniforme do modelo inteiro.

A interpretação é coerente com o papel funcional da camada 0. É nela que as representações deixam de ser a soma direta de *embeddings* de token e de posição e passam a ser contextualizadas pela primeira vez; qualquer informação descartada ali não tem como ser recuperada pelas camadas subsequentes, que operam sobre um sinal já degradado. Trata-se, portanto, de um erro que se propaga por toda a pilha, ao contrário de um erro cometido nas camadas intermediárias.

Na poda estruturada observa-se ainda um segundo ponto crítico na outra extremidade: a camada 11, imediatamente anterior à cabeça de linguagem, apresenta $\Delta_{11} = 0{,}663$, quase cinco vezes a mediana das camadas intermediárias. O perfil estruturado tem, assim, formato aproximado de "U": as bordas da pilha são críticas e o miolo é comparativamente barato. Esse padrão não se repete na poda por magnitude, cujo perfil decai após um pico inicial e mantém as últimas camadas entre as mais tolerantes.

6.3.3 Os Perfis Dependem da Estratégia

O terceiro resultado tem consequência metodológica direta: os dois perfis **não** são o mesmo. A correlação de postos de Spearman entre eles é $\rho = 0{,}50$ — há concordância, mas parcial. As duas estratégias coincidem em eleger a camada 0 como a mais crítica e em considerar as camadas 1 e 7 entre as mais tolerantes, e divergem em praticamente todo o resto: a camada 11 é a segunda mais sensível sob poda estruturada e apenas a oitava sob poda por magnitude; a camada 3 é a segunda mais tolerante sob magnitude e a quarta mais sensível sob poda estruturada.

A implicação prática é que não existe um perfil de sensibilidade único do GPT-2. Sensibilidade é uma propriedade do par (camada, estratégia de poda), não da camada isoladamente, e o perfil precisa ser levantado separadamente para cada estratégia — como foi feito aqui — sob pena de se distribuir a poda com um mapa que pertence a outro método. Esse achado também oferece uma explicação para a inversão entre as alocações sem análise de sensibilidade observada na Seção 6.4: como magnitude de peso e norma de estrutura respondem a aspectos diferentes da importância de uma camada, é esperado

que a alocação não uniforme (que decide com base nessas grandezas) acerte em um caso e erre no outro.

6.3.4 Da Sensibilidade à Alocação

O perfil é um diagnóstico; para virar estratégia, precisa ser convertido em uma taxa de poda por camada. Essa conversão é a Equação 5.2, apresentada na Seção 5.3.2: a taxa de cada camada é proporcional à sua tolerância — o inverso da degradação medida — elevada ao expoente β, escalada por um fator único obtido por bisseção de modo que a taxa de poda pretendida seja respeitada, e limitada pelo teto $r_{\max} = 0{,}95$. Interessa aqui apenas o que ela produz na prática.

A Tabela 14 mostra as taxas que a Equação 5.2 produziu para uma taxa de poda de 50 % com $\beta = 1$. O contraste com a alocação uniforme é acentuado: sob poda estruturada, a camada 0 recebe 2 % de poda e a camada 1 recebe 84 %, enquanto a alocação uniforme aplicaria 50 % a ambas.

Tabela 14 – Taxas de poda por camada efetivamente aplicadas pela Equação 5.2 para taxa de poda de 50 % e $\beta = 1{,}0$ (coluna `taxas_por_camada` dos registros experimentais). β é o expoente de intensidade da equação, que controla o quanto a alocação segue o perfil de sensibilidade; com $\beta = 1{,}0$, o perfil é seguido integralmente. A alocação uniforme corresponderia a 50 % em todas as camadas.

Camada	0	1	2	3	4	5	6	7	8	9	10	11
Magnitude (%)	8	94	35	75	16	25	44	67	59	53	61	61
Estruturada (%)	2	84	46	43	36	47	57	67	64	85	57	12

6.3.5 Robustez do Perfil à Taxa-Sonda

O perfil que alimenta as alocações foi levantado a uma taxa-sonda de 50 %. Como a escolha dessa taxa é arbitrária, cabe verificar se a ordenação de sensibilidade que dela resulta é uma propriedade das camadas ou um artefato do regime de poda em que a sonda opera. Para isso, o perfilamento completo foi repetido a uma taxa-sonda de 30 %, nas duas estratégias, o que fornece uma réplica independente da fase 1; a Tabela 13 traz os dois levantamentos lado a lado.

A correlação de postos de Spearman entre as duas sondas é $\rho = 0{,}944$ na poda por magnitude e $\rho = 0{,}713$ na poda estruturada. A ordenação é, portanto, substancialmente estável — e os achados que sustentam a estratégia otimizada sobrevivem à troca de sonda. Na magnitude, as três camadas mais sensíveis (0, 4 e 5) e as três mais tolerantes (1, 3 e 7) são **as mesmas** nos dois levantamentos. Na estruturada, a camada 0 e a camada 11 ocupam os dois primeiros postos em ambos, de modo que o formato em "U" discutido na

Seção 6.3.2 não depende da taxa-sonda; a camada 0 responde por 65,5 % da soma dos Δ_ℓ a 50 % e por 67,9 % a 30 %.

A estabilidade é menor na poda estruturada, e a divergência concentra-se em uma camada: a camada 1 salta do 11º posto na sonda de 50 % para o 3º na de 30 %. A leitura mais plausível é que o miolo da pilha tem sensibilidades próximas entre si — os Δ_ℓ das camadas 1 a 10 ficam todos entre 0,05 e 0,22 —, de modo que pequenas variações de medição reordenam postos sem alterar a estrutura do perfil. Isso é coerente com o comportamento do expoente β reportado na Seção 6.4.4: o que a alocação efetivamente aproveita é o sinal forte das bordas, não a ordenação fina do miolo.

6.3.6 Limitações do Perfilamento

Três limitações do procedimento devem ser explicitadas, pois condicionam a leitura dos resultados da alocação com análise de sensibilidade.

A primeira é que, embora a verificação da seção anterior mostre que a ordenação é estável entre 30 % e 50 %, ambas as taxas pertencem ao mesmo regime intermediário de poda. Nada garante que a ordenação se mantenha em regimes extremos — poda muito branda, em que a degradação de todas as camadas se aproxima do ruído de medição, ou muito agressiva, em que várias camadas já colapsaram. Estender a verificação a essas faixas tem custo proporcional: cada ponto de perfil exige uma avaliação completa de perplexity.

A segunda, e mais relevante, é que a sonda mede o efeito de cada camada **isoladamente**, ignorando as interações entre elas. Os dados do próprio experimento mostram que essa aproximação é imperfeita: a soma dos Δ_ℓ individuais sob poda por magnitude é 1,238, ao passo que a poda uniforme simultânea de todas as camadas a 50 % produz degradação logarítmica de 2,934 — mais que o dobro. A degradação é fortemente superaditiva, isto é, os erros introduzidos em camadas distintas se compõem em vez de simplesmente se somarem. O perfil deve, por isso, ser lido como uma ordenação relativa de importância, e não como um modelo preditivo da degradação de uma configuração completa.

A terceira é que todas as medições são *one-shot*, sem *fine-tuning* de recuperação. Camadas que parecem frágeis nesse regime poderiam ser recuperáveis com retreinamento, o que eventualmente alteraria a alocação ótima. A opção pelo regime *one-shot* é deliberada e coerente com o objetivo do trabalho — isolar o efeito da poda do efeito do retreinamento —, mas restringe a generalidade das conclusões.

Nenhuma dessas limitações invalida o achado principal desta seção, que é robusto às três: sob qualquer leitura, as camadas do GPT-2 diferem entre si por mais de uma ordem de grandeza no custo de serem podadas, e essa diferença é informação que as alocações uniforme e não uniforme simplesmente não utilizam. Se essa informação se

converte em ganho efetivo na fronteira entre compressão e qualidade é o que a seção seguinte verifica.

6.4 Qualidade Preditiva

Esta seção responde à segunda pergunta do trabalho: se a alocação com análise de sensibilidade melhora o compromisso entre compressão e qualidade em relação às alocações sem essa análise. As Tabelas 15 e 16 apresentam a perplexity das quatro alocações em cada taxa de poda. A alocação com análise de sensibilidade foi avaliada com dois valores do expoente β, 1,0 e 0,5, sobre o mesmo perfil. Um terceiro valor, $\beta = 0$, não é uma alocação candidata, e sim um controle: nele a regra atribui a mesma taxa a todas as camadas e deve reproduzir a alocação uniforme (Seção 6.4.3).

6.4.1 Poda por Magnitude

Tabela 15 – Perplexity da poda por magnitude, sem retreinamento, nas quatro alocações. Em negrito, o menor valor de cada taxa. β é o expoente de intensidade da Equação 5.2, que controla o quanto a alocação segue o perfil de sensibilidade: com $\beta = 1{,}0$ o perfil é seguido integralmente, e com $\beta = 0{,}5$ as diferenças entre camadas são atenuadas.

	Sem análise de sensibilidade		**Com análise de sensibilidade**	
Taxa de poda	**Não uniforme**	**Uniforme**	$\boldsymbol{\beta = 1{,}0}$	$\boldsymbol{\beta = 0{,}5}$
0 %	25,17 (modelo base)			
10 %	**25,40**	25,47	25,44	25,44
20 %	26,87	27,22	26,79	**26,57**
30 %	40,23	36,42	34,62	**31,20**
40 %	165,20	104,82	193,83	**57,30**
50 %	1096,50	473,28	1026,09	**447,57**
60 %	5121,25	2004,20	**1524,55**	2171,79
70 %	9371,16	6891,85	**1853,30**	2805,39
80 %	8847,27	10871,00	**2747,56**	3715,68
90 %	**4612,69**	13996,88	10398,10	7616,63

Nas alocações sem análise de sensibilidade, a curva de perplexity apresenta um joelho acentuado em torno de 30 %. Até 20 % a poda é praticamente gratuita (acréscimo de 0,2 a 2,1 pontos de perplexity); a partir de 40 % a degradação torna-se explosiva. A região utilizável em regime *one-shot* é, portanto, limitada a taxas de até 20 %.

A comparação entre as duas alocações sem análise de sensibilidade revela um cruzamento duplo: a não uniforme apresenta valores ligeiramente menores até 20 %, a uniforme domina claramente entre 30 % e 70 % — exatamente a faixa em que a escolha de

alocação teria consequência prática — e a não uniforme volta a apresentar valores menores em 80 % e 90 %, região em que ambos os modelos já estão destruídos (perplexity acima de 4600) e a comparação perde sentido. Na faixa que importa, portanto, a alocação uniforme é preferível à não uniforme. Esse é um resultado contraintuitivo: a alocação não uniforme é a que distribui a poda com base em uma medida de importância — a magnitude do peso — e ainda assim perde para a alocação que ignora qualquer medida de importância. Trata-se do primeiro indício de que a magnitude do peso é um *proxy* pobre para a importância de um parâmetro.

A alocação com análise de sensibilidade vence as duas em sete das nove taxas, de 20 % a 80 %, e as margens são substanciais na faixa de interesse. Em 30 %, a perplexity cai de 36,42 (melhor alocação sem análise de sensibilidade) para 31,20 — uma redução de 14 %. Em 40 %, de 104,82 para 57,30, ou seja, a degradação é praticamente **reduzida à metade** na mesma taxa de poda. Em 50 %, a vantagem persiste, ainda que modesta (447,57 contra 473,28). De 60 % a 80 %, a configuração com $\beta = 1{,}0$ produz perplexities de 1,3 a 3,7 vezes menores que a melhor alocação sem análise de sensibilidade — embora, nesse regime, todos os modelos já estejam degradados a ponto de a comparação ter interesse mais teórico que prático. Na média geométrica de 10 % a 50 % (Seção 4.1.3), a melhor configuração com análise de sensibilidade ($\beta = 0{,}5$, 55,80) fica cerca de 15 % abaixo da melhor sem ela (uniforme, 66,00).

As derrotas ocorrem nos extremos. Em 10 %, a alocação não uniforme (25,40) fica 0,04 abaixo das duas configurações com análise de sensibilidade (25,44), diferença sem consequência prática. Em 90 %, a não uniforme apresenta o menor valor, mas, como a perplexity de todas as configurações ultrapassa 4600, a ordenação entre modelos igualmente inservíveis não carrega significado.

6.4.2 Poda Estruturada

Na poda estruturada, o preço da redução de custo é severo em regime *one-shot*. Já com 10 % de estruturas removidas, a perplexity da alocação não uniforme salta de 25,17 para 356,20 — compare-se com 25,40 na poda por magnitude à mesma taxa. **Não existe região gratuita** na poda estruturada sem retreinamento, o que é coerente com o procedimento original de Li et al. (2017), em que a poda é sempre seguida de *fine-tuning*.

A inversão observada na magnitude repete-se ao contrário: entre as alocações sem análise de sensibilidade, é a **não uniforme** que domina na poda estruturada, com exceção da taxa de 20 %, e a uniforme colapsa em taxas altas (perplexity de 53.313 a 80 % e de 827.316 a 90 %, contra 7620 e 5823 da não uniforme). Somado ao resultado da poda por magnitude, isso estabelece que **nenhuma das duas alocações sem análise de sensibilidade vence nas duas estratégias** — a constatação que motiva a análise de sensibilidade.

Tabela 16 – Perplexity da poda estruturada, sem retreinamento, nas quatro alocações; a taxa de poda é a fração de estruturas removidas. Em negrito, o menor valor de cada taxa. β é o expoente de intensidade da Equação 5.2, que controla o quanto a alocação segue o perfil de sensibilidade: com $\beta = 1{,}0$ o perfil é seguido integralmente, e com $\beta = 0{,}5$ as diferenças entre camadas são atenuadas.

	Sem análise de sensibilidade		**Com análise de sensibilidade**	
Taxa de poda	**Não uniforme**	**Uniforme**	$\boldsymbol{\beta = 1{,}0}$	$\boldsymbol{\beta = 0{,}5}$
0 %	25,17 (modelo base)			
10 %	356,20	481,13	**124,29**	215,83
20 %	2102,06	1484,89	**371,07**	717,19
30 %	2413,52	5467,56	**724,53**	923,65
40 %	2434,92	10486,71	**1301,15**	9489,87
50 %	2402,58	4573,00	**2327,59**	7922,81
60 %	**2957,26**	5799,76	5393,15	12322,05
70 %	**4635,36**	12249,58	10130,33	103463,60
80 %	**7620,02**	53313,38	8891,77	203995,84
90 %	5822,89	827316,19	5353,85	**4830,24**

A comparação entre os dois tipos de estrutura acrescenta uma assimetria. Remover cabeças de atenção é notavelmente mais tolerável que remover neurônios MLP: com 129 das 144 cabeças removidas (90 %), a perplexity fica em 781, ao passo que a remoção equivalente de neurônios MLP produz valores acima de 3900. A curva das cabeças é, ainda, não monotônica, com mínimo local em torno de 30 % (perplexity 162, inferior aos 237 obtidos com apenas 10 % removidas) — eco direto do achado de Michel, Levy e Neubig (2019) sobre a redundância das cabeças de atenção. Em contrapartida, os MLPs concentram cerca de dois terços dos parâmetros podáveis, de modo que a poda restrita a cabeças tem alcance limitado como estratégia de compressão.

A alocação com análise de sensibilidade, com $\beta = 1{,}0$, obtém a menor perplexity em todas as taxas de 10 % a 50 %. A vantagem é máxima entre 20 % e 30 %: em 20 %, a perplexity cai de 1484,89 (melhor alocação sem análise de sensibilidade) para 371,07, um fator de **quatro**; em 30 %, de 2413,52 para 724,53, um fator de 3,3. Em 10 %, o fator é de 2,9 (356,20 contra 124,29). A partir daí, a vantagem diminui: o fator é de 1,9 em 40 % (2434,92 contra 1301,15), e a diferença é marginal em 50 % (2402,58 contra 2327,59). Na média geométrica de 10 % a 50 %, a perplexity cai de 1602,62 (não uniforme) para 632,46, um fator de 2,5. Considerando que não existe região gratuita para a poda estruturada *one-shot*, reduzir a perplexity a um quarto na mesma taxa de poda é o resultado mais expressivo deste capítulo.

Uma ressalva quantitativa é necessária. Como a remoção de estruturas é discreta,

as taxas fracionárias por camada não são atingíveis exatamente, e a alocação com análise de sensibilidade acaba removendo uma fração de parâmetros ligeiramente menor que a não uniforme no mesmo alvo: em 10 %, esparsidade real de 9,20 % contra 9,90 %; em 30 %, 29,01 % contra 29,95 %. Parte da vantagem observada deve-se, portanto, a um corte marginalmente menor. A diferença é de menos de um ponto percentual de esparsidade, ao passo que a diferença de perplexity chega a um fator de quatro, de modo que a explicação não se sustenta como causa principal — mas o efeito existe e deve ser declarado.

De 60 % a 80 %, a ordenação se inverte e a alocação não uniforme volta a vencer; em 90 %, a perplexity de todas as configurações supera 4800, e a ordenação perde significado. A causa da inversão é identificável nas taxas alocadas: a partir de 60 %, um número crescente de camadas satura no teto $r_{\max} = 0{,}95$ — duas camadas em 60 %, quatro em 70 %, oito em 80 % e onze em 90 %. Saturadas as camadas, a alocação deixa de discriminar entre elas e degenera em algo próximo da poda uniforme sobre o subconjunto saturado, ao mesmo tempo em que concentra uma pressão crescente sobre as poucas camadas ainda livres. A alocação com análise de sensibilidade, portanto, **só é informativa enquanto a taxa de poda couber dentro do teto por camada**, o que justifica o corte das médias em 50 % (Seção 6.1). Esse é um limite intrínseco de qualquer alocação proporcional com teto, e não um defeito de implementação.

6.4.3 O Controle $\beta = 0$

Antes de interpretar a ablação, cabe verificar se a regra de alocação está correta. Com $\beta = 0$ o fator $\Delta_\ell^{-\beta}$ da Equação 5.2 vale 1 para toda camada, de modo que todas recebem a mesma taxa e a alocação deve coincidir com a varredura uniforme correspondente. É um teste de sanidade barato, pois reaproveita o perfil já levantado.

Na poda estruturada a coincidência é **exata**: nas dez taxas de poda, a alocação com $\beta = 0$ reproduz a perplexity da varredura uniforme até a última casa decimal registrada — 5467,5635 em 30 %, 4573,0020 em 50 % e 827.316,1875 em 90 %, para citar três níveis. A identidade confirma que a conversão de perfil em taxas, a bisseção do fator de escala e a aplicação das taxas por camada estão implementadas corretamente: o que a alocação com análise de sensibilidade obtém a mais, nas seções anteriores, vem do perfil, e não de alguma diferença espúria de procedimento.

Na poda por magnitude a coincidência **não** ocorre, e a razão é uma diferença deliberada de implementação que merece registro. A varredura uniforme decide um limiar de magnitude para cada matriz de peso isoladamente, ao passo que a alocação por camada decide um limiar único para cada camada, compartilhado pelas quatro projeções que a compõem. As duas produzem a mesma esparsidade agregada — exatamente 30 %, 50 % e assim por diante —, mas distribuída de forma diferente entre as projeções de uma mesma camada, e as perplexities divergem: 473,28 contra 590,25 em 50 %, e 13.996,88 contra

8610,96 em 90 %. A alocação com $\beta = 0$ não é, portanto, a poda uniforme da Seção 6.4.1, e sim uma terceira alocação — "não uniforme dentro da camada" — cuja comparação com as demais fica fora do escopo deste trabalho. Para a poda estruturada, que é a estratégia efetivamente capaz de reduzir consumo, o controle vale integralmente.

6.4.4 Ablação do Expoente β

A comparação entre $\beta = 1{,}0$ e $\beta = 0{,}5$ produziu um resultado que não era antecipado: **o valor adequado de β depende da estratégia**, e depende dela de forma oposta nas duas.

Na poda estruturada, cujo perfil tem razão de 42,9 entre a degradação da camada mais sensível e a da mais tolerante (Tabela 13), $\beta = 1$ obteve perplexity menor que $\beta = 0{,}5$ em todas as taxas de poda até 80 %, e o amortecimento foi francamente prejudicial: em 70 % e 80 %, a configuração com $\beta = 0{,}5$ produziu perplexities de 103.463 e 203.996, 8,4 e 3,8 vezes as da alocação uniforme, a pior das demais nessas taxas. Na poda por magnitude, cujo perfil tem razão de 11,3, ocorreu o inverso na faixa útil: $\beta = 0{,}5$ foi melhor de 20 % a 50 %; de 60 % a 80 %, o expoente pleno passou à frente, e, em 90 %, $\beta = 0{,}5$ voltou a ser melhor (7616,63 contra 10398,10).

Na poda por magnitude, essa diferença decidiu a comparação com as alocações sem análise de sensibilidade. A 40 %, por exemplo, a perplexity foi de 57,30 com $\beta = 0{,}5$, de 104,82 com a alocação uniforme, a melhor sem análise de sensibilidade nessa taxa, e de 193,83 com $\beta = 1$. Apenas com $\beta = 1$, a alocação com análise de sensibilidade teria sido superior às alocações sem ela em cinco das nove taxas de poda, e não em sete (Seção 6.4.1): a 40 % e a 50 %, teria resultado em perplexity maior, e não menor.

Fixar a intensidade em 0,5 teria produzido o problema inverso na poda estruturada. Com $\beta = 1$, a alocação com análise de sensibilidade obteve a menor perplexity em todas as taxas de poda de 10 % a 50 % (Seção 6.4.2); com $\beta = 0{,}5$, ela teria perdido para a alocação não uniforme a 40 % e a 50 %, com perplexity de 9489,87 e 7922,81, contra 2434,92 e 2402,58. São as mesmas duas taxas de poda em que $\beta = 1$ falhou na poda por magnitude. Entre os valores avaliados, portanto, nenhuma intensidade fixa teria servido às duas estratégias.

A perplexity variou com β, embora a quantidade removida praticamente não tenha variado. Na poda por magnitude a 40 %, os modelos obtidos com $\beta = 1$ e com $\beta = 0{,}5$ conservaram os mesmos 90,5 milhões de parâmetros não zerados; na poda estruturada, $\beta = 1$ removeu 54 cabeças e 14.739 neurônios, e $\beta = 0{,}5$, 51 cabeças e 14.740 neurônios. O parâmetro de intensidade altera apenas a distribuição da poda entre as camadas, e a perplexity depende dessa distribuição porque as camadas contribuem de forma desigual para a perda do modelo: a mesma quantidade de elementos degrada mais o modelo

quando removida de uma camada sensível do que de uma tolerante. A diferença é ainda ampliada pela própria métrica. Como a perplexity é a exponencial da perda média por token (Hugging Face, 2026b), diferenças moderadas na perda tornam-se multiplicativas. A 40 %, a perplexity de $\beta = 1$ na poda por magnitude, 193,83, foi 3,4 vezes a de $\beta = 0{,}5$, 57,30, o que corresponde a uma diferença de 1,22 na escala logarítmica da Equação 5.1; na poda estruturada, a razão de 7,3 entre $\beta = 0{,}5$ e $\beta = 1$ corresponde a 1,99.

Os dados por camada indicam por que cada intensidade falhou onde falhou. Na poda por magnitude a 40 %, $\beta = 1$ atribuiu 75,5 % de poda à camada 1, a mais tolerante, taxa 1,5 vez maior que a taxa-sonda de 50 % com que sua tolerância foi medida (Seção 5.3.1); acima dessa taxa, o perfil nada informa sobre o comportamento da camada. Com $\beta = 0{,}5$, a mesma camada recebeu 57,1 %, mais perto da taxa medida. Na poda estruturada, o desvio ocorreu no sentido oposto: $\beta = 0{,}5$ elevou a taxa da camada 0, a mais sensível (Seção 6.3.2), de 1,6 % para 8,4 % a 40 % e de 3,0 % para 14,6 % a 70 %. Uma intensidade alta demais leva as camadas tolerantes a taxas de poda que o perfil não mediu; uma intensidade baixa demais devolve poda à camada que o perfil apontou como crítica.

Qual dos dois desvios custa mais depende de como a degradação de uma camada cresce com a sua taxa de poda, e os dois levantamentos do perfil, a 30 % e a 50 % (Seção 6.3.5), indicam que esse crescimento difere entre as estratégias. Na poda por magnitude, a passagem da taxa-sonda de 30 % para 50 %, um aumento de 1,7 vez, multiplicou a degradação de cada camada por valores entre 3,8 e 9,4: a degradação cresce muito mais depressa que a taxa. Concentrar a poda nas camadas tolerantes, como faz $\beta = 1$, leva-as à faixa em que esse custo mais cresce; atenuar as diferenças, como faz $\beta = 0{,}5$, reparte a poda e reduz a degradação total. O equilíbrio, porém, tem limite: a 40 %, a alocação uniforme, em que todas as camadas recebem a mesma taxa, resultou em perplexity de 104,82, entre os 57,30 de $\beta = 0{,}5$ e os 193,83 de $\beta = 1$. Na poda por magnitude, o melhor resultado ocorreu na intensidade intermediária.

Na poda estruturada, o mesmo aumento da taxa-sonda multiplicou a degradação das camadas por valores entre 0,6 e 2,2, e a camada 0 já degradava o modelo a 30 %: podada sozinha, elevou a perplexity de 25,17 para 772,11. Nessa estratégia, o custo depende mais de qual camada é podada do que de quanto, e o decisivo é preservar a camada 0, o que um β alto garante. A 40 %, a perplexity diminuiu a cada aumento da intensidade: 10.486,71 com $\beta = 0$, 9489,87 com $\beta = 0{,}5$ e 1301,15 com $\beta = 1$. As duas leituras se apoiam em camadas podadas isoladamente e em apenas duas taxas-sonda, e a degradação de camadas podadas em conjunto é superaditiva (Seção 6.3.6). Elas constituem, portanto, uma explicação compatível com os resultados, e não uma demonstração.

Por essas razões, o parâmetro de intensidade mostrou-se parte indispensável da

regra de alocação. O expoente β comporta-se como um parâmetro de confiança no perfil, e a confiança que convém depositar nele depende da estratégia: é maior na poda estruturada, cujo perfil tem razão de 42,9 e é dominado pela camada 0, e menor na poda por magnitude, cujo perfil tem razão de 11,3 e várias camadas de sensibilidade intermediária. Essa confiança só pode ser estimada experimentalmente. Sem o parâmetro, a regra assumiria confiança total em qualquer perfil; com ele, a mesma regra percorre todo o intervalo entre a alocação uniforme, com $\beta = 0$, e o perfil seguido integralmente, com $\beta = 1$, e a intensidade pode ser ajustada a cada estratégia. É esse intervalo, também, que permitiu a verificação com $\beta = 0$ da Seção 6.4.3. Como apenas dois valores foram avaliados, a intensidade ótima de cada estratégia não foi determinada, e sua busca fica como extensão deste trabalho.

6.5 *Fine-tuning* de Recuperação

Todas as varreduras apresentadas até aqui operam em regime *one-shot*. Esta seção reporta a Etapa 4 (Seção 5.4), que incorpora o retreinamento ao experimento para medir quanto da degradação causada pela poda pode ser recuperada: as sete configurações definidas na Seção 5.4.1 foram submetidas ao *fine-tuning* de recuperação, com a perplexity medida antes e depois do retreinamento. A quantidade de retreinamento é idêntica para todas: uma época sobre o conjunto de treino do WikiText-2, 297 passos do otimizador, taxa de aprendizado de 5×10^{-5} e semente fixa. Diferentemente das demais, esta varredura foi executada integralmente em uma única sessão, de modo que suas medições de tempo e energia são diretamente comparáveis entre si.

Tabela 17 – Perplexity antes (*one-shot*) e depois do *fine-tuning* de recuperação (uma época, 297 passos). Sem análise de sensibilidade, a alocação é a uniforme na poda por magnitude e a não uniforme na estruturada; com análise de sensibilidade, usa-se $\beta = 1{,}0$, o expoente de intensidade da Equação 5.2 com o qual a alocação segue integralmente o perfil de sensibilidade. A razão expressa a perplexity pós-retreinamento como múltiplo da do modelo base retreinado, e não do modelo base original.

	Sem análise de sensibilidade			**Com análise de sensibilidade**		
Configuração	***One-shot***	**Pós-FT**	**Razão**	***One-shot***	**Pós-FT**	**Razão**
Denso (controle)	25,17 *one-shot*; 18,68 pós-FT (referência da razão)					
Magnitude 30 %	36,42	20,54	1,10	—	—	—
Magnitude 50 %	473,28	30,27	1,62	—	—	—
Estruturada 10 %	356,20	25,33	1,36	124,29	25,96	1,39
Estruturada 30 %	2413,52	104,78	5,61	724,53	56,08	3,00

6.5.1 O Controle Denso Reenquadra a Leitura

O primeiro resultado da Tabela 17 não envolve poda alguma: o modelo base, submetido à mesma quantidade de retreinamento, tem sua perplexity reduzida de 25,17 para **18,68**. São 26 % de ganho obtidos sem remover um único parâmetro, atribuíveis exclusivamente à adaptação de domínio — o GPT-2 foi pré-treinado no WebText, não no WikiText-2, e o retreinamento o aproxima da distribuição da base de dados de avaliação.

A consequência metodológica é considerável e justifica retroativamente a decisão de incluir o controle. Sem ele, a configuração de magnitude a 30 % pareceria ter *superado* o modelo original: 20,54 contra 25,17, uma leitura que sugeriria que a poda melhora o modelo. A comparação correta é contra 18,68, e diante desse valor a mesma configuração aparece pelo que de fato é — 10 % pior que o modelo base retreinado. As colunas de razão da Tabela 17 adotam essa referência, a única leitura que separa recuperação do dano da poda de mera adaptação à base de dados.

6.5.2 A Recuperação é Substancial, mas Desigual

O retreinamento recupera uma fração expressiva do dano em todas as configurações, e a magnitude dessa recuperação é inversamente proporcional à qualidade do ponto de partida. A poda estruturada a 30 %, que o regime *one-shot* deixara em perplexity 2413,52 — um modelo destruído para qualquer propósito prático —, retorna a 104,78. A poda por magnitude a 50 %, em 473,28, retorna a 30,27, isto é, a 1,62 vez o modelo base retreinado.

Esse comportamento qualifica de forma importante a leitura das seções anteriores. A perplexity *one-shot* mede o dano imediato da poda, mas superestima o dano permanente: configurações que pareciam inutilizáveis são, após uma quantidade modesta de retreinamento, recuperáveis a patamares utilizáveis. A região praticável da poda, delimitada em 20 % de esparsidade na Seção 6.4.1, estende-se consideravelmente quando o retreinamento é incluído.

Registre-se ainda que a hierarquia entre granularidades se mantém: a configuração de magnitude a 30 % atinge a menor perplexity pós-retreinamento de todas as configurações podadas (20,54), mas, pelas razões estabelecidas na Seção 6.2, não reduz tempo, energia nem memória. As configurações estruturadas a 30 %, essas sim, registram 40,82 ms por janela e 1,285 Wh por avaliação completa contra 50,21 ms e 1,588 Wh do modelo base retreinado — uma redução de aproximadamente 19 % em ambos.

6.5.3 O *Fine-tuning* Corrói a Vantagem da Análise de Sensibilidade

O achado mais desconfortável desta varredura diz respeito diretamente à contribuição central do trabalho. As linhas de poda estruturada da Tabela 17 confrontam,

nas mesmas duas taxas de poda, a alocação não uniforme e a alocação com análise de sensibilidade, antes e depois do retreinamento.

Em 10 % de estruturas removidas, a vantagem **desaparece**. Em regime *one-shot*, a alocação com análise de sensibilidade registrava perplexity 124,29 contra 356,20 da alocação não uniforme, uma vantagem de 2,87 vezes. Após o retreinamento, a relação se inverte: 25,96 contra 25,33, com ligeira vantagem para a alocação não uniforme. Em 30 %, a vantagem sobrevive, mas reduzida quase à metade: o fator de 3,33 vezes do regime *one-shot* (724,53 contra 2413,52) torna-se 1,87 vez (56,08 contra 104,78).

A interpretação é que a alocação com análise de sensibilidade otimiza uma quantidade específica — o dano imediato causado pela poda — e o retreinamento repara justamente o tipo de dano que ela evita. Quanto maior a quantidade de retreinamento, menor a importância de haver podado bem. Sob essa leitura, o perfil de sensibilidade é mais valioso quanto mais escassa for a quantidade de retreinamento disponível, e a vantagem tende a crescer com a severidade da poda, o que é consistente com sua persistência em 30 % e seu desaparecimento em 10 %.

O achado não invalida a contribuição, mas delimita seu escopo com precisão: em taxas de poda elevadas, a alocação com análise de sensibilidade continua entregando perplexity aproximadamente duas vezes menor ao mesmo custo computacional — 40,28 ms e 1,307 Wh contra 40,82 ms e 1,285 Wh da alocação não uniforme em 30 %, valores equivalentes dentro da variação de medição. Em taxas de poda baixas, seguidas de retreinamento, a alocação sem análise de sensibilidade é suficiente.

6.5.4 Verificações de Integridade e Custo

Duas verificações confirmam a correção do procedimento. A esparsidade das configurações de magnitude, medida ao final do treinamento, permanece em exatamente 30,0000 % e 50,0000 %, o que confirma que a máscara binária descrita na Seção 5.4 foi corretamente reaplicada após cada passo do otimizador e que o modelo não voltou a ser denso. As esparsidades reais das configurações com análise de sensibilidade, por sua vez, ficam ligeiramente abaixo do alvo (9,20 % e 29,01 % contra 9,90 % e 29,95 % das configurações com alocação não uniforme), diferença atribuível à granularidade discreta das estruturas removidas — uma cabeça de atenção ou um neurônio MLP são indivisíveis. A diferença favorece marginalmente a alocação com análise de sensibilidade e está registrada aqui por transparência, ainda que inferior a um ponto percentual.

Quanto ao custo, o retreinamento consome 7,33 Wh no modelo base, contra 1,59 Wh de uma avaliação completa do mesmo modelo — aproximadamente 4,6 vezes. Trata-se, porém, de um custo pago uma única vez, ao passo que a economia por inferência da poda estruturada se acumula a cada uso. A configuração estruturada a 30 % economiza

0,303 Wh por avaliação completa do conjunto de teste (1,285 contra 1,588 Wh), de modo que o custo do próprio retreinamento se amortiza em aproximadamente 24 avaliações equivalentes — um volume trivial para um modelo em uso continuado. Cabe explicitar a unidade: o consumo é medido em torno do bloco de avaliação inteiro, que percorre todo o conjunto de teste por janela deslizante, e não em torno de uma janela individual. Converter a economia para base por janela exigiria registrar o número de janelas de cada avaliação, o que não foi feito; a amortização fica, portanto, expressa na unidade efetivamente medida.

A limitação principal desta varredura é a quantidade de retreinamento: uma única época. Não é possível afirmar, a partir destes dados, se a erosão da vantagem da alocação com análise de sensibilidade se estabiliza no patamar observado em 30 % ou se prossegue com mais épocas até desaparecer também nessa taxa. Trata-se da verificação mais imediata que este trabalho deixa em aberto.

6.6 Compromisso entre Qualidade e Energia

As seções anteriores trataram o custo e a qualidade separadamente. A Tabela 18 combina as duas grandezas nos indicadores da Seção 4.1.3.

O primeiro resultado é que **nenhuma configuração podada supera o modelo base em eficiência relativa**: η fica abaixo de 1 em todas, com e sem retreinamento, porque a perplexity cresce mais depressa do que a energia cai. Na poda estruturada sem retreinamento, a configuração de melhor resultado — com análise de sensibilidade, $\beta = 1{,}0$ — economiza em média 18,0 % de energia ao preço de uma perplexity 25 vezes maior, e seu η é de 0,049. Após o *fine-tuning*, o maior η da poda estruturada é o da alocação não uniforme a 10 % (0,773), que economiza 4,6 % de energia com perplexity 36 % acima da do modelo base retreinado. Na poda por magnitude, os valores de η são mais altos, mas não por eficiência: como ΔE está abaixo do limiar de detecção (Seção 6.2), η reflete apenas a perplexity e o ruído de medição.

Dentro de cada estratégia, a alocação com análise de sensibilidade tem o maior η: 0,470 contra 0,393 na poda por magnitude ($\beta = 0{,}5$ contra a uniforme) e 0,049 contra 0,018 na estruturada ($\beta = 1{,}0$ contra a não uniforme). Como ΔE é equivalente entre as alocações (Seção 6.2), a diferença vem da perplexity: **o ganho de qualidade da análise de sensibilidade não tem custo adicional de energia**. Após o *fine-tuning*, a vantagem em η se mantém a 30 % (0,405 contra 0,220) e desaparece a 10 % (0,744 contra 0,773), acompanhando a perplexity (Seção 6.5.3).

O ponto de eficiência é o indicador mais restritivo. Sem retreinamento, só a poda por magnitude tem S_E^*: 10 %, em todas as alocações; a 20 %, mesmo a melhor configuração (26,57, com $\beta = 0{,}5$) excede o limite de 26,43. Na poda estruturada, nenhuma taxa fica

Tabela 18 – Indicadores de compromisso entre qualidade e energia (Seção 4.1.3). Sem retreinamento, cada configuração é resumida pelas médias de 10 % a 50 % — geométrica para a perplexity e aritmética para ΔE —, com η calculado a partir delas; S_E^* é a maior taxa com perplexity até 5 % acima da do modelo base (26,43). Após o *fine-tuning*, os valores são por configuração, e a referência é o modelo base retreinado; nenhuma configuração fica dentro do limite de 5 % (19,62). β é o expoente de intensidade da Equação 5.2, que controla o quanto a alocação segue o perfil de sensibilidade.

Configuração	**PPL**	**ΔE (%)**	**η**	**S_E^***
Sem retreinamento (médias de 10 % a 50 %)				
Modelo base	25,17	0,0	1,000	—
Poda por magnitude				
Sem análise de sensibilidade — não uniforme	86,97	3,0	0,298	10 %
Sem análise de sensibilidade — uniforme	66,00	3,0	0,393	10 %
Com análise de sensibilidade — $\beta = 1{,}0$	85,96	4,4	0,306	10 %
Com análise de sensibilidade — $\beta = 0{,}5$	55,80	4,0	0,470	10 %
Poda estruturada				
Sem análise de sensibilidade — não uniforme	1602,62	14,3	0,018	—
Sem análise de sensibilidade — uniforme	2847,86	18,7	0,011	—
Com análise de sensibilidade — $\beta = 1{,}0$	632,46	18,0	0,049	—
Com análise de sensibilidade — $\beta = 0{,}5$	1607,97	17,5	0,019	—
Após o *fine-tuning* de recuperação				
Modelo base retreinado	18,68	0,0	1,000	—
Poda por magnitude				
Sem análise de sensibilidade — uniforme, 30 %	20,54	0,8	0,917	—
Sem análise de sensibilidade — uniforme, 50 %	30,27	2,2	0,631	—
Poda estruturada				
Sem análise de sensibilidade — não uniforme, 10 %	25,33	4,6	0,773	—
Com análise de sensibilidade — $\beta = 1{,}0$, 10 %	25,96	3,2	0,744	—
Sem análise de sensibilidade — não uniforme, 30 %	104,78	19,1	0,220	—
Com análise de sensibilidade — $\beta = 1{,}0$, 30 %	56,08	17,7	0,405	—

dentro do limite — a menor perplexity, 124,29, é quase cinco vezes a do modelo base —, em coerência com a ausência de região gratuita (Seção 6.4.2). Após o *fine-tuning*, nenhuma configuração fica dentro de 5 % do modelo base retreinado; a mais próxima, a magnitude a 30 %, fica 10 % acima (20,54 contra 18,68). Com o limite de 5 %, fixado antes da análise, o trabalho não identifica uma taxa de poda estruturada que preserve a qualidade; o que ele identifica é quanto da qualidade a análise de sensibilidade preserva em cada taxa.

6.7 Síntese dos Resultados

Os experimentos permitem responder às duas perguntas que orientaram o trabalho.

À primeira — se a redução teórica de parâmetros se converte em redução real de consumo — a resposta é condicional à granularidade da poda. A poda não estruturada por magnitude reduz em 61 % os parâmetros não nulos sem alterar o tamanho em memória nem os FLOPs, e sem produzir em tempo ou energia qualquer efeito distinguível do ruído de medição do próprio ambiente: na Tesla T4 utilizada, sem suporte de *hardware* para esparsidade, o ganho é puramente contábil. A poda estruturada, ao remover fisicamente cabeças de atenção e neurônios MLP, converte a mesma redução de 61 % em parâmetros em quedas de 56 % no tempo, 59 % na energia e 62 % nos FLOPs. Para o objetivo declarado deste trabalho — redução do consumo de energia —, apenas a poda estruturada é uma estratégia viável.

À segunda — se a alocação otimizada empurra a fronteira entre compressão e qualidade — a resposta é afirmativa, com escopo delimitado. As camadas do GPT-2 diferem entre si por mais de uma ordem de grandeza no custo de serem podadas, com a camada 0 respondendo isoladamente por cerca de três quartos da degradação da poda uniforme; essa informação, que nenhuma alocação sem análise de sensibilidade utiliza, converte-se em ganho mensurável quando incorporada à distribuição da poda entre as camadas. Na poda estruturada — a estratégia que efetivamente reduz consumo —, a alocação com análise de sensibilidade obtém a menor perplexity em todas as taxas de 10 % a 50 %: por fatores de 2,9 a 4 entre 10 % e 30 %, de 1,9 a 40 % e de forma marginal a 50 %; na média geométrica dessa faixa, por um fator de 2,5, sem diferença de energia distinguível do ruído de medição. O escopo da conclusão é delimitado por três fronteiras: a saturação da alocação em taxas de poda a partir de 60 %; o fato de que o perfil de sensibilidade precisa ser levantado separadamente para cada estratégia de poda, por não ser transferível entre elas; e, sobretudo, a quantidade de retreinamento disponível.

Os indicadores combinados qualificam esse ganho. Nenhuma configuração podada supera o modelo base em eficiência relativa, e nenhuma configuração de poda estruturada fica dentro de 5 % da perplexity do modelo base, com ou sem retreinamento. A análise de sensibilidade não cria, portanto, uma região de poda estruturada sem perda; ela reduz a perda em cada taxa, o que a torna a alocação de maior eficiência relativa em cada estratégia.

A quantidade de retreinamento é a fronteira que mais qualifica a contribuição. O *fine-tuning* de recuperação (Seção 6.5) repara justamente o tipo de dano que a alocação com análise de sensibilidade evita, e por isso corrói sua vantagem: em 10 % de estruturas removidas a vantagem desaparece após uma época de retreinamento, e em 30 % ela se

reduz de um fator de 3,33 para 1,87. A análise de sensibilidade é, portanto, uma contribuição cujo valor cresce com a severidade da compressão e decresce com a quantidade de retreinamento disponível — útil onde a poda é agressiva e o retreinamento, caro, e dispensável no regime oposto. Sobre a leitura de todos esses números pesa ainda o controle denso: o mero retreinamento do modelo sem poda reduz a perplexity de 25,17 para 18,68, e é contra esse valor, não contra o modelo pré-treinado original, que qualquer recuperação deve ser medida.

7 Considerações Finais

Referências

BAHDANAU, D.; CHO, K.; BENGIO, Y. Neural machine translation by jointly learning to align and translate. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2015. Citado na página 11.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, v. 5, n. 2, p. 157–166, 1994. Citado 2 vezes nas páginas 6 e 11.

BERGSTRA, J.; BENGIO, Y. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, v. 13, p. 281–305, 2012. Citado na página 8.

BIDERMAN, S. et al. Pythia: A suite for analyzing large language models across training and scaling. In: *Proceedings of the 40th International Conference on Machine Learning*. [S.l.: s.n.], 2023. (PMLR, v. 202), p. 2397–2430. Citado 2 vezes nas páginas 41 e 43.

BLALOCK, D. et al. What is the state of neural network pruning? In: *Proceedings of Machine Learning and Systems (MLSys)*. [S.l.: s.n.], 2020. Citado 7 vezes nas páginas 17, 21, 25, 30, 35, 40 e 50.

CHENG, H.; ZHANG, M.; SHI, J. Q. A survey on deep neural network pruning: Taxonomy, comparison, analysis, and recommendations. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 46, n. 12, p. 10558–10578, 2024. Citado na página 49.

COURTY, B. et al. *CodeCarbon: estimate and track carbon emissions from your computing*. 2023. Disponível em: <https://github.com/mlco2/codecarbon>. Acesso em: 17 abr. 2026. Citado na página 66.

DENIL, M. et al. Predicting parameters in deep learning. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2013. Citado 2 vezes nas páginas 16 e 21.

DENTON, E. L. et al. Exploiting linear structure within convolutional networks for efficient evaluation. In: *Advances in Neural Information Processing Systems (NIPS)*. [S.l.: s.n.], 2014. v. 27, p. 1269–1277. Citado na página 17.

DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. [S.l.]: Association for Computational Linguistics, 2019. p. 4171–4186. Citado 4 vezes nas páginas 41, 42, 64 e 71.

FRANKLE, J.; CARBIN, M. The lottery ticket hypothesis: Finding sparse, trainable neural networks. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2019. Citado 2 vezes nas páginas 22 e 25.

FRANTAR, E.; ALISTARH, D. SparseGPT: Massive language models can be accurately pruned in one-shot. In: *Proceedings of the 40th International Conference on Machine Learning*. [S.l.: s.n.], 2023. (PMLR, v. 202), p. 10323–10337. Citado 4 vezes nas páginas 32, 42, 43 e 49.

GAO, L. et al. The Pile: An 800GB dataset of diverse text for language modeling. *arXiv preprint arXiv:2101.00027*, 2020. Citado 4 vezes nas páginas 42, 43, 44 e 45.

GOKASLAN, A.; COHEN, V. *OpenWebText Corpus*. 2019. Disponível em: <http://Skylion007.github.io/OpenWebTextCorpus>. Acesso em: 28 set. 2026. Citado 2 vezes nas páginas 44 e 45.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, MA: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>. Citado 7 vezes nas páginas 2, 3, 4, 6, 8, 9 e 29.

GURURANGAN, S. et al. Don't stop pretraining: Adapt language models to domains and tasks. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. [S.l.]: Association for Computational Linguistics, 2020. p. 8342–8360. Citado na página 62.

HAN, S. et al. Learning both weights and connections for efficient neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2015. Citado 10 vezes nas páginas 17, 19, 23, 24, 39, 40, 49, 50, 59 e 62.

HENDERSON, P. et al. Towards the systematic reporting of the energy and carbon footprints of machine learning. *Journal of Machine Learning Research*, v. 21, n. 248, p. 1–43, 2020. Citado na página 30.

HENDRYCKS, D.; GIMPEL, K. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016. Citado na página 14.

HINTON, G.; VINYALS, O.; DEAN, J. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015. Citado na página 17.

HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. Citado na página 11.

Hugging Face. *Causal language modeling*. 2026. Documentação da biblioteca `transformers`. Disponível em: <https://huggingface.co/docs/transformers/tasks/language_modeling>. Acesso em: 26 out. 2026. Citado na página 63.

Hugging Face. *Perplexity of fixed-length models*. 2026. Documentação da biblioteca `transformers`. Disponível em: <https://huggingface.co/docs/transformers/perplexity>. Acesso em: 30 set. 2026. Citado 4 vezes nas páginas 42, 46, 73 e 86.

JACOB, B. et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2018. Citado na página 16.

JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.]: Stanford University, 2025. Rascunho da 3.ª edição. Disponível em: <https://web.stanford.edu/~jurafsky/slp3/>. Citado na página 9.

KOVALEVA, O. et al. BERT busters: Outlier dimensions that disrupt transformers. In: *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*. [S.l.]: Association for Computational Linguistics, 2021. p. 3392–3405. Citado na página 33.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2012. Citado na página 5.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. Citado 2 vezes nas páginas 2 e 6.

LECUN, Y.; DENKER, J. S.; SOLLA, S. A. Optimal brain damage. In: *Advances in Neural Information Processing Systems*. [S.l.]: Morgan Kaufmann, 1990. v. 2, p. 598–605. Citado na página 20.

LHOEST, Q. et al. Datasets: A community library for natural language processing. In: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. [S.l.]: Association for Computational Linguistics, 2021. p. 175–184. Citado na página 66.

LI, H. et al. Pruning filters for efficient convnets. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2017. Citado 11 vezes nas páginas 19, 24, 25, 35, 39, 40, 49, 50, 51, 59 e 82.

LIU, Z. et al. Rethinking the value of network pruning. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2019. Citado na página 25.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2019. Citado na página 64.

LUCCIONI, A. S.; VIGUIER, S.; LIGOZAT, A.-L. Estimating the carbon footprint of BLOOM, a 176B parameter language model. *arXiv preprint arXiv:2211.02001*, 2022. Citado na página 15.

MERITY, S. et al. Pointer sentinel mixture models. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2017. Citado 3 vezes nas páginas 40, 44 e 45.

MICHEL, P.; LEVY, O.; NEUBIG, G. Are sixteen heads really better than one? In: *Advances in Neural Information Processing Systems*. [S.l.]: Curran Associates, Inc., 2019. v. 32. Citado 5 vezes nas páginas 13, 21, 49, 59 e 83.

MICIKEVICIUS, P. et al. Mixed precision training. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2018. Citado na página 65.

NAIR, V.; HINTON, G. E. Rectified linear units improve restricted Boltzmann machines. In: *Proceedings of the 27th International Conference on Machine Learning (ICML)*. [S.l.: s.n.], 2010. Citado 2 vezes nas páginas 5 e 14.

NIELSEN, M. A. *Neural Networks and Deep Learning*. [S.l.]: Determination Press, 2015. Disponível em: <http://neuralnetworksanddeeplearning.com/>. Citado 3 vezes nas páginas 3, 4 e 5.

NVIDIA Corporation. *NVIDIA T4 Tensor Core GPU: Datasheet*. 2019. Disponível em: <https://www.nvidia.com/content/dam/en-zz/Solutions/Data-Center/tesla-t4/t4-tensor-core-datasheet-951643.pdf>. Acesso em: 28 set. 2026. Citado 3 vezes nas páginas 27, 65 e 68.

NVIDIA Corporation. *NVIDIA A100 Tensor Core GPU Architecture*. 2020. White paper. Descreve o suporte a esparsidade estruturada 2:4 na arquitetura Ampere. Citado na página 19.

PASZKE, A. et al. Pytorch: An imperative style, high-performance deep learning library. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2019. Citado 2 vezes nas páginas 41 e 65.

PATTERSON, D. et al. Carbon emissions and large neural network training. *arXiv preprint arXiv:2104.10350*, 2021. Citado na página 15.

RADFORD, A. et al. Language models are unsupervised multitask learners. *OpenAI Technical Report*, 2019. Citado 9 vezes nas páginas 14, 27, 40, 41, 42, 43, 44, 45 e 73.

RAJBHANDARI, S. et al. ZeRO: Memory optimizations toward training trillion parameter models. In: *SC20: International Conference for High Performance Computing, Networking, Storage and Analysis*. [S.l.]: IEEE, 2020. p. 1–16. Citado 3 vezes nas páginas 27, 42 e 43.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, v. 323, n. 6088, p. 533–536, 1986. Citado na página 7.

SANH, V. et al. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019. Citado 2 vezes nas páginas 41 e 43.

SANH, V.; WOLF, T.; RUSH, A. M. Movement pruning: Adaptive sparsity by fine-tuning. In: *Advances in Neural Information Processing Systems*. [S.l.]: Curran Associates, Inc., 2020. v. 33, p. 20378–20389. Citado na página 49.

SCHWARTZ, R. et al. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020. Citado 2 vezes nas páginas 15 e 30.

SEVILLA, J. et al. Compute trends across three eras of machine learning. *arXiv preprint arXiv:2202.05924*, 2022. Citado na página 16.

SNOEK, J.; LAROCHELLE, H.; ADAMS, R. P. Practical Bayesian optimization of machine learning algorithms. In: *Advances in Neural Information Processing Systems (NIPS)*. [S.l.: s.n.], 2012. v. 25, p. 2951–2959. Citado na página 8.

STRUBELL, E.; GANESH, A.; MCCALLUM, A. Energy and policy considerations for deep learning in nlp. In: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S.l.: s.n.], 2019. Citado 2 vezes nas páginas 15 e 27.

SUN, M. et al. A simple and effective pruning approach for large language models. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2024. Citado 4 vezes nas páginas 32, 42, 43 e 49.

TOUVRON, H. et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023. Citado 2 vezes nas páginas 27 e 41.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. p. 5998–6008. Citado 3 vezes nas páginas 10, 12 e 13.

WOLF, T. et al. Transformers: State-of-the-art natural language processing. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. [S.l.]: Association for Computational Linguistics, 2020. p. 38–45. Citado 2 vezes nas páginas 27 e 65.

YANG, T.-J.; CHEN, Y.-H.; SZE, V. Designing energy-efficient convolutional neural networks using energy-aware pruning. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2017. Citado na página 25.

ZHANG, S. et al. OPT: Open pre-trained transformer language models. *arXiv preprint arXiv:2205.01068*, 2022. Citado 3 vezes nas páginas 27, 41 e 43.

ZHU, L. *THOP: PyTorch-OpCounter*. 2022. Biblioteca Python `thop`, versão 0.1.1. Disponível em: <https://github.com/Lyken17/pytorch-OpCounter>. Acesso em: 26 out. 2026. Citado na página 66.

ZHU, M.; GUPTA, S. To prune, or not to prune: Exploring the efficacy of pruning for model compression. *arXiv preprint arXiv:1710.01878*, 2017. Citado na página 22.

8 Apêndice

[TO DO]